

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA TOÁN - CƠ - TIN HỌC

Lê Bình Minh

BÀI TOÁN PHÁT HIỆN CỘNG ĐỒNG VÀ PHƯƠNG
PHÁP ĐÁNH GIÁ THÔNG QUA MOTIF

KHÓA LUẬN TỐT NGHIỆP ĐẠI HỌC
Ngành: Toán Tin

Hà Nội - 2026

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA TOÁN - CƠ - TIN HỌC

Lê Bình Minh

BÀI TOÁN PHÁT HIỆN CỘNG ĐỒNG VÀ PHƯƠNG
PHÁP ĐÁNH GIÁ THÔNG QUA MOTIF

KHÓA LUẬN TỐT NGHIỆP ĐẠI HỌC
Ngành: Toán Tin

Cán bộ hướng dẫn: PGS.TSKH. Phan Thị Hà Dương

Hà Nội - 2026

LỜI CẢM ƠN

Em xin gửi lời cảm ơn chân thành và sâu sắc nhất tới cô PGS.TSKH. Phan Thị Hà Dương, người đã tận tình hướng dẫn, định hướng nghiên cứu và truyền cho em cảm hứng đối với lĩnh vực lý thuyết đồ thị và phát hiện cộng đồng. Em cũng xin cảm ơn thầy TS. Đỗ Duy Hiếu đã đóng góp nhiều ý kiến quý báu cho khóa luận trong các buổi seminar.

Em xin cảm ơn Viện Toán học và Trung tâm UNESCO về Khoa học và Giáo dục Toán học đã tạo điều kiện tổ chức các buổi seminar để em được học hỏi và trao đổi cùng nhóm nghiên cứu.

Em xin cảm ơn công ty Smartlog và anh TS. Đỗ Đức Hạnh đã hỗ trợ và tạo điều kiện thuận lợi cho em trong suốt quá trình thực hiện khóa luận.

Em xin bày tỏ lòng biết ơn tới các thầy cô Khoa Toán - Cơ - Tin học, Trường Đại học Khoa học Tự nhiên, Đại học Quốc gia Hà Nội, đã truyền đạt cho em những kiến thức quý báu. Em cũng cảm ơn anh Trần Anh Minh cùng các bạn Nguyễn Thùy Trang và Trần Nhật Minh đã luôn đồng hành và chia sẻ với em trong suốt chặng đường này.

Khóa luận khó tránh khỏi thiếu sót, em rất mong nhận được ý kiến đóng góp của quý thầy cô và bạn đọc.

Hà Nội, tháng 5 năm 2026

Sinh viên

Lê Bình Minh

DANH MỤC CÁC KÝ HIỆU VÀ CHỮ VIẾT TẮT

STT	Tên đầy đủ	Ký hiệu/Viết tắt
1	Normalized Cut	NCut
2	Normalized Mutual Information	NMI
3	Clustering Coefficient (hệ số phân cụm)	CC
4	Lancichinetti–Fortunato–Radicchi benchmark	LFR
5	Stochastic Block Model	SBM
6	Superimposed Stochastic Block Model	SupSBM
7	Higher Order Spectral Clustering	HOSC
8	Random Matrix Theory	RMT
9	Ma trận kề của đồ thị G	A
10	Ma trận motif (motif adjacency)	$W^{(M)}$
11	Ma trận hỗn hợp (motif-enhanced)	W_λ
12	Normalized Laplacian	$\mathcal{L}$
13	Modularity matrix	B
14	Tham số nội suy giữa A và $W^{(M)}$	λ

Bảng 1: Danh mục các ký hiệu và chữ viết tắt

Mục lục

Lời cảm ơn	1
Danh mục các ký hiệu và chữ viết tắt	2
Mở đầu	7
1 Đặt vấn đề và tổng quan	10
1.1 Bối cảnh	10
1.2 Các biến thể của bài toán	10
1.3 Các hướng tiếp cận thuật toán	11
1.4 Hướng tiếp cận của khoá luận	12
2 Cơ sở lý thuyết	13
2.1 Phát biểu bài toán	13
2.1.1 Bài toán phát hiện cộng đồng	13
2.1.2 Bài toán với modularity	14
2.1.3 Bài toán với conductance	17
2.2 Đồ thị Higher Order	20
2.2.1 Motif	21
2.2.2 Hệ số phân cụm và vai trò của tam giác trong mạng xã hội	21
2.2.3 Đồ thị Higher Order	23
2.3 Thuật toán phân cụm phổ	25
2.3.1 Thuật toán K -means	26
2.3.2 Tọa độ hóa các đỉnh bằng phổ của toán tử Laplace	26
2.3.3 Thuật toán phân cụm phổ chuẩn hóa	27
2.3.4 Đánh giá và tính đúng đắn	28
3 Đồ thị hỗn hợp G_λ và thuật toán đề xuất	30
3.1 Đồ thị hỗn hợp G_λ	30
3.1.1 Ý tưởng	30
3.1.2 Định nghĩa	30
3.2 Tính chất phổ và hệ quả của thuật toán	31
3.2.1 G_λ là đồ thị có trọng số hợp lệ	31
3.2.2 Conductance trên G_λ	31

3.2.3	Bất đẳng thức Cheeger trên G_λ	32
3.2.4	Tính đúng đắn của phân cụm phổ trên G_λ	33
3.2.5	Cải thiện so với đồ thị Higher Order	34
3.3	Phân tích tỉ lệ phân cụm sai trên mô hình SupSBM	34
3.3.1	Mô hình Superimposed SBM	35
3.3.2	Tỉ lệ phân cụm sai và cận tổng quát	36
3.3.3	Tính kỳ vọng ma trận cạnh trên SupSBM	38
3.3.4	Gộp kỳ vọng hai tầng cạnh	45
3.3.5	Kỳ vọng ma trận tam giác A_T	45
3.3.6	Chứng minh Định lý 3.10	46
3.3.7	Tối ưu λ^* và so sánh với HOSC	47
4	Thực nghiệm và đánh giá	49
4.1	Thiết lập thí nghiệm	49
4.2	Đồ thị có cấu trúc cộng đồng	50
4.2.1	LFR Benchmark	50
4.2.2	Stochastic Block Model	53
4.2.3	Planted Partition	56
4.2.4	Gaussian Random Partition Graph	59
4.3	Đồ thị mạng xã hội thật	63
4.4	Tổng hợp: hai chế độ tối ưu của λ	84
	Kết luận	86
	A Chứng minh các định lý	88
A.1	Định lý Courant–Fischer	88
A.2	Định lý Ky Fan	89
A.3	Bất đẳng thức Cheeger	90
	B Các mô hình sinh ngẫu nhiên	92
B.1	Stochastic Block Model	92
B.2	Planted Partition	93
B.3	Gaussian Random Partition Graph	93
B.4	LFR Benchmark	93
	Tài liệu tham khảo	95

Danh mục hình vẽ

Hình 2.1 Ví dụ phân hoạch đồ thị 20 đỉnh thành 4 cụm.	14
Hình 2.2 Xây dựng đồ thị Higher Order G_M từ đồ thị gốc G với $M = K_3$	24
Hình 3.1 Xây dựng đồ thị hỗn hợp G_λ từ G và G_M	31
Hình 3.2 Phép chồng hai tầng của mô hình SupSBM.	36
Hình 3.3 Bốn loại tam giác sinh từ phép chồng cạnh và tam giác trong SupSBM.	46
Hình 4.1 Modularity Q trên năm bộ LFR theo λ	51
Hình 4.2 NMI so với phân hoạch chuẩn trên năm bộ LFR theo λ	51
Hình 4.3 $\overline{CC}_w$ trên năm bộ LFR theo λ	52
Hình 4.4 $\overline{CC}$ trên năm bộ LFR theo λ	52
Hình 4.5 Modularity Q trên năm bộ SBM theo λ	54
Hình 4.6 NMI so với phân hoạch chuẩn trên năm bộ SBM theo λ	54
Hình 4.7 $\overline{CC}_w$ trên năm bộ SBM theo λ	55
Hình 4.8 $\overline{CC}$ trên năm bộ SBM theo λ	55
Hình 4.9 Modularity Q trên bốn bộ Planted Partition theo λ	57
Hình 4.10 NMI so với phân hoạch chuẩn trên bốn bộ Planted Partition theo λ	57
Hình 4.11 $\overline{CC}_w$ trên bốn bộ Planted Partition theo λ	58
Hình 4.12 $\overline{CC}$ trên bốn bộ Planted Partition theo λ	58
Hình 4.13 Modularity Q trên năm bộ GRPG theo λ	60
Hình 4.14 NMI so với phân hoạch chuẩn trên năm bộ GRPG theo λ	60
Hình 4.15 $\overline{CC}_w$ trên năm bộ GRPG theo λ	61
Hình 4.16 $\overline{CC}$ trên năm bộ GRPG theo λ	61
Hình 4.17 Modularity Q trên musae_DE theo λ và K	63
Hình 4.18 $\overline{CC}_w$ trên musae_DE theo λ và K	64
Hình 4.19 $\overline{CC}$ trên musae_DE theo λ và K	64
Hình 4.20 Modularity Q trên musae_ES theo λ và K	65
Hình 4.21 $\overline{CC}_w$ trên musae_ES theo λ và K	66
Hình 4.22 $\overline{CC}$ trên musae_ES theo λ và K	66
Hình 4.23 Modularity Q trên lastfm_asia theo λ và K	67

Hình 4.24 $\overline{CC}_w$ trên lastfm_asia theo λ và K	68
Hình 4.25 $\overline{CC}$ trên lastfm_asia theo λ và K	68
Hình 4.26 Modularity Q trên Email-Enron theo λ và K	69
Hình 4.27 $\overline{CC}_w$ trên Email-Enron theo λ và K	70
Hình 4.28 $\overline{CC}$ trên Email-Enron theo λ và K	70
Hình 4.29 Modularity Q trên facebook_combined theo λ và K . . .	71
Hình 4.30 $\overline{CC}_w$ trên facebook_combined theo λ và K	72
Hình 4.31 $\overline{CC}$ trên facebook_combined theo λ và K	72
Hình 4.32 Modularity Q trên CA-GrQc theo λ và K	73
Hình 4.33 $\overline{CC}_w$ trên CA-GrQc theo λ và K	74
Hình 4.34 $\overline{CC}$ trên CA-GrQc theo λ và K	74
Hình 4.35 Modularity Q trên CA-AstroPh theo λ và K	75
Hình 4.36 $\overline{CC}_w$ trên CA-AstroPh theo λ và K	76
Hình 4.37 $\overline{CC}$ trên CA-AstroPh theo λ và K	76
Hình 4.38 Modularity Q trên CA-CondMat theo λ và K	77
Hình 4.39 $\overline{CC}_w$ trên CA-CondMat theo λ và K	78
Hình 4.40 $\overline{CC}$ trên CA-CondMat theo λ và K	78
Hình 4.41 Modularity Q trên CA-HepTh theo λ và K	79
Hình 4.42 $\overline{CC}_w$ trên CA-HepTh theo λ và K	80
Hình 4.43 $\overline{CC}$ trên CA-HepTh theo λ và K	80
Hình 4.44 Modularity Q trên musae_facebook theo λ và K	81
Hình 4.45 $\overline{CC}_w$ trên musae_facebook theo λ và K	82
Hình 4.46 $\overline{CC}$ trên musae_facebook theo λ và K	82

Danh mục bảng

Bảng 4.1 Kết quả tốt nhất trên bốn mô hình có cấu trúc cộng đồng	50
Bảng 4.2 Năm bộ test LFR có cải thiện modularity lớn nhất . . .	50
Bảng 4.3 Năm bộ test SBM có cải thiện modularity lớn nhất . . .	53
Bảng 4.4 Bốn bộ test Planted có cải thiện modularity lớn nhất . .	56
Bảng 4.5 Năm bộ test GRPG có cải thiện modularity lớn nhất . .	59
Bảng 4.6 Tổng hợp kết quả trên mười đồ thị mạng xã hội thật . .	63
Bảng 4.7 Hai chế độ tối ưu của λ^* phụ thuộc loại đồ thị	85

MỞ ĐẦU

Trong các cấu trúc toán học được dùng để mô tả thế giới, đồ thị có lẽ là cấu trúc có sức biểu diễn lớn nhất khi chỉ với hai thành phần tối giản là đỉnh và cạnh, nó đã đủ để mô hình hoá hầu hết mọi hệ thống mà ở đó các thực thể có quan hệ với nhau, từ mạng máy tính, mạng giao thông đô thị, mạng tương tác protein, cho đến mạng trích dẫn khoa học hay mạng người dùng trên mạng xã hội. Bước sang thế kỷ 21, khi dữ liệu thu thập được vượt ra khỏi mọi quy mô có thể quan sát thủ công, lớp đối tượng mà ta phải đối mặt không còn là những đồ thị nhỏ vẽ ra trên giấy, mà là những đồ thị lớn với hàng tỷ đỉnh và hàng nghìn tỷ cạnh như Facebook, Twitter, mạng tri thức Wikipedia, mạng trích dẫn khoa học, mạng tương tác gen hay mạng giao dịch tài chính. Phân tích những đối tượng này không còn dừng ở mức trừu tượng toán học mà đã trở thành công cụ then chốt để hiểu các hệ thống thực mà ta đang sống cùng.

Sức mạnh của đồ thị lớn nằm ở chỗ chính cấu trúc của nó đã mã hoá những thông tin mà ta không nhìn thấy được khi quan sát từng thực thể đơn lẻ. Hai người dùng tưởng chừng không liên quan trên mạng xã hội có thể cùng thuộc một nhóm sở thích chỉ vì cùng kết nối tới một tập bạn chung, hay hai protein có chức năng khác nhau trên giấy vẫn có thể cùng tham gia một con đường chuyển hoá nếu cấu trúc tương tác của chúng tương tự. Cấu trúc của đồ thị, vì thế, là một dạng tín hiệu, và phát hiện các cấu trúc ẩn trong đồ thị lớn chính là cách ta rút tri thức từ dữ liệu quan hệ.

Trong số những cấu trúc cần phát hiện, cộng đồng là một trong những đối tượng quan trọng nhất, hiểu nôm na là một nhóm đỉnh có liên kết nội bộ chặt chẽ và liên kết ra ngoài thưa hơn, ứng với nhóm bạn bè hay nhóm sở thích trong mạng xã hội, với phức hợp protein cùng chức năng trong mạng sinh học, và với chủ đề nghiên cứu trong mạng trích dẫn. Bài toán phát hiện cộng đồng vì vậy được đặt ra một cách rất tự nhiên: cho một đồ thị G , hãy phân hoạch tập đỉnh thành các cụm sao cho mỗi cụm phản ánh đúng cấu trúc cộng đồng nội tại của đồ thị. Các tiêu chí đánh giá phân hoạch và phát biểu hình thức của bài toán được trình bày ở Chương 2.

Tuy nhiên, đồ thị lớn không chỉ chứa thông tin ở mức cạnh đơn lẻ. Bên cạnh các cạnh, có những cấu trúc bậc cao là các đồ thị con xuất hiện với tần suất bất thường so với mô hình sinh cạnh ngẫu nhiên, mang theo những tín hiệu mà phân tích cạnh đôi khi không phát hiện được. Trong nhiều mạng thực, đặc biệt là mạng xã hội, tam giác K_3 là mẫu hình con được nghiên cứu rộng rãi nhất, bởi một quan sát rất quen thuộc: hai người cùng quen chung một người thứ ba có xu hướng quen biết nhau cao hơn so với hai người không có người quen chung. Tam giác vì thế không xuất hiện một cách ngẫu nhiên trên mạng xã hội mà là dấu vết trực tiếp của cơ chế hình thành cộng đồng, và lẽ tự nhiên là người ta muốn tận dụng tín hiệu này khi phân cụm.

Hướng tiếp cận đưa cấu trúc bậc cao vào thuật toán phân cụm đã được Benson, Gleich và Leskovec đề xuất một cách hệ thống vào năm 2016 [1], với ý tưởng rằng thay vì tối thiểu hoá số cạnh bị cắt qua biên cụm như cách làm cổ điển, ta tối thiểu hoá số motif bị cắt. Để hiện thực hoá ý tưởng đó, các tác giả xây dựng một đồ thị mới G_M trên cùng tập đỉnh, trong đó trọng số cạnh giữa hai đỉnh bằng số tam giác đi qua cả hai, rồi áp dụng phân cụm phổ trên G_M thay vì trên đồ thị gốc. Cách tiếp cận này cho kết quả tốt trên một số đồ thị, nhưng cũng nhanh chóng bộc lộ hai hạn chế khi áp dụng cho đồ thị lớn: một mặt, một đỉnh không thuộc bất kỳ tam giác nào sẽ trở thành cô lập trong G_M dù trong đồ thị gốc có nhiều cạnh kề, mà trong các đồ thị thưa quy mô lớn, tỷ lệ đỉnh như vậy là không nhỏ; mặt khác, G_M bỏ qua hoàn toàn thông tin cạnh gốc, dù cạnh vốn là đại lượng cơ bản nhất mô tả quan hệ giữa các đỉnh, và hệ quả là khi đánh giá phân hoạch thu được bằng modularity hay conductance trên cạnh, G_M thường cho kết quả tệ hơn phân cụm phổ trên ma trận kề.

Xuất phát từ quan sát rằng cạnh và motif đều mang tín hiệu cộng đồng nhưng ở những mức khác nhau, khoá luận đề xuất một ma trận hỗn hợp $W_\lambda = A + \lambda W^{(M)}$ với $\lambda \geq 0$ đóng vai trò tham số nội suy giữa hai nguồn thông tin. Khi $\lambda = 0$, thuật toán quy về phân cụm phổ cổ điển; khi $\lambda \rightarrow \infty$, nó tiệm cận về phương pháp motif thuần G_M , và những giá trị λ hữu hạn ở giữa cho phép tận dụng đồng thời cả hai. Cấu trúc lai này một mặt khôi phục được tính liên thông của đồ thị thưa, vì các cạnh trong A ngăn không cho đỉnh không thuộc tam giác trở nên cô lập, mặt khác vẫn cho phép thông tin motif đóng góp vào kết quả phân hoạch. Các tính chất phổ kế thừa, ý nghĩa của tham số λ và bằng chứng thực nghiệm về vai trò của motif sẽ được phân tích chi tiết trong các chương tiếp theo của khoá luận.

Khoá luận được tổ chức thành bốn chương chính, kèm phần Kết luận và Tài liệu tham khảo:

- Chương 1 đặt vấn đề và tổng quan: bối cảnh đồ thị mạng xã hội quy mô lớn, các biến thể của bài toán phát hiện cộng đồng và các hướng tiếp cận thuật toán đã được nghiên cứu.
- Chương 2 trình bày các kết quả nền tảng: metric đánh giá phân hoạch, cấu trúc đồ thị motif, và thuật toán phân cụm phổ kèm các định lý nền.
- Chương 3 trình bày đóng góp lý thuyết: ma trận hỗn hợp W_λ , các tính chất phổ kế thừa, diễn giải Pareto của tham số λ và hai chế độ phụ thuộc cấu trúc đồ thị.
- Chương 4 trình bày phần thực nghiệm trên đồ thị sinh ngẫu nhiên và đồ thị xã hội thật, kèm phân tích kết quả.
- Kết luận tổng kết đóng góp, hạn chế và các hướng nghiên cứu tiếp theo.

Chương 1

ĐẶT VẤN ĐỀ VÀ TỔNG QUAN

1.1 Bối cảnh

Đồ thị mạng xã hội ngày nay là những đối tượng có quy mô rất lớn, từ vài trăm nghìn đến hàng tỷ đỉnh, mà cấu trúc của chúng mã hoá nhiều hiện tượng xã hội đáng quan tâm, chẳng hạn quá trình lan truyền thông tin, sự hình thành các nhóm sở thích hay sự xuất hiện của những vai trò trung gian giữa các cộng đồng. Để quan sát những hiện tượng này một cách hệ thống thay vì dựa trên trực giác hay khảo sát thủ công, người nghiên cứu cần một cách phân rã đồ thị thành các đơn vị có ý nghĩa, mà trong đó cộng đồng là đơn vị cơ bản nhất.

Khó khăn nằm ở chỗ cộng đồng không có một định nghĩa toán học duy nhất: trong mạng xã hội cộng đồng là một nhóm bạn bè, trong mạng sinh học là một phức hợp protein cùng chức năng, trong mạng trích dẫn là một chủ đề nghiên cứu. Tùy vào hiện tượng cần nắm bắt, cùng một đồ thị có thể được phân tích theo nhiều cách khác nhau, và mỗi cách đặt ra một bài toán toán học riêng với cách thao tác hoá riêng. Bài toán phát hiện cộng đồng vì vậy không phải là một bài toán đơn lẻ, mà là một họ bài toán mà mỗi biến thể trả lời một câu hỏi quan sát khác về cấu trúc của mạng. Hai mục tiếp theo đi qua các biến thể thường gặp và các hướng tiếp cận thuật toán đã được nghiên cứu, qua đó dẫn tới hướng đi mà khoá luận lựa chọn.

1.2 Các biến thể của bài toán

Ba biến thể được nhắc đến nhiều nhất là phát hiện cộng đồng toàn cục, cục bộ và chồng chéo. Mỗi biến thể tương ứng với một câu hỏi quan sát khác và dẫn tới các thuật toán có cấu trúc rất khác nhau.

Phát hiện cộng đồng toàn cục đặt ra yêu cầu cơ bản nhất: cho toàn bộ đồ thị G , hãy phân hoạch tập đỉnh thành các cụm sao cho cấu trúc cộng đồng nội tại được phản ánh đúng. Đây là biến thể được nghiên

cứu sớm nhất và sâu nhất, đồng thời là biến thể mà khoá luận tập trung giải quyết, vì phân hoạch toàn cục cho ta một bức tranh tổng thể về cấu trúc của đồ thị và là điểm khởi đầu tự nhiên trước khi xét các biến thể chi tiết hơn.

Phát hiện cộng đồng cục bộ thay đổi giả thiết đầu vào: thay vì duyệt toàn bộ đồ thị, người ta chỉ quan sát một đồ thị con $G' \subseteq G$ hoặc xuất phát từ một tập đỉnh hạt giống, rồi tìm cộng đồng trong lân cận của nó. Biến thể này phù hợp với đồ thị quá lớn để duyệt toàn bộ hoặc khi người dùng chỉ quan tâm tới một nhóm cụ thể; các phương pháp dựa trên bước ngẫu nhiên cá nhân hoá hay khuếch tán cục bộ là đại diện điển hình.

Phát hiện cộng đồng chồng chéo bỏ giả thiết phân hoạch: trong nhiều mạng thực, một đỉnh có thể đồng thời thuộc nhiều cộng đồng, chẳng hạn một người dùng vừa là thành viên của nhóm bạn học vừa là thành viên của nhóm đồng nghiệp. Khi đó bài toán không còn là phân hoạch tập đỉnh nữa mà là gán cho mỗi đỉnh một tập các cộng đồng mà nó thuộc về [2].

Ngoài ba biến thể trên còn nhiều mở rộng đáng kể, như phát hiện cộng đồng trên đồ thị có hướng [3], trên đồ thị động theo thời gian, hay trên đồ thị có thuộc tính trên đỉnh. Khóa luận giới hạn ở biến thể toàn cục trên đồ thị vô hướng có trọng số không âm.

1.3 Các hướng tiếp cận thuật toán

Có nhiều hướng tiếp cận để giải bài toán phát hiện cộng đồng. Hai họ thuật toán được nghiên cứu rộng rãi nhất là phân cụm phổ và các thuật toán heuristic.

Phân cụm phổ nói lỏng bài toán tổ hợp thành bài toán trị riêng của một toán tử tuyến tính liên kết với đồ thị, thường là toán tử Laplace. Shi và Malik [4] đề xuất phân cụm phổ chuẩn hoá để giải bài toán normalized cut, là đại diện kinh điển của hướng này. Jin [5] đề xuất thuật toán SCORE chuẩn hoá vector riêng theo cấp đỉnh để xử lý đồ thị có phân bố bậc lệch. Benson, Gleich và Leskovec [1] mở rộng phân cụm phổ sang cấu trúc bậc cao bằng cách thay ma trận kề bằng ma trận trọng số motif. Đặng Tiến Đạt, Đỗ Duy Hiếu và Phan Thị Hà Dương [3] mở rộng hướng phổ sang đồ thị có hướng dựa trên phân bố dừng và hitting time của bước ngẫu nhiên.

Thuật toán heuristic trực tiếp tối ưu một hàm chất lượng bằng các bước cập nhật cục bộ tham lam. Thuật toán Louvain của Blondel và cộng

sự [6] di chuyển từng đỉnh sang cụm lân cận sao cho modularity tăng nhiều nhất, rồi gộp các cụm thành đỉnh siêu để lặp ở mức cao hơn, nhờ vậy đạt khả năng mở rộng tới hàng triệu đỉnh. Phan Thị Hà Dương và Đỗ Duy Hiếu [7] cải tiến Louvain bằng bước ngẫu nhiên để giảm phụ thuộc thứ tự duyệt và tránh kẹt ở cực trị địa phương; trên cùng hướng bước ngẫu nhiên, các tác giả mở rộng thuật toán Walktrap để xử lý đồ thị lớn [8].

1.4 Hướng tiếp cận của khoá luận

Khoá luận đi theo hướng phổ, vì cấu trúc đại số của hướng này cho phép phát biểu rõ ràng quan hệ giữa phổ của toán tử liên kết với đồ thị và chất lượng phân hoạch, đồng thời cho phép mở rộng tự nhiên sang cấu trúc bậc cao bằng cách thay đổi ma trận trọng số trước khi tính phổ. Trong khuôn khổ đó, khoá luận tập trung vào việc kết hợp ma trận kề với ma trận motif, trong đó tam giác K_3 được dùng làm motif đại diện do vai trò trực tiếp của nó trong cơ chế hình thành cộng đồng trên mạng xã hội. Cơ sở lý thuyết của hướng đi này và đề xuất cụ thể của khoá luận được trình bày trong các chương tiếp theo.

Chương 2

CƠ SỞ LÝ THUYẾT


Chương này trình bày các kết quả nền tảng được dùng làm công cụ cho phần lý thuyết ở Chương 3. Nội dung đi từ phát biểu bài toán phát hiện cộng đồng dưới dạng tối ưu, qua hệ số phân cụm và các dạng đồ thị, đến thuật toán phân cụm phổ kèm các định lý nền.

Quy ước ký hiệu. Trong toàn khóa luận, $G = (V, E)$ là đồ thị vô hướng với $|V| = n$, $|E| = m$, ma trận kề A đối xứng và không âm. Đỉnh trong V được ký hiệu bằng các chữ cái u, v, w . Bậc của đỉnh u là $d_u = \sum_{v \in V} A_{uv}$. Một phân hoạch của V thành K cụm được ký hiệu $\mathcal{C} = \{C_1, \dots, C_K\}$ với $V = \bigsqcup_k C_k$.

2.1 Phát biểu bài toán

2.1.1 Bài toán phát hiện cộng đồng

Cho một đồ thị vô hướng $G = (V, E)$ mô hình hoá một hệ thống quan hệ nào đó, bài toán phát hiện cộng đồng đặt ra yêu cầu rất tự nhiên: hãy chia tập đỉnh V thành các nhóm sao cho mỗi nhóm tương ứng với một cộng đồng thực sự trong hệ thống đang xét, nghĩa là các đỉnh trong cùng một nhóm có liên kết chặt chẽ với nhau và liên kết ra ngoài nhóm thưa hơn. Hình 2.1 minh hoạ trực giác này trên một đồ thị 20 đỉnh được chia thành bốn cụm, các cạnh nội cụm tập trung dày trong khi cạnh liên cụm chỉ chiếm tỷ lệ nhỏ.



Hình 2.1: Ví dụ phân hoạch đồ thị 20 đỉnh thành 4 cụm. Cạnh liền nét là cạnh nội cụm, cạnh nét đứt là cạnh liên cụm.

Đặc điểm quan trọng nhất khiến bài toán này khó là khái niệm cộng đồng vốn không có một định nghĩa toán học duy nhất. Trong mạng xã hội, cộng đồng có thể là một nhóm bạn bè thân thiết; trong mạng sinh học, có thể là một phức hợp protein cùng chức năng; trong mạng trích dẫn, có thể là một chủ đề nghiên cứu. Mỗi ngữ cảnh ứng với một tiêu chí khác nhau về “thế nào là cộng đồng”, và do đó không có một phân hoạch nào được công nhận là đúng tuyệt đối cho mọi đồ thị. Để có thể đánh giá và so sánh các phân hoạch một cách có hệ thống, người ta đưa ra các tiêu chí đánh giá dưới dạng một hàm số

$$f : \mathcal{P}(V) \rightarrow \mathbb{R} \quad (2.1)$$

- Trong đó $\mathcal{P}(V)$ là tập tất cả các phân hoạch của V thành các tập con không rỗng đôi một rời nhau.

Ngay cả khi đã cố định một tiêu chí f , việc tìm phân hoạch tối ưu f vẫn là một bài toán khó. Lực lượng của $\mathcal{P}(V)$ tăng theo cấp số mũ với n và được đếm bởi số Bell B_n , nên duyệt toàn bộ là không khả thi với đồ thị quy mô lớn. Hơn nữa, hai bài toán cụ thể là cực đại modularity và cực tiểu normalized cut đều thuộc lớp NP-khó [4], [9].

2.1.2 Bài toán với modularity

Định nghĩa 2.1 (Ma trận modularity). Mô hình ngẫu nhiên cùng dãy bậc cho kỳ vọng cạnh giữa hai đỉnh u và v bằng $d_u d_v / (2m)$. Ma trận

modularity được định nghĩa

$$B = A - \frac{dd^\top}{2m},$$

trong đó $d \in \mathbb{R}^n$ là vector bậc của đồ thị.

Định nghĩa 2.2 (Modularity của phân hoạch [9]). Cho phân hoạch $\mathcal{C} = \{C_1, \dots, C_K\}$ với c_u ký hiệu cụm chứa đỉnh u , và $\delta(c_u, c_v)$ là Kronecker delta, bằng 1 nếu $c_u = c_v$ và bằng 0 nếu khác. Modularity được định nghĩa

$$Q(\mathcal{C}) = \frac{1}{2m} \sum_{u,v} \left(A_{uv} - \frac{d_u d_v}{2m} \right) \delta(c_u, c_v).$$

Đặt $S \in \{0, 1\}^{n \times K}$ là ma trận chỉ thị cụm với $S_{uk} = 1 \iff u \in C_k$. Khi đó

$$Q = \frac{1}{2m} \text{Tr}(S^\top B S).$$

Ý nghĩa của Q là chênh lệch giữa mật độ cạnh nội cụm thực tế và mật độ kỳ vọng. Giá trị $Q > 0$ nghĩa là phân hoạch tốt hơn ngẫu nhiên, Q càng lớn càng phân hoạch tốt theo nghĩa cộng đồng.

Bài toán phát hiện cộng đồng theo modularity được phát biểu như sau. Hàm mục tiêu là vết của ma trận $S^\top BS$, đại diện cho modularity của một phân hoạch:

$$\max_{S \in \mathbb{R}^{n \times K}} \text{Tr}(S^\top BS). \quad (2.2)$$

Ma trận S là ma trận assignment chịu ba ràng buộc, mỗi ràng buộc thể hiện một tính chất bắt buộc của phân hoạch.

Mỗi phần tử S_{uk} là nhãn cho biết đỉnh u có thuộc cụm k hay không, do đó chỉ nhận giá trị nhị phân:

$$S_{uk} \in \{0, 1\}, \quad \forall u \in V, \forall k \in \{1, \dots, K\}. \quad (2.3)$$

Mỗi đỉnh thuộc đúng một cụm, tức là tổng các phần tử trên hàng tương ứng phải bằng 1:

$$\sum_{k=1}^K S_{uk} = 1, \quad \forall u \in V. \quad (2.4)$$

Không cụm nào được rỗng, tức là tổng các phần tử trên cột tương ứng phải lớn hơn hoặc bằng 1:

$$\sum_{u \in V} S_{uk} \geq 1, \quad \forall k \in \{1, \dots, K\}. \quad (2.5)$$

Ba ràng buộc trên tương đương với điều kiện $\mathcal{C} \in \mathcal{P}_K(V)$.

Bài toán (2.2) với các ràng buộc trên là NP-khó [9]. Phép nối lỏng phổ chuẩn thay các ràng buộc rời rạc bằng một ràng buộc trực giao đại số tuyến tính, biến bài toán tổ hợp thành bài toán liên tục giải được bằng phân tích trị riêng. Cơ sở của phép nối lỏng này là định lý Ky Fan, một tổng quát hóa của thương Rayleigh từ một vector lên K vector trực giao.

Định lý 2.3 (Tổng quát hóa Ky Fan [10]). *Cho ma trận đối xứng $M \in \mathbb{R}^{n \times n}$ với các giá trị riêng $\lambda_1(M) \leq \dots \leq \lambda_n(M)$ và các vector riêng đơn vị tương ứng $v_1, \dots, v_n$. Khi đó với mọi $k \leq n$:*

$$\begin{aligned} \max_{X \in \mathbb{R}^{n \times k}, X^\top X = I_k} \text{Tr}(X^\top M X) &= \sum_{i=1}^k \lambda_{n-i+1}(M), \\ \min_{X \in \mathbb{R}^{n \times k}, X^\top X = I_k} \text{Tr}(X^\top M X) &= \sum_{i=1}^k \lambda_i(M). \end{aligned}$$

Nghiệm cực đại đạt tại $X^ = [v_n, v_{n-1}, \dots, v_{n-k+1}]$ và nghiệm cực tiểu đạt tại $X^* = [v_1, v_2, \dots, v_k]$.*

Áp dụng định lý 2.3 cho ma trận modularity B với $k = K$, ta thay các ràng buộc rời rạc (2.3)–(2.5) bằng ràng buộc trực giao $S^\top S = I_K$ và thu được bài toán liên tục

$$\max_{S \in \mathbb{R}^{n \times K}, S^\top S = I_K} \text{Tr}(S^\top B S). \quad (2.6)$$

Nghiệm tối ưu là $S^* = [v_n, v_{n-1}, \dots, v_{n-K+1}]$ gồm K vector riêng của B ứng với K giá trị riêng lớn nhất, và giá trị tối ưu bằng tổng K giá trị riêng lớn nhất đó. Bước rời rạc hóa từ $S^* \in \mathbb{R}^{n \times K}$ về một phân hoạch cụ thể được thực hiện bằng k -means trên các hàng của S^* , sẽ trình bày ở Mục 2.3.

2.1.3 Bài toán với conductance

Chia tập đỉnh V thành hai phần $V = S \cup \bar{S}$, trong đó $\emptyset \neq S \subsetneq V$ và $\bar{S} = V \setminus S$.

Định nghĩa 2.4 (Cut và volume). Cho $S \subset V$. Cut của $(S, \bar{S})$ là tổng trọng số các cạnh có một đầu trong S và đầu kia trong $\bar{S}$:

$$\text{cut}(S, \bar{S}) = \sum_{u \in S, v \in \bar{S}} A_{uv}.$$

Volume của S là tổng bậc các đỉnh trong S :

$$\text{vol}(S) = \sum_{u \in S} d_u.$$

Chất lượng của nhát cắt $(S, \bar{S})$ được phản ánh trực tiếp bởi giá trị $\text{cut}(S, \bar{S})$: giá trị càng nhỏ thì S và $\bar{S}$ càng ít nối với nhau. Tuy nhiên dùng $\text{cut}(S, \bar{S})$ làm tiêu chí có một nhược điểm cố hữu: các nhát cắt suy biến như $|S| = 1$ thường có giá trị cut rất nhỏ, tạo ra phân hoạch mất cân bằng. Để khắc phục, ta chuẩn hóa cut theo volume của mỗi phía, dẫn đến đại lượng conductance.

Định nghĩa 2.5 (Conductance [11]). Conductance của tập S là

$$\phi(S) = \frac{\text{cut}(S, \bar{S})}{\min(\text{vol}(S), \text{vol}(\bar{S}))}.$$

Conductance tối thiểu của đồ thị là $\phi^* = \min_{\emptyset \neq S \subsetneq V} \phi(S)$.

Mẫu số $\min(\text{vol}(S), \text{vol}(\bar{S}))$ ngăn các nhát cắt mất cân bằng đạt giá trị tối ưu một cách giả tạo. Bài toán cực tiểu hóa ϕ trên tất cả các nhát cắt là NP-khó, do đó cần một cách diễn giải khác để có thể tiếp cận bằng công cụ giải tích.

Quan sát then chốt là một nhất cắt $(S, \bar{S})$ có thể biểu diễn bằng một hàm số gán giá trị cho từng đỉnh. Cụ thể, đặt $f : V \rightarrow \mathbb{R}$ là hàm chỉ thị của S ,

$$f(u) = \begin{cases} 1 & \text{nếu } u \in S, \\ 0 & \text{nếu } u \in \bar{S}. \end{cases}$$

Khi đó hai đại lượng cấu thành conductance đều biểu diễn được qua f . Số cạnh bị cắt bằng tổng bình phương sai phân của f qua các cạnh:

$$\text{cut}(S, \bar{S}) = \sum_{(u,v) \in E} (f(u) - f(v))^2,$$

vì $f(u) - f(v)$ bằng ± 1 trên cạnh bị cắt và bằng 0 trên cạnh không bị cắt. Tổng bình phương trên có thể hiểu là độ biến thiên của f qua cấu trúc cạnh của đồ thị: f thay đổi càng nhiều qua cạnh thì tổng càng lớn. Tương tự, volume của S bằng tổng có trọng số bậc của các giá trị f^2 :

$$\text{vol}(S) = \sum_{u \in V} f(u)^2 d_u.$$

Ý tưởng then chốt là tổng quát hóa: cho f là hàm thực bất kỳ trên V , không nhất thiết nhị phân. Khi đó tỷ số

$$\mathcal{R}(f) = \frac{\sum_{(u,v) \in E} (f(u) - f(v))^2}{\sum_{u \in V} f(u)^2 d_u}$$

đo độ biến thiên của f qua cạnh, chuẩn hóa theo độ lớn có trọng số của f . Khi f là chỉ thị của S , ta có $\mathcal{R}(f) = \text{cut}(S, \bar{S})/\text{vol}(S)$, gần với conductance về hình thức. Khi f là hàm thực tổng quát, $\mathcal{R}(f)$ trở thành một bài toán liên tục có thể tối ưu bằng giải tích, đây chính là phép nối lỏng phổ của bài toán nhất cắt rời rạc. Tỷ số $\mathcal{R}(f)$ là dạng biến phân của thương Rayleigh trên đồ thị, được Chung phát biểu thành định nghĩa cơ bản trong lý thuyết phổ đồ thị [11].

Định nghĩa 2.6 (Thương Rayleigh trên đồ thị). Cho đồ thị có ma trận kề A , ma trận bậc D và Laplacian không chuẩn hóa $L = D - A$. Với hàm $f : V \rightarrow \mathbb{R}$, $f \neq 0$, thương Rayleigh của f là

$$\mathcal{R}(f) = \frac{f^\top L f}{f^\top D f} = \frac{\sum_{(u,v) \in E} (f(u) - f(v))^2}{\sum_{u \in V} f(u)^2 d_u}.$$

Đẳng thức $f^\top L f = \sum_{(u,v) \in E} (f(u) - f(v))^2$ là đồng nhất thức cơ bản của Laplacian, nối dạng đại số ma trận với dạng biến phân trên đồ thị.

Đặt $g = D^{1/2}f$ và $\mathcal{L} = I - D^{-1/2}AD^{-1/2}$ là Laplacian chuẩn hóa, mẫu số trở thành $\|g\|^2$ và tử số trở thành $g^\top \mathcal{L}g$, do đó $\mathcal{R}(f) = R(\mathcal{L}, g)$ trong đó

$$R(M, x) = \frac{x^\top Mx}{x^\top x}$$

là thương Rayleigh đại số trên ma trận đối xứng M tổng quát.

Nhờ đồng nhất thức trên, mọi câu hỏi về cực trị của $\mathcal{R}(f)$ đều quy về câu hỏi về phổ của $\mathcal{L}$. Quan sát rằng hàm hằng $f \equiv c$ cho $\mathcal{R}(f) = 0$ vì không có biến thiên qua cạnh nào, ứng với giá trị riêng nhỏ nhất $\lambda_1 = 0$ của $\mathcal{L}$. Khi loại bỏ thành phần hằng, cực tiểu của $\mathcal{R}(f)$ cho ta giá trị riêng nhỏ thứ hai. Kết quả tổng quát hơn cho mọi giá trị riêng được phát biểu qua định lý Courant–Fischer.

Định lý 2.7 (Tính chất biến phân Courant–Fischer). *Cho ma trận đối xứng $M \in \mathbb{R}^{n \times n}$ với các giá trị riêng $\lambda_1(M) \leq \dots \leq \lambda_n(M)$ và các vector riêng đơn vị tương ứng $v_1, \dots, v_n$. Khi đó với mọi $k \in \{1, \dots, n\}$:*

$$\lambda_k(M) = \min_{\substack{U \subset \mathbb{R}^n \\ \dim U = k}} \max_{x \in U \setminus \{0\}} R(M, x) = \max_{x \perp v_1, \dots, v_{k-1}} R(M, x).$$

Đặc biệt, $\lambda_1(M) = \min_{x \neq 0} R(M, x)$ và $\lambda_n(M) = \max_{x \neq 0} R(M, x)$.

Áp dụng định lý 2.7 cho Laplacian chuẩn hóa $\mathcal{L}$ và phép biến đổi $g = D^{1/2}f$ ở trên, ta có

$$\lambda_2(\mathcal{L}) = \min_{f \perp d} \mathcal{R}(f),$$

trong đó $f \perp d$ nghĩa là $\sum_u f(u)d_u = 0$, tức f trực giao với vector bậc $d = D\mathbf{1}$. Đây là đáy của tỷ số biến thiên qua cạnh trên kích thước có trọng số khi đã loại bỏ thành phần hằng. Vì conductance được biểu diễn xấp xỉ qua $\mathcal{R}$ với hàm chỉ thị có trọng, λ_2 và ϕ^* phải có liên hệ định lượng với nhau. Liên hệ đó là nội dung của bất đẳng thức Cheeger.

Định lý 2.8 (Bất đẳng thức Cheeger [11]). *Cho đồ thị vô hướng có trọng số không âm với ma trận kề A và ma trận bậc $D = \text{diag}(d_1, \dots, d_n)$. Đặt*

$$\mathcal{L} = I - D^{-1/2}AD^{-1/2}$$

là Laplacian chuẩn hóa của đồ thị. Khi đó $\mathcal{L}$ đối xứng nửa xác định dương với các giá trị riêng

$$0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n \leq 2,$$

và conductance tối thiểu ϕ^ thỏa mãn cận hai phía*

$$\frac{\lambda_2}{2} \leq \phi^* \leq \sqrt{2\lambda_2}.$$

Bất đẳng thức Cheeger kẹp ϕ^* giữa hai biểu thức của giá trị riêng λ_2 , đại lượng còn được gọi là khoảng cách phổ của đồ thị. Cận dưới $\lambda_2/2 \leq \phi^*$ cho thấy không nhất cắt nào có conductance bé hơn $\lambda_2/2$, do đó λ_2 nhỏ là điều kiện cần để đồ thị có cộng đồng tách rõ. Cận trên $\phi^* \leq \sqrt{2\lambda_2}$ là phần mang tính xây dựng: từ vector riêng ứng với λ_2 , một thuật toán sweep cho phép tìm một nhất cắt cụ thể có conductance không vượt quá $\sqrt{2\lambda_2}$. Hai cận này đảm bảo rằng cực tiểu hóa λ_2 trên các đồ thị có trọng số là một xấp xỉ chặt của bài toán cực tiểu hóa ϕ .

Một điểm đáng lưu ý: bất đẳng thức Cheeger được phát biểu cho mọi đồ thị có trọng số không âm và đối xứng, không yêu cầu thêm điều kiện về cấu trúc. Tính tổng quát này sẽ đóng vai trò then chốt khi xét các biến thể đồ thị có trọng số ở Chương 3.

Định nghĩa 2.9 (Normalized Cut, Shi–Malik 2000 [4]). Với phân hoạch hai cụm $\{S, \bar{S}\}$:

$$\text{NCut}(S, \bar{S}) = \frac{\text{cut}(S, \bar{S})}{\text{vol}(S)} + \frac{\text{cut}(S, \bar{S})}{\text{vol}(\bar{S})}.$$

Tổng quát hóa cho phân hoạch K cụm:

$$\text{NCut}(\mathcal{C}) = \sum_{k=1}^K \frac{\text{cut}(C_k, \bar{C}_k)}{\text{vol}(C_k)}.$$

NCut là một dạng chuẩn hóa theo volume nên không bị thiên lệch về cụm rất nhỏ. Liên hệ với conductance: $\text{NCut}(S, \bar{S}) \approx 2\phi(S)$ khi hai cụm có volume xấp xỉ nhau.

Bài toán tối ưu. Bài toán phát hiện cộng đồng theo conductance hoặc theo normalized cut là

$$\mathcal{C}_{\text{NCut}}^* = \arg \min_{\mathcal{C} \in \mathcal{P}_K(V)} \text{NCut}(\mathcal{C}).$$

Bài toán này là NP-khó [4]. Phép nối lỏng phổ tương ứng dẫn đến vector riêng nhỏ nhất của normalized Laplacian, được trình bày ở Mục 2.3.

2.2 Đồ thị Higher Order

Mục 2.1 đã trình bày bài toán phát hiện cộng đồng dưới góc nhìn cạnh: chất lượng phân hoạch được đo qua cut, ϕ , Q , đều là các đại lượng dựa trên cấu trúc cạnh đơn lẻ. Tuy nhiên trong nhiều mạng thực, đặc biệt là mạng xã hội, cấu trúc bậc cao mang theo tín hiệu cộng đồng mạnh hơn cả cạnh đơn lẻ. Mục này hình thức hóa khái niệm đó thông qua *motif* và

đồ thị *Higher Order*, đồng thời chứng tỏ rằng tam giác K_3 là motif then chốt cho lớp đồ thị xã hội thực tế thông qua hệ số phân cụm.

2.2.1 Motif

Định nghĩa 2.10 (Motif và motif instance). Motif M là một đồ thị con nhỏ, cố định, được dùng làm đơn vị cấu trúc để phân tích đồ thị lớn. Một instance của M trong $G = (V, E)$ là một đồ thị con của G đẳng cấu với M .

Việc chọn motif cụ thể nào phụ thuộc vào loại đồ thị đang xét, vì mỗi lớp đồ thị có cấu trúc bậc cao đặc trưng riêng. Phần bản luận chi tiết về cách chọn motif sẽ được trình bày ở Mục 2.2.2 sau khi giới thiệu hệ số phân cụm.

2.2.2 Hệ số phân cụm và vai trò của tam giác trong mạng xã hội

Để chứng tỏ một motif cụ thể mang ý nghĩa cộng đồng thực sự trong một lớp đồ thị nào đó, ta cần một đại lượng đo mật độ motif trên đồ thị, độc lập với phân hoạch cụ thể. Với motif là tam giác, đại lượng đó là hệ số phân cụm.

Về mặt trực giác, hệ số phân cụm đặc trưng cho xác suất mà một bộ ba đỉnh đã có liên kết bộ phận thực sự khép lại thành một tam giác, và vì vậy phản ánh mức độ chặt chẽ trong cấu trúc kết nối của đồ thị: hệ số phân cụm càng cao, các đỉnh càng có xu hướng đan vào nhau thành các tam giác, một dấu hiệu cho thấy đồ thị mang cấu trúc cộng đồng đậm đặc hơn.

Định nghĩa 2.11 (Hệ số phân cụm tại đỉnh). Hệ số phân cụm tại đỉnh u là

$$cc(u) = \frac{2T_u}{d_u(d_u - 1)},$$

với T_u là số tam giác chứa u trong G . Quy ước $cc(u) := 0$ nếu $d_u \leq 1$.

Định nghĩa 2.12 (Hệ số phân cụm toàn cục). Một *tam giác mở* tại đỉnh v là một bộ ba có thứ tự (u, v, w) với u, w là hai hàng xóm phân biệt của v . Số tam giác mở của G là

$$P_2 = \sum_{v \in V} d_v(d_v - 1).$$

Hệ số phân cụm toàn cục của G là

$$cc_{\text{global}}(G) = \frac{6T}{P_2} = \frac{6T}{\sum_v d_v(d_v - 1)},$$

với T là tổng số tam giác trong G . Quy ước $cc_{\text{global}}(G) := 0$ nếu $P_2 = 0$.

Hệ số cc_{global} nhận giá trị trong $[0, 1]$ và đo xác suất một tam giác mở chọn ngẫu nhiên thực sự đóng thành tam giác. Khác với trung bình của $cc(u)$ trên các đỉnh, cc_{global} tính trọng số theo bậc đỉnh, do đó phản ánh đúng mật độ tam giác ở mức đồ thị mà không bị thiên lệch bởi các đỉnh bậc thấp. Trong khoá luận, cc_{global} được dùng làm tham chiếu để so sánh với hệ số phân cụm trên từng phân hoạch.

Đối với một phân hoạch $\mathcal{C} = \{C_1, \dots, C_K\}$, hai đại lượng tổng hợp được dùng để đánh giá mức độ đóng kín tam giác trên các cụm.

Định nghĩa 2.13 (Hệ số phân cụm trên phân hoạch). Cho cụm C_j trong phân hoạch $\mathcal{C} = \{C_1, \dots, C_K\}$, đặt

$$CC(C_j) = \frac{1}{|C_j|} \sum_{u \in C_j} cc(u).$$

Trung bình của các giá trị này trên các cụm với trọng số đều là

$$\overline{CC}(\mathcal{C}) = \frac{1}{K} \sum_{j=1}^K CC(C_j).$$

Đại lượng $\overline{CC}(\mathcal{C})$ phản ánh mật độ tam giác trung bình bên trong mỗi cụm, nhưng bộc lộ một điểm yếu khi kích thước các cụm chênh lệch nhiều. Vì $\overline{CC}$ gán đồng đều một lượng $\frac{1}{K}$ cho mọi cụm, một cụm chỉ gồm ba đỉnh nổi thành K_3 luôn cho $CC = 1$ và đóng góp ngang bằng một cụm hàng trăm hay hàng nghìn đỉnh. Hệ quả là một phân hoạch sinh ra nhiều cụm rất nhỏ với hệ số phân cụm cao có thể đạt $\overline{CC}$ gần 1 mặc dù về mặt cấu trúc cộng đồng, các cụm cỡ ba đỉnh thường không mang ý nghĩa thực sự. Để khắc phục điểm yếu này, thay vì gán trọng số đều cho các cụm, ta gán trọng số tỉ lệ với kích thước cụm, dẫn tới đại lượng sau đây.

Định nghĩa 2.14 (Hệ số phân cụm có trọng số). Hệ số phân cụm có trọng số của phân hoạch $\mathcal{C} = \{C_1, \dots, C_K\}$ là trung bình có trọng số tỉ lệ với kích thước cụm:

$$\overline{CC}_w(\mathcal{C}) = \frac{\sum_{j=1}^K |C_j| CC(C_j)}{\sum_{j=1}^K |C_j|} = \frac{1}{n} \sum_{u \in V} cc(u).$$

Trong $\overline{CC}_w$, mỗi cụm đóng góp theo đúng số đỉnh nó chứa, nên cụm K_3 chỉ đóng góp ba đỉnh trên tổng n , không thể kéo trung bình lên cao chỉ vì có $CC = 1$. Công thức rút gọn $\overline{CC}_w(\mathcal{C}) = \frac{1}{n} \sum_u cc(u)$ cho thấy đại

lượng này thực chất là trung bình hệ số phân cụm tại đỉnh trên toàn bộ đồ thị, không phụ thuộc cách phân hoạch chia cụm. Vì lý do đó, $\overline{CC}_w$ được dùng làm đại lượng đánh giá chính trong khóa luận; $\overline{CC}$ được tính kèm để phát hiện hiện tượng phân hoạch tạo ra cụm rất nhỏ làm thiên lệch chỉ số.

Bằng chứng thống kê cho vai trò của tam giác. Việc chọn tam giác K_3 làm motif không phải lựa chọn tùy ý mà được công nhận rộng rãi trong tài liệu phân tích mạng nhờ bằng chứng thống kê trên nhiều lớp mạng thực tế khác nhau. Watts và Strogatz [12] là những người đầu tiên chỉ ra rằng nhiều mạng thực, từ mạng diễn viên đồng diễn, mạng kết nối synapse trong hệ thần kinh của giun *C. elegans* đến mạng lưới điện, có hệ số phân cụm trung bình lớn hơn rất nhiều so với mô hình ngẫu nhiên có cùng số đỉnh và cạnh. Kết quả này được Newman tổng hợp lại trong khảo sát [13] cho nhiều lớp mạng thực: mạng cộng tác khoa học, mạng email, mạng web, mạng xã hội. Hệ số phân cụm trung bình trên các mạng này nằm trong khoảng 0,1–0,8, trong khi mật độ cạnh thường chỉ ở mức 10^{-3} trở xuống. Hai đại lượng này có thể so sánh trực tiếp vì cùng thang đo: $cc(u)$ là xác suất có điều kiện rằng hai hàng xóm của u nối với nhau, còn mật độ cạnh là xác suất hai đỉnh bất kỳ nối với nhau. Trên đồ thị ngẫu nhiên Erdős–Rényi $G(n, p)$ với các cạnh độc lập, hai xác suất này bằng nhau và đều bằng p . Trên các mạng thực kể trên, cc lớn hơn mật độ cạnh từ một đến nhiều bậc.

Nếu các cạnh được sinh độc lập với nhau như trong mô hình Erdős–Rényi, kỳ vọng của $cc(u)$ chính bằng mật độ cạnh, do đó khoảng cách giữa hai con số trên không thể giải thích bằng hiệu ứng ngẫu nhiên. Cơ chế tạo nên khoảng cách này là triadic closure, một quy luật xã hội đã được nghiên cứu từ sớm bởi Granovetter [14] và Holland–Leinhardt [15]: hai đỉnh chia sẻ hàng xóm có xu hướng kết nối với nhau cao hơn nhiều so với cặp đỉnh ngẫu nhiên. Mật độ tam giác cao hơn dự đoán ngẫu nhiên do đó là tín hiệu cộng đồng đáng tin cậy chứ không phải nhiễu ngẫu nhiên.

2.2.3 Đồ thị Higher Order

Ý tưởng đưa cấu trúc bậc cao vào bài toán phân cụm được hình thức hóa qua việc xây dựng một đồ thị mới trên cùng tập đỉnh của G , trong đó trọng số cạnh giữa hai đỉnh phản ánh số motif chứa cả hai. Đồ thị mới này được gọi là đồ thị Higher Order.

Định nghĩa 2.15 (Ma trận motif và đồ thị Higher Order). Cho đồ thị $G = (V, E)$ và motif M . Ma trận motif của G ứng với M là $W^{(M)} \in \mathbb{R}^{n \times n}$


với

$$W_{uv}^{(M)} = |\{\text{instance của } M \text{ chứa cả } u \text{ và } v\}|.$$

Đồ thị Higher Order $G_M = (V, W^{(M)})$ là đồ thị có trọng số trên cùng tập đỉnh V , với ma trận trọng số $W^{(M)}$.

Phép xây dựng nói trên có một diễn giải tự nhiên trên mạng xã hội: hai người cùng tham gia một tam giác bạn bè được kết nối qua hai con đường, một cạnh trực tiếp và một con đường gián tiếp qua người thứ ba. Mỗi tam giác mà cả hai cùng thuộc về làm tăng cường mức độ gần gũi của họ. Đồ thị Higher Order G_M định lượng mức độ gần gũi đó bằng cách đặt trọng số cạnh giữa hai đỉnh đúng bằng số motif chứa cả hai.

Hình 2.2 minh họa phép xây dựng này trên một đồ thị mẫu nhỏ.



Hình 2.2: Xây dựng đồ thị Higher Order G_M từ đồ thị gốc G với $M = K_3$. Ở (b), trọng số mỗi cạnh bằng số tam giác chứa cả hai đỉnh, các cạnh không thuộc tam giác nào trong G bị loại bỏ, các đỉnh không thuộc tam giác nào trở thành cô lập (vẽ với viền đứt nét).

Mệnh đề 2.16. Ma trận $W^{(M)}$ đối xứng và không âm. Do đó G_M là đồ thị có trọng số vô hướng hợp lệ, và mọi kết quả phổ phát biểu cho lớp đồ thị này, bao gồm bất đẳng thức Cheeger và các phép nối lỏng phổ của NCut hay modularity, áp dụng được cho G_M .

Tương tự đồ thị gốc, ta định nghĩa motif degree $d_u^{(M)} = \sum_{v \in V} W_{uv}^{(M)}$ và motif volume $\text{vol}_M(S) = \sum_{u \in S} d_u^{(M)}$. Đại lượng cắt theo motif là

$$\text{cut}_M(S, \bar{S}) = |\{\text{motif instance có ít nhất một đỉnh ở mỗi bên}\}|,$$

và conductance motif tương ứng là

$$\phi_M(S) = \frac{\text{cut}_M(S, \bar{S})}{\min(\text{vol}_M(S), \text{vol}_M(\bar{S}))}.$$

Định lý 2.17 (Higher-order Cheeger inequality [1]). *Phân cụm phổ trên $W^{(M)}$ thu được nhất cắt có ϕ_M gần tối ưu, với cùng dạng cận như bất đẳng thức Cheeger cổ điển. Tính chất này là hệ quả trực tiếp của Mệnh đề 2.16 và bất đẳng thức Cheeger áp dụng cho G_M .*

Nhận xét 2.18 (Hai hạn chế của G_M thuần).

- 1) G_M có thể không liên thông: đỉnh không thuộc bất kỳ instance nào của M sẽ bị cô lập trong G_M , dù trong G gốc có thể có nhiều cạnh kề.
- 2) G_M mất thông tin cạnh gốc: cạnh không thuộc instance nào của M bị xóa hoàn toàn trong G_M , dù có thể mang thông tin cộng đồng quan trọng.

Hai hạn chế trên có thể quan sát trực tiếp trên Hình 2.2. Chúng là động lực trực tiếp cho cách tiếp cận đề xuất ở Chương 3.

Cổ định motif $M = K_3$ cho phần còn lại của khóa luận. Định nghĩa 2.15 cho phép M là một motif tùy ý, mở ra nhiều cấu trúc bậc cao khác nhau. Trên cơ sở bằng chứng thống kê đã trình bày ở Mục 2.2.2, cộng với các ưu điểm thuật toán, khóa luận cổ định motif là tam giác trong toàn bộ phần còn lại với ba lý do:

- 1) Tam giác xuất hiện trong mạng xã hội thực tế với mật độ vượt xa kỳ vọng ngẫu nhiên, được giải thích bởi triadic closure, do đó mang tín hiệu cộng đồng có ý nghĩa.
- 2) Số tam giác chứa từng đỉnh hoặc từng cạnh trong đồ thị thưa có thể đếm hiệu quả với độ phức tạp $O(m^{3/2})$, không trở thành bottleneck cho thuật toán quy mô lớn.
- 3) Tam giác đối xứng tự nhiên trên ba đỉnh, không yêu cầu xử lý hướng cạnh hay vai trò không đối xứng giữa các đỉnh, làm cho ma trận motif $W^{(M)}$ đơn giản nhất có thể trong lớp các motif kích thước lớn hơn hai.

Việc khảo sát các motif khác như K_4 hay bi-fan là một hướng mở rộng tự nhiên, nhưng nằm ngoài phạm vi của khóa luận này.

2.3 Thuật toán phân cụm phổ

Trên các lớp đồ thị đã được định nghĩa, gồm đồ thị gốc G và đồ thị Higher Order G_M , phân cụm phổ là một trong những thuật toán ứng dụng tốt nhất phép tọa độ hóa qua phổ của Laplacian, và đã được chứng minh là cách hiệu quả để tối ưu normalized cut trên đồ thị có trọng số không âm [4].

2.3.1 Thuật toán K -means

Thuật toán K -means được trình bày tổng quát cho tập n điểm trong $\mathbb{R}^d$ với số chiều d tùy ý. Thuật toán cực tiểu hóa tổng bình phương khoảng cách từ mỗi điểm đến tâm cụm chứa nó qua hai bước lặp xen kẽ: gán điểm về tâm gần nhất và cập nhật tâm thành trung bình của cụm.

Algorithm 1: Thuật toán K -means

Input: Tập điểm $X = \{x_1, \dots, x_n\} \subset \mathbb{R}^d$; số cụm K .

Output: Phân hoạch $\{C_1, \dots, C_K\}$ và tâm $\{\mu_1, \dots, \mu_K\}$.

Khởi tạo K tâm $\mu_1, \dots, \mu_K$ là K điểm ngẫu nhiên trong không gian;

repeat

Bước gán: với mỗi x_i , đặt C_k là cụm có tâm gần nhất,
 $k = \arg \min_j \|x_i - \mu_j\|$;

Bước cập nhật: đặt $\mu_k \leftarrow \frac{1}{|C_k|} \sum_{x \in C_k} x$ với mỗi k ;

until phân hoạch không thay đổi;

Đặt hàm mục tiêu

$$J(\{C_k\}, \{\mu_k\}) = \sum_{k=1}^K \sum_{x \in C_k} \|x - \mu_k\|^2.$$

Thuật toán K -means có thể được hiểu là một dạng phép giảm toạ độ trên hàm mục tiêu J : bước gán cực tiểu J với $\{\mu_k\}$ cố định, bước cập nhật cực tiểu J với $\{C_k\}$ cố định. Do đó J không tăng qua mỗi vòng lặp, bị chặn dưới bởi 0 và chỉ nhận hữu hạn giá trị vì số phân hoạch của X thành K cụm là hữu hạn, nên thuật toán dừng sau hữu hạn bước. Điểm dừng phụ thuộc vào tâm khởi tạo và không nhất thiết là cực tiểu toàn cục của J , nên trong thực hành thuật toán được chạy nhiều lần với khởi tạo ngẫu nhiên độc lập và lấy nghiệm có J nhỏ nhất.

2.3.2 Tọa độ hóa các đỉnh bằng phổ của toán tử Laplace

Cho ma trận trọng số W đối xứng không âm trên V , ma trận bậc $D = \text{diag}(W\mathbf{1})$ và Laplacian chuẩn hóa $\mathcal{L} = I - D^{-1/2}WD^{-1/2}$. Theo Định lý 2.8, $\mathcal{L}$ đối xứng nửa xác định dương với phổ $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n \leq 2$ và hệ vector riêng đơn vị $u_1, \dots, u_n$ trực giao đôi một.

Định nghĩa 2.19 (Tọa độ phổ của đỉnh [16]). Đặt $U = [u_1, u_2, \dots, u_K] \in \mathbb{R}^{n \times K}$ là ma trận có cột là K vector riêng đầu của $\mathcal{L}$. Tọa độ phổ K chiều của đỉnh là ánh xạ $\psi : V \rightarrow \mathbb{R}^K$ gán cho mỗi đỉnh u hàng thứ u của U :

$$\psi(u) = (u_1(u), u_2(u), \dots, u_K(u)).$$

Trực giác cho phép tọa độ hóa này được Chung [11] trình bày qua trường hợp $K = 2$. Vector riêng u_2 ứng với giá trị riêng nhỏ thứ hai của $\mathcal{L}$ chia tập đỉnh thành hai nhóm theo dấu của tọa độ: đỉnh có $u_2(u) > 0$ thuộc một cộng đồng, đỉnh có $u_2(u) < 0$ thuộc cộng đồng còn lại. Quan sát then chốt là các đỉnh trong cùng một cộng đồng có xu hướng nhận giá trị tương tự nhau trên u_2 , vì u_2 tối thiểu hóa tổng bình phương sai phân qua các cạnh: hai đỉnh nối với nhau bằng một cạnh thường có giá trị u_2 gần nhau. Cộng đồng được hiểu là tập đỉnh nối nhau dày đặc, do đó các đỉnh bên trong một cộng đồng bị ràng buộc nhận giá trị u_2 gần nhau, còn hai cộng đồng khác nhau ngăn cách bởi ít cạnh hơn nên có thể nhận giá trị u_2 lệch dấu.

Trường hợp K cộng đồng được Shi và Malik [4] tổng quát hóa trực tiếp: thay vì một tọa độ duy nhất, mỗi đỉnh được mô tả bằng K tọa độ ứng với K vector riêng đầu. Hai đỉnh cùng cộng đồng có K tọa độ tương tự nhau, do đó $\psi(u)$ và $\psi(v)$ gần nhau theo khoảng cách Euclidean. Hai đỉnh khác cộng đồng được phân biệt bởi ít nhất một trong K vector riêng, nên $\psi(u)$ và $\psi(v)$ cách xa nhau. Bài toán tìm cộng đồng trong G do đó trở thành bài toán phân cụm $\{\psi(u)\}_{u \in V}$ trong không gian Euclidean $\mathbb{R}^K$, áp dụng được Thuật toán 1.

2.3.3 Thuật toán phân cụm phổ chuẩn hóa

Gộp hai bước trên ta được thuật toán phân cụm phổ chuẩn hóa, áp dụng cho ma trận trọng số đối xứng không âm bất kỳ.

Algorithm 2: Phân cụm phổ chuẩn hóa cho K cụm

Input: Ma trận trọng số W đối xứng không âm trên n đỉnh; số cụm K .

Output: Phân hoạch $\mathcal{C} = \{C_1, \dots, C_K\}$ của V .

$D \leftarrow \text{diag}(W\mathbf{1})$;

$\mathcal{L} \leftarrow I - D^{-1/2}WD^{-1/2}$;

Tính $u_1, \dots, u_K$: K vector riêng nhỏ nhất của $\mathcal{L}$;

Đặt $U \leftarrow [u_1, \dots, u_K] \in \mathbb{R}^{n \times K}$;

Chuẩn hóa từng hàng của U về độ dài đơn vị, thu được $\tilde{U}$;

Đặt $\psi(u) \leftarrow \tilde{U}_{u,:}$ với mỗi đỉnh u ;

Chạy Thuật toán 1 trên tập $\{\psi(u)\}_{u \in V}$ với K cụm;

return phân hoạch tương ứng của V ;

Độ phức tạp tính toán gồm hai phần. Bước phân tích phổ tính K vector riêng đầu của $\mathcal{L}$ tốn $O(Knm)$ với phương pháp Lanczos thưa khi W thưa, hoặc $O(n^3)$ với phân tích đầy đủ. Bước k -means tốn $O(tKn)$ với t là số vòng lặp, thường nhỏ trong thực hành. Tổng độ phức tạp do đó bị

chi phối bởi bước phân tích phổ.

Trong khóa luận, Thuật toán 2 được áp dụng với ba lựa chọn W khác nhau: $W = A$ cho phân cụm phổ cổ điển trên đồ thị gốc, $W = W^{(M)}$ cho phân cụm trên đồ thị Higher Order, và $W = W_\lambda = A + \lambda W^{(M)}$ cho phương pháp đề xuất ở Chương 3. Cả ba lựa chọn đều cho ma trận đối xứng không âm, do đó áp dụng được trực tiếp.

2.3.4 Đánh giá và tính đúng đắn

Mục này trình bày tính đúng đắn của Thuật toán 2 theo nghĩa: nghiệm thu được là một xấp xỉ định lượng của conductance tối ưu ϕ^* . Khung chứng minh được Chung trình bày trong sách [11], đi từ trường hợp $K = 2$ qua phép sweep trên vector Fiedler, sau đó tổng quát hóa lên K cụm.

Trường hợp $K = 2$. Thuật toán 2 với $K = 2$ thực chất tương đương với phép sweep trên vector Fiedler u_2 : sắp xếp các đỉnh theo giá trị của u_2 và xét tất cả các nhát cắt prefix, chọn nhát cắt có conductance nhỏ nhất. Gọi S^{sweep} là nhát cắt thu được.

Định lý 2.20 (Cận sweep [11]). *Nhát cắt S^{sweep} thỏa*

$$\phi(S^{\text{sweep}}) \leq \sqrt{2\lambda_2}.$$

Kết hợp Định lý 2.20 với cận dưới của bất đẳng thức Cheeger, $\lambda_2/2 \leq \phi^*$ (Định lý 2.8), ta thu được

$$\phi^* \leq \phi(S^{\text{sweep}}) \leq \sqrt{2\lambda_2} \leq 2\sqrt{\phi^*}.$$

Bất đẳng thức kép này là kết quả mấu chốt: nghiệm S^{sweep} của thuật toán phổ luôn nằm trong khoảng hằng số nhân với $\sqrt{\phi^*}$ so với nghiệm tối ưu. Khi ϕ^* nhỏ, tức đồ thị có cộng đồng tách rõ, $\phi(S^{\text{sweep}})$ cũng nhỏ và nghiệm phổ gần tối ưu.

Trường hợp K cụm. Khi $K > 2$, định nghĩa hằng số Cheeger bậc cao $\rho_K(G) = \min_{\mathcal{C}} \max_k \phi(C_k)$, lấy tối thiểu trên các phân hoạch $\mathcal{C}$ thành K cụm. Lee, Oveis Gharan và Trevisan tổng quát hóa bất đẳng thức Cheeger thành

$$\frac{\lambda_K}{2} \leq \rho_K(G) \leq O(K^2)\sqrt{\lambda_K},$$

trong đó cận trên đạt được một cách xây dựng thông qua Thuật toán 2: phân hoạch thu được từ K vector riêng đầu của $\mathcal{L}$ kết hợp với k -means trên tọa độ phổ có $\max_k \phi(C_k)$ không vượt quá $O(K^2)\sqrt{\lambda_K}$. Đây là dạng tổng quát của Định lý 2.20 cho K cụm và đảm bảo Thuật toán 2 là một thuật toán xấp xỉ tốt cho bài toán cực tiểu hóa conductance trên K cụm.

Áp dụng cho đồ thị Higher Order. Mệnh đề 2.16 đảm bảo $G_M = (V, W^{(M)})$ là đồ thị có trọng số vô hướng hợp lệ, do đó toàn bộ khung lý luận trên áp dụng nguyên vẹn cho G_M với conductance motif ϕ_M thay cho ϕ . Hệ quả là Thuật toán 2 với đầu vào $W = W^{(M)}$ cho phân hoạch có ϕ_M gần tối ưu, là điểm tựa cho phương pháp đề xuất ở Chương 3.

Chương 3

ĐỒ THỊ HỖN HỢP G_λ VÀ THUẬT TOÁN ĐỀ XUẤT

3.1 Đồ thị hỗn hợp G_λ

3.1.1 Ý tưởng

Nhận xét 2.18 đã chỉ ra hai hạn chế của đồ thị Higher Order G_M thuần khi dùng $W^{(M)}$ làm đầu vào duy nhất cho phân cụm phổ. Thứ nhất, G_M có thể không liên thông: mọi đỉnh không thuộc bất kỳ instance nào của M đều cô lập trong G_M dù trong G gốc có thể có nhiều cạnh kề. Thứ hai, G_M mất thông tin cạnh gốc: cạnh không thuộc instance nào của M bị xóa hoàn toàn, kể cả khi có thể mang tín hiệu cộng đồng.


Hai hạn chế này đều xuất phát từ việc loại bỏ hoàn toàn A khỏi đầu vào của thuật toán. Một cách khắc phục tự nhiên là không loại bỏ A , mà cộng nó với $W^{(M)}$ qua một tham số nội suy $\lambda \geq 0$. Khi $\lambda = 0$, ma trận đầu vào trùng với A , ta thu được phân cụm phổ cổ điển. Khi $\lambda \rightarrow \infty$ (sau chuẩn hóa), ma trận đầu vào tỷ lệ với $W^{(M)}$, ta thu được phân cụm trên G_M thuần. Mọi giá trị $\lambda > 0$ hữu hạn cho một đồ thị có trọng số giữ lại cả thông tin cạnh gốc lẫn thông tin cấu trúc bậc cao.

3.1.2 Định nghĩa

Định nghĩa 3.1 (Ma trận hỗn hợp và đồ thị hỗn hợp). Cho đồ thị $G = (V, E)$ với ma trận kề A , motif $M = K_3$ và ma trận motif $W^{(M)}$ định nghĩa ở Mục 2.2.3. Với tham số $\lambda \geq 0$, ma trận hỗn hợp được định nghĩa

$$W_\lambda = A + \lambda W^{(M)}.$$

Đồ thị hỗn hợp $G_\lambda = (V, W_\lambda)$ là đồ thị có trọng số trên cùng tập đỉnh V , với ma trận trọng số W_λ .



Hình 3.1: Xây dựng đồ thị hỗn hợp G_λ từ G và G_M với $\lambda = 1$, $M = K_3$.

3.2 Tính chất phổ và hệ quả của thuật toán

3.2.1 G_λ là đồ thị có trọng số hợp lệ

Mệnh đề 3.2. Với mọi $\lambda \geq 0$, ma trận W_λ đối xứng và không âm. Do đó $G_\lambda = (V, W_\lambda)$ là đồ thị có trọng số vô hướng hợp lệ.

Chứng minh. A và $W^{(M)}$ đều đối xứng (Mệnh đề 2.16 cho $W^{(M)}$, định nghĩa cho A) và có các phần tử không âm. Vì $\lambda \geq 0$, tổng có trọng số $A + \lambda W^{(M)}$ giữ tính đối xứng và không âm. $\square$

Mệnh đề 3.2 là điểm tựa cho toàn bộ phần còn lại của chương: vì W_λ thuộc lớp ma trận trọng số đối xứng không âm, mọi định lý phổ phát biểu trong Chương 2 cho lớp này áp dụng nguyên dạng cho G_λ .

3.2.2 Conductance trên G_λ

Tương tự conductance trên G và conductance motif trên G_M , ta định nghĩa conductance trên G_λ bằng cách thay A bởi W_λ trong Định nghĩa 2.4 và Định nghĩa 2.5.

Định nghĩa 3.3 (Conductance trên G_λ). Với $S \subset V$, đặt

$$\text{cut}_\lambda(S, \bar{S}) = \sum_{u \in S, v \in \bar{S}} (W_\lambda)_{uv}, \quad \text{vol}_\lambda(S) = \sum_{u \in S} (W_\lambda \mathbf{1})_u.$$

Conductance trên G_λ là

$$\phi_\lambda(S) = \frac{\text{cut}_\lambda(S, \bar{S})}{\min(\text{vol}_\lambda(S), \text{vol}_\lambda(\bar{S}))},$$

và $\phi_\lambda^* = \min_{\emptyset \neq S \subsetneq V} \phi_\lambda(S)$.

Một quan sát đơn giản nhưng then chốt: conductance trên G_λ là tổ hợp tuyến tính của conductance trên G và conductance motif trên G_M .

Mệnh đề 3.4 (Phân tích cộng tính của cut_λ). Với mọi $S \subset V$,

$$\text{cut}_\lambda(S, \bar{S}) = \text{cut}(S, \bar{S}) + \lambda \text{cut}_M(S, \bar{S}), \quad \text{vol}_\lambda(S) = \text{vol}(S) + \lambda \text{vol}_M(S).$$

Chứng minh. Hệ quả trực tiếp của $W_\lambda = A + \lambda W^{(M)}$ và tính tuyến tính của tổng theo các phần tử ma trận. $\square$

3.2.3 Bất đẳng thức Cheeger trên G_λ

Định lý 3.5 (Cheeger trên G_λ). Đặt $D_\lambda = \text{diag}(W_\lambda \mathbf{1})$ và $\mathcal{L}_\lambda = I - D_\lambda^{-1/2} W_\lambda D_\lambda^{-1/2}$ là Laplacian chuẩn hóa của G_λ . Khi đó $\mathcal{L}_\lambda$ đối xứng nửa xác định dương với phổ

$$0 = \lambda_1(\mathcal{L}_\lambda) \leq \lambda_2(\mathcal{L}_\lambda) \leq \dots \leq \lambda_n(\mathcal{L}_\lambda) \leq 2,$$

và conductance tối thiểu ϕ_λ^* thỏa

$$\frac{\lambda_2(\mathcal{L}_\lambda)}{2} \leq \phi_\lambda^* \leq \sqrt{2\lambda_2(\mathcal{L}_\lambda)}.$$

Chứng minh. Theo Mệnh đề 3.2, W_λ là ma trận đối xứng và không âm, do đó $G_\lambda = (V, W_\lambda)$ thuộc đúng lớp đồ thị mà Định lý 2.8 đã được phát biểu. Việc cần làm là chỉ ra mọi đại lượng và mọi lập luận trong chứng minh nguyên thủy đều chuyển nguyên dạng sang G_λ .

Các đại lượng phổ trên G_λ được đặt theo đúng công thức như trên G , chỉ thay ma trận trọng số A bởi W_λ . Ma trận bậc $D_\lambda = \text{diag}(W_\lambda \mathbf{1})$ có phần tử đường chéo $(D_\lambda)_{uu} = d_u + \lambda d_u^{(M)}$ dương trên mọi đỉnh có $d_u \geq 1$ (Mệnh đề 3.7), nên $D_\lambda^{-1/2}$ định nghĩa tốt và Laplacian chuẩn hoá

$$\mathcal{L}_\lambda = I - D_\lambda^{-1/2} W_\lambda D_\lambda^{-1/2}$$

là ma trận đối xứng nửa xác định dương với phổ nằm trong $[0, 2]$. Tương tự, conductance ϕ_λ trên G_λ (Định nghĩa 3.3) mang cấu trúc đại số đồng nhất với conductance ϕ trên G , chỉ thay cut bởi cut_λ và vol bởi vol_λ .

Chứng minh của Định lý 2.8 không dùng giả thiết nào ngoài tính đối xứng và tính không âm của ma trận trọng số, vốn đã được kế thừa cho W_λ . Cụ thể, cận dưới $\lambda_2/2 \leq \phi^*$ trên G được rút ra bằng cách áp dụng bất đẳng thức biến phân Courant–Fischer (Định lý 2.7) cho vector chỉ thị có trọng của một nhất cắt bất kỳ; cùng lập luận này áp dụng cho $\mathcal{L}_\lambda$ vì vector chỉ thị có trọng vẫn định nghĩa tốt với D_λ dương trên các đỉnh liên thông và biến phân Courant–Fischer thì đúng cho mọi ma trận đối xứng. Cận trên $\phi^* \leq \sqrt{2\lambda_2}$ trên G rút ra bằng phép cắt sweep trên vector riêng thứ hai; trên G_λ , ánh xạ $D_\lambda^{-1/2} v_2(\mathcal{L}_\lambda)$ vẫn là một hàm thực trên V nên sweep được định nghĩa tốt và sinh một họ hữu hạn nhất cắt S_t để so sánh.

Do đó hai cận của Định lý 2.8 chuyển nguyên dạng sang G_λ :

$$\frac{\lambda_2(\mathcal{L}_\lambda)}{2} \leq \phi_\lambda^* \leq \sqrt{2\lambda_2(\mathcal{L}_\lambda)}. \quad \square$$

3.2.4 Tính đúng đắn của phân cụm phổ trên G_λ

Định lý 3.6 (Bảo đảm xấp xỉ conductance). *Áp dụng Thuật toán 2 với đầu vào $W = W_\lambda$ và $K = 2$, gọi S_λ^{sweep} là nhát cắt thu được. Khi đó*

$$\phi_\lambda^* \leq \phi_\lambda(S_\lambda^{\text{sweep}}) \leq \sqrt{2\lambda_2(\mathcal{L}_\lambda)} \leq 2\sqrt{\phi_\lambda^*}.$$

Tổng quát hóa cho K cụm: phân hoạch $\{C_k\}$ thu được từ Thuật toán 2 thỏa

$$\max_k \phi_\lambda(C_k) \leq O(K^2)\sqrt{\lambda_K(\mathcal{L}_\lambda)},$$

theo bất đẳng thức Cheeger bậc cao.

Chứng minh. Trường hợp $K = 2$. Thuật toán 2 chạy trên đầu vào $W = W_\lambda$ tính phổ của $\mathcal{L}_\lambda$, lấy vector riêng $v_2(\mathcal{L}_\lambda)$ ứng với $\lambda_2(\mathcal{L}_\lambda)$ và xét các nhát cắt sweep trên $D_\lambda^{-1/2}v_2(\mathcal{L}_\lambda)$. Định lý 2.20 áp dụng cho G_λ (hợp lệ nhờ Mệnh đề 3.2) cho cận

$$\phi_\lambda(S_\lambda^{\text{sweep}}) \leq \sqrt{2\lambda_2(\mathcal{L}_\lambda)}.$$

Theo định nghĩa của conductance tối thiểu, $\phi_\lambda^* \leq \phi_\lambda(S_\lambda^{\text{sweep}})$. Mặt khác, cận dưới Cheeger $\lambda_2(\mathcal{L}_\lambda)/2 \leq \phi_\lambda^*$ (Định lý 3.5) viết lại thành $\lambda_2(\mathcal{L}_\lambda) \leq 2\phi_\lambda^*$, từ đó

$$\sqrt{2\lambda_2(\mathcal{L}_\lambda)} \leq \sqrt{4\phi_\lambda^*} = 2\sqrt{\phi_\lambda^*}.$$

Ghép ba bất đẳng thức:

$$\phi_\lambda^* \leq \phi_\lambda(S_\lambda^{\text{sweep}}) \leq \sqrt{2\lambda_2(\mathcal{L}_\lambda)} \leq 2\sqrt{\phi_\lambda^*}.$$

Trường hợp K cụm. Bất đẳng thức Cheeger bậc cao của Lee, Oveis Gharan và Trevisan (trình bày trong Mục 2.3.4 cho đồ thị có trọng số tổng quát) cho phép, với phân hoạch $\{C_k\}$ thu được từ phân cụm phổ trên K vector riêng đầu của $\mathcal{L}_\lambda$:

$$\max_k \phi_\lambda(C_k) \leq O(K^2)\sqrt{\lambda_K(\mathcal{L}_\lambda)}.$$

Việc áp dụng bất đẳng thức này cho $\mathcal{L}_\lambda$ hợp lệ vì $\mathcal{L}_\lambda$ là Laplacian chuẩn hoá của đồ thị có trọng số đối xứng không âm (Mệnh đề 3.2) và lập luận chứng minh trong tài liệu gốc chỉ dùng các tính chất phổ của Laplacian không phụ thuộc dạng riêng của ma trận trọng số. $\square$

Định lý 3.6 nói rằng phân cụm phổ trên G_λ tìm phân hoạch có conductance gần tối ưu theo metric ϕ_λ tương ứng. Đây là sự kế thừa trực tiếp của các bảo đảm trên đồ thị có trọng số tổng quát: việc đưa thêm thành phần $\lambda W^{(M)}$ vào ma trận đầu vào không làm mất đi bất kỳ bảo đảm nào đã có cho phân cụm phổ cổ điển.

3.2.5 Cải thiện so với đồ thị Higher Order

So với phân cụm phổ trên G_M thuần, phân cụm phổ trên G_λ với $\lambda > 0$ có hai cải thiện trực tiếp, hệ quả của việc cộng thêm A vào ma trận đầu vào.

Mệnh đề 3.7 (Khắc phục hạn chế của G_M). *Với mọi $\lambda > 0$:*

- 1) *Bảo toàn tính liên thông. Nếu G liên thông thì G_λ cũng liên thông.*
- 2) *Bảo toàn thông tin cạnh gốc. Mọi cạnh $(u, v) \in E$ đều có $(W_\lambda)_{uv} \geq A_{uv} \geq 1$, nên không bị xóa trong G_λ kể cả khi không thuộc instance nào của M .*

Chứng minh. Phần (1). Vì $W^{(M)} \geq 0$ và $\lambda \geq 0$, ta có $(W_\lambda)_{uv} = A_{uv} + \lambda W_{uv}^{(M)} \geq A_{uv}$ với mọi u, v . Do đó mọi cạnh của G đều là cạnh của G_λ (với trọng số dương ít nhất bằng trong G). Nếu G liên thông thì giữa hai đỉnh bất kỳ tồn tại đường đi trong G và đường đi đó cũng là đường đi trong G_λ , nên G_λ liên thông. Trái lại, trong G_M thuần một đỉnh không thuộc tam giác nào sẽ có $d_u^{(M)} = 0$ và trở thành cô lập, làm G_M có thể mất liên thông kể cả khi G liên thông.

Phần (2). Trực tiếp từ $W_\lambda = A + \lambda W^{(M)}$:

$$(W_\lambda)_{uv} = A_{uv} + \lambda W_{uv}^{(M)} \geq A_{uv},$$

vì $\lambda W_{uv}^{(M)} \geq 0$. Khi $(u, v) \in E$, $A_{uv} \geq 1$, nên $(W_\lambda)_{uv} \geq 1$. Cạnh (u, v) do đó được bảo toàn trong G_λ với trọng số ít nhất bằng trọng số gốc, không bị xóa kể cả khi (u, v) không thuộc instance nào của M (trường hợp $W_{uv}^{(M)} = 0$). $\square$

Hai khẳng định trong Mệnh đề 3.7 đối ứng với hai hạn chế của G_M phát biểu trong Nhận xét 2.18 và có thể quan sát trực tiếp trên Hình 3.1: các đỉnh 6, 7 vốn cô lập trong G_M trở lại liên thông trong G_λ và các cạnh 5–6, 6–7 vốn bị xóa trong G_M được bảo toàn trong G_λ với trọng số 1.

3.3 Phân tích tỉ lệ phân cụm sai trên mô hình SupSBM

Phép xây dựng $W_\lambda = A + \lambda W^{(M)}$ ở Mục 3.1 đứng độc lập với cách đồ thị được sinh ra. Để đánh giá thuật toán một cách định lượng, ta cần một

lớp mô hình sinh đồ thị sao cho mỗi đại lượng phổ liên quan có thể tính trong kỳ vọng và sai số quanh kỳ vọng có thể chặn. Mô hình thoả mãn cả hai điều kiện này là Superimposed Stochastic Block Model do Paul, Milenkovic và Chen [17] đề xuất, sinh đồng thời cấu trúc cạnh và cấu trúc tam giác trên cùng cấu trúc cộng đồng. Trên mô hình này, ta phân tích tỉ lệ phân cụm sai của Thuật toán 2 với đầu vào W_λ , ký hiệu là R_λ , theo công thức Davis–Kahan kèm hệ quả chọn λ tối ưu và đối chiếu với hai cực $\lambda = 0$ (phân cụm phổ trên A thuần) và $\lambda \rightarrow \infty$ (phân cụm phổ trên G_M thuần).

3.3.1 Mô hình Superimposed SBM

Mục tiêu của mô hình. Superimposed SBM [17] lấy nền tảng từ mô hình SBM (định nghĩa hình thức xem Phụ lục B). SBM đơn thuần sinh mỗi cạnh độc lập với xác suất dựa trên cộng đồng đã phân sẵn của hai đỉnh đầu mút, do đó số tam giác trên SBM hoàn toàn là hệ quả thống kê của mật độ cạnh. Superimposed SBM mở rộng mô hình này bằng cách coi tam giác là một cấu trúc có giá trị riêng, được sinh trực tiếp từ một bộ tham số đầu vào độc lập với bộ tham số sinh cạnh.

Tham số đầu vào. Mô hình nhận sáu tham số: số đỉnh n , số cộng đồng K , phép gán cộng đồng $\bar{e} : \{1, \dots, n\} \rightarrow \{1, \dots, K\}$ và bốn hằng số tín hiệu cộng đồng a_e, b_e, a_t, b_t không phụ thuộc n , đặc trưng cho mật độ cạnh và mật độ tam giác trong và ngoài cộng đồng. Dưới giả thiết cộng đồng cân bằng kích thước n/K , bốn hằng số có diễn giải qua kỳ vọng tại mỗi đỉnh: a_e/K và $(K-1)b_e/K$ lần lượt xấp xỉ kỳ vọng số cạnh nội cộng đồng và liên cộng đồng tại mỗi đỉnh trong G_E ; tương tự, $a_t/(2K^2)$ và $b_t/2$ xấp xỉ kỳ vọng số tam giác nội cộng đồng và liên cộng đồng đi qua mỗi đỉnh trong G_T . Yêu cầu $a_e > b_e$ và $a_t > b_t$ thể hiện cộng đồng là vùng dày cạnh và dày tam giác hơn so với phần còn lại.

Định nghĩa mô hình. Đồ thị quan sát G_s được sinh qua hai tầng độc lập trên cùng tập đỉnh và cùng phép gán cộng đồng $\bar{e}$.

Tầng cạnh. Đồ thị cạnh G_E sinh theo cơ chế SBM. Với mỗi cặp đỉnh phân biệt u, v , chỉ thị cạnh E_{uv} là biến Bernoulli độc lập với tham số

$$\pi_{uv}^e = \begin{cases} a_e/n & \text{nếu } \bar{e}_u = \bar{e}_v, \\ b_e/n & \text{nếu } \bar{e}_u \neq \bar{e}_v. \end{cases}$$

Cạnh uv tồn tại trong G_E khi và chỉ khi $E_{uv} = 1$.

Tầng tam giác. Đồ thị tam giác G_T sinh độc lập với G_E theo cơ chế siêu cạnh ba đỉnh. Với mỗi bộ ba đỉnh phân biệt u, v, w , chỉ thị tam giác

T_{uvw} là biến Bernoulli độc lập với tham số


$$\pi_{uvw}^t = \begin{cases} a_t/n^2 & \text{nếu } \bar{e}_u = \bar{e}_v = \bar{e}_w, \\ b_t/n^2 & \text{nếu ngược lại.} \end{cases}$$

Mỗi $T_{uvw} = 1$ tương ứng với một tam giác trên ba đỉnh u, v, w trong G_T . Khi đó $A_T[u, v] = A_T[v, w] = A_T[u, w] = 1$.

Chồng hai tầng. Đồ thị quan sát thu được bằng phép hợp $G_s = G_E \cup G_T$, hiểu trên mức ma trận kề là phép OR theo từng phần tử:

$$A_s[u, v] = A_E[u, v] \vee A_T[u, v] \quad \forall u \neq v,$$

trong đó A_E là ma trận kề của G_E và A_T là ma trận kề của G_T sau khi gộp các cạnh trùng. Hình 3.2 minh họa phép chồng này trên một đồ thị nhỏ.



Hình 3.2: Minh họa phép chồng hai tầng của mô hình SupSBM trên đồ thị $n = 7$ đỉnh. (a) đồ thị tam giác G_T trước khi gộp cạnh trùng (multi-edge); (b) G_T sau khi gộp thành đồ thị nhị phân; (c) đồ thị cạnh G_E ; (d) đồ thị quan sát $G_s = G_E \cup G_T$.

Trên đồ thị quan sát G_s , thuật toán phân cụm phổ [4] tính hai ma trận: ma trận kề A_s chỉ thị các cạnh quan sát được và ma trận tam giác A_T đếm số tam giác đi qua mỗi cặp đỉnh trong G_s , theo Định nghĩa 2.15. Cả hai ma trận đều ngẫu nhiên do G_s ngẫu nhiên.

Paul, Milenkovic và Chen [17] đã phân tích tỉ lệ phân cụm sai của thuật toán Higher Order Spectral Clustering [1], tương ứng với phân cụm phổ trên A_T thuần, trên mô hình SupSBM và thu được một cận trên phụ thuộc bốn tham số a_e, b_e, a_t, b_t . Khóa luận sử dụng cùng kỹ thuật để phân tích thuật toán dùng đầu vào $W_\lambda = A_s + \lambda A_T$, qua đó thu được một cận trên phụ thuộc thêm tham số λ . So sánh hai cận trên cùng mô hình cho phép trả lời các câu hỏi cụ thể: với cùng cấu hình tham số a_e, b_e, a_t, b_t , giá trị λ nào tối ưu và tại λ tối ưu thì cận của khóa luận có chặt hơn cận của Higher Order Spectral Clustering hay không.

3.3.2 Tỉ lệ phân cụm sai và cận tổng quát

Định nghĩa 3.8 (Tỉ lệ phân cụm sai). Cho nhãn cộng đồng thật $\bar{e} = (\bar{e}_1, \dots, \bar{e}_n)$ theo mô hình SupSBM và nhãn cộng đồng ước lượng $\hat{e} =$

$(\hat{e}_1, \dots, \hat{e}_n)$ do một thuật toán phân cụm xuất ra, tỉ lệ phân cụm sai được định nghĩa

$$R(\hat{e}) = \inf_{\Pi \in S_K} \frac{1}{n} \sum_{i=1}^n \mathbf{1}\{\bar{e}_i \neq \Pi(\hat{e}_i)\},$$

trong đó S_K là tập tất cả hoán vị của $\{1, \dots, K\}$.

Phép lấy infimum trên hoán vị xử lý tính bất biến nhãn của bài toán phát hiện cộng đồng: chỉ có cấu trúc cụm có ý nghĩa, không phải tên gọi cụm cụ thể. Trong các mục sau, ký hiệu $R_\lambda := R(\hat{e}_\lambda)$ với $\hat{e}_\lambda$ là nhãn do Thuật toán 2 xuất ra khi dùng đầu vào W_λ .

Việc cận tỉ lệ phân cụm sai của phân cụm phổ trên SBM là kết quả chuẩn trong tài liệu thống kê. Khoá luận sử dụng trực tiếp dạng do Lei và Rinaldo chứng minh.

Định lý 3.9 (Cận tỉ lệ phân cụm sai [18]). *Cho $\widehat{M}$ là ma trận đối xứng ngẫu nhiên trên n đỉnh, có ma trận kỳ vọng $\mathbb{E}[\widehat{M}]$ thoả $\text{rank}(\mathbb{E}[\widehat{M}]) \leq K$. Khi đó tỉ lệ phân cụm sai của Thuật toán 2 chạy trên đầu vào $\widehat{M}$ thoả*

$$R(\hat{e}) \lesssim \frac{\|\widehat{M} - \mathbb{E}[\widehat{M}]\|_2^2}{\lambda_{\min}^+(\mathbb{E}[\widehat{M}])^2}, \quad (3.1)$$

trong đó $\|M\|_2 = \max_i |\lambda_i(M)|$ là chuẩn phổ và $\lambda_{\min}^+(\mathbb{E}[\widehat{M}])$ là giá trị riêng dương nhỏ nhất của ma trận kỳ vọng.

Điều kiện $\text{rank}(\mathbb{E}[\widehat{M}]) \leq K$ ở Định lý 3.9 không phải giả thiết áp đặt từ ngoài, mà là hệ quả của cấu trúc cộng đồng. Vì $\widehat{M}$ là ma trận quan sát từ một mô hình có K cộng đồng, hai đỉnh u, u' thuộc cùng một cộng đồng có kỳ vọng các phần tử $\mathbb{E}[\widehat{M}][u, w]$ và $\mathbb{E}[\widehat{M}][u', w]$ trùng nhau với mọi đỉnh w , do xác suất tạo cạnh và tạo tam giác đối với chúng là như nhau. Hai hàng u và u' của $\mathbb{E}[\widehat{M}]$ do đó giống hệt, mỗi cộng đồng góp đúng một hàng phân biệt và $\text{rank}(\mathbb{E}[\widehat{M}]) \leq K$.

Chứng minh nguyên thủy của Định lý 3.9 kết hợp cận Davis–Kahan cho vector riêng và phân tích K-means xấp xỉ trên hàng của ma trận vector riêng, chi tiết xem [18, Định lý 3.1]. Paul, Milenkovic và Chen [17] áp dụng định lý này vào mô hình SupSBM. Khoá luận làm điều tương tự cho ma trận hỗn hợp W_λ .

Áp dụng (3.1) cho $\widehat{M} = W_\lambda$:

$$R_\lambda \lesssim \frac{\|W_\lambda - \mathbb{E}[W_\lambda]\|_2^2}{\lambda_{\min}^+(\mathbb{E}[W_\lambda])^2}. \quad (3.2)$$

Định lý 3.10 (Tỉ lệ phân cụm sai của phân cụm phổ trên G_λ). *Giả sử mô hình SupSBM cân bằng với cộng đồng cỡ n/K và bốn tham số a_e, b_e, a_t, b_t thoả giả thiết thừa của [17]. Với xác suất $1 - o(1)$, tỉ lệ phân cụm sai của Thuật toán 2 chạy trên đầu vào $W_\lambda = A_s + \lambda A_T$ thoả*

$$R_\lambda \lesssim \frac{(\sqrt{a_e} + \lambda\sqrt{a_t})^2}{\left[\frac{a_e - b_e}{K} + (1 + \lambda)\frac{a_t - b_t}{K^2}\right]^2}. \quad (3.3)$$

Để chứng minh định lý này, ta biến đổi mẫu số và tử số của vế phải (3.2) dựa trên định nghĩa $W_\lambda = A_s + \lambda A_T$. Mẫu số biến đổi qua tính tuyến tính của kỳ vọng:

$$\begin{aligned} \mathbb{E}[W_\lambda] &= \mathbb{E}[A_s + \lambda A_T] \\ &= \mathbb{E}[A_s] + \lambda \mathbb{E}[A_T]. \end{aligned}$$

Tử số biến đổi qua bất đẳng thức tam giác đối với chuẩn phổ:

$$\begin{aligned} \|W_\lambda - \mathbb{E}[W_\lambda]\|_2 &= \|(A_s + \lambda A_T) - (\mathbb{E}[A_s] + \lambda \mathbb{E}[A_T])\|_2 \\ &= \|(A_s - \mathbb{E}[A_s]) + \lambda(A_T - \mathbb{E}[A_T])\|_2 \\ &\leq \|A_s - \mathbb{E}[A_s]\|_2 + \lambda \|A_T - \mathbb{E}[A_T]\|_2. \end{aligned}$$

Hai đại lượng của ma trận tam giác A_T đã được Paul, Milenkovic và Chen [17] tính trong paper, khoá luận chỉ trích lại. Hai đại lượng của ma trận cạnh A_s tính ở đây: do A_s là phép hợp nhị phân của cạnh từ G_E và cạnh sinh từ tam giác G_T . Phần thuần từ A_E là SBM cổ điển, dùng kết quả của Rohe, Chatterjee, Yu [19] và Lei, Rinaldo [18]. Phần kỳ vọng cạnh được tạo ra trong G_T được tính trực tiếp bằng cách lấy xác suất ít nhất một tam giác trong G_T đi qua hai đỉnh đang xét. Tổng hợp các kết quả cho ra cận (3.3) ở định lý.

3.3.3 Tính kỳ vọng ma trận cạnh trên SupSBM

Theo định nghĩa của Paul, Milenkovic và Chen [17], ma trận kề bậc hai của mỗi tầng được đặt

$$A_{E^2}[u, v] = E_{uv}, \quad A_{T^2}[u, v] = \sum_{w \neq u, v} T_{uvw}.$$

Ở đây A_{E^2} là ma trận kề nhị phân của G_E . Ma trận $A_{T^2}[u, v]$ đếm số tam giác trong G_T đi qua cặp đỉnh (u, v) , có thể lớn hơn 1 khi có nhiều tam giác chia chung cặp (u, v) . Ta cũng đặt ma trận kề nhị phân của cạnh quan

sát sinh ra từ tam giác:

$$A_{ET}[u, v] = \begin{cases} 1 & \text{nếu tồn tại } w \neq u, v \text{ sao cho } T_{uvw} = 1, \\ 0 & \text{nếu trái lại,} \end{cases}$$

tức $A_{ET}[u, v] = \mathbf{1}\{A_{T^2}[u, v] \geq 1\}$. Khi đó $A_{ET} \leq A_{T^2}$ theo từng phần tử và phần trùng lặp ghi nhận bởi $D = A_{T^2} - A_{ET} \geq 0$.

Ma trận cạnh quan sát phân rã thành hai tầng $A_s = A_{E^2} + A_{ET}$: tầng cạnh trực tiếp từ G_E và tầng cạnh sinh từ tam giác G_T (lấy theo dạng nhị phân, không trùng). Trong mục này khoá luận tính chặn chuẩn phổ và phổ của A_s qua A_{E^2} và A_{ET} riêng rẽ. Đối với ma trận tam giác A_T , khoá luận dùng lại kết quả đã được Paul, Milenkovic và Chen [17] chứng minh, được trích lại ở Mục 3.3.5.

Bổ đề 3.11 (Phổ của $CBC^\top$). Cho $C \in \{0, 1\}^{n \times K}$ với $C_{uk} = \mathbf{1}\{\bar{e}_u = k\}$ và cộng đồng cân bằng kích thước n/K và $B \in \mathbb{R}^{K \times K}$ thoả mãn

$$B = \alpha I_K + \beta \mathbf{1}_K \mathbf{1}_K^\top.$$

Khi đó B có giá trị riêng $\alpha + K\beta$ và α (bội $K - 1$). Hệ quả, ma trận $CBC^\top$ có hai giá trị riêng khác không $\frac{n}{K}(\alpha + K\beta)$ và $\frac{n}{K}\alpha$ (bội $K - 1$).

Chứng minh. Phổ của B rút ra trực tiếp từ tác động lên $\mathbf{1}_K$ và lên phần bù trực giao.

Với $v = \mathbf{1}_K$,

$$B\mathbf{1}_K = \alpha\mathbf{1}_K + \beta\mathbf{1}_K(\mathbf{1}_K^\top \mathbf{1}_K) = (\alpha + K\beta)\mathbf{1}_K.$$

Với mọi $v \in \mathbb{R}^K$ thoả $\mathbf{1}_K^\top v = 0$,

$$Bv = \alpha v + \beta\mathbf{1}_K(\mathbf{1}_K^\top v) = \alpha v.$$

Không gian $\{v : \mathbf{1}_K^\top v = 0\}$ có chiều $K - 1$ nên α là giá trị riêng bội $K - 1$.

Để chuyển sang $CBC^\top$, dùng tính cân bằng $C^\top C = (n/K)I_K$: với mọi vector riêng v của B có giá trị riêng μ ,

$$(CBC^\top)(Cv) = CB(C^\top C)v = \frac{n}{K}\mu(Cv).$$

Mặt khác $CBC^\top$ có hạng tối đa K vì chứa thừa số $C \in \mathbb{R}^{n \times K}$, nên các giá trị riêng khác không của $CBC^\top$ chính là $(n/K)\mu$ với μ chạy trên phổ của B .

Thay $\mu = \alpha + K\beta$ và $\mu = \alpha$ cho hai giá trị riêng ở phát biểu. $\square$

Bổ đề 3.12 (Spectral gap của $\mathbb{E}[A_{E^2}]$). Trên mô hình SupSBM cân bằng với $a_e > b_e$,

$$\lambda_{\min}^+(\mathbb{E}[A_{E^2}]) = \frac{a_e - b_e}{K}.$$

Chứng minh. Theo định nghĩa mô hình, $A_{E^2}[u, v] = E_{uv}$ là biến Bernoulli với tham số

$$\pi_{uv}^e = \begin{cases} a_e/n & \text{nếu } \bar{e}_u = \bar{e}_v, \\ b_e/n & \text{nếu } \bar{e}_u \neq \bar{e}_v. \end{cases}$$

Đặt $B_{E^2} \in \mathbb{R}^{K \times K}$ với

$$B_{E^2}[k, \ell] = \begin{cases} a_e/n & \text{nếu } k = \ell, \\ b_e/n & \text{nếu } k \neq \ell. \end{cases}$$

Khi đó

$$\begin{aligned} \mathbb{E}[A_{E^2}] &= CB_{E^2}C^\top - \frac{a_e}{n}I_n \\ &\approx CB_{E^2}C^\top, \end{aligned}$$

trong đó dòng cuối bỏ đường chéo bậc $O(1/n)$, không ảnh hưởng đến hai giá trị riêng chính. Viết B_{E^2} về dạng hai mức

$$B_{E^2} = \alpha I_K + \beta \mathbf{1}_K \mathbf{1}_K^\top, \quad \alpha = \frac{a_e - b_e}{n}, \quad \beta = \frac{b_e}{n},$$

rồi áp dụng Bổ đề 3.11 với cặp (α, β) trên, hai giá trị riêng khác không của $\mathbb{E}[A_{E^2}]$ là

$$\begin{aligned} \frac{n}{K}(\alpha + K\beta) &= \frac{a_e - b_e}{K} + b_e = \frac{a_e + (K-1)b_e}{K} \quad (\text{bội } 1), \\ \frac{n}{K}\alpha &= \frac{a_e - b_e}{K} \quad (\text{bội } K-1). \end{aligned}$$

Giả thiết $a_e > b_e$ cho cả hai giá trị riêng dương và giá trị nhỏ hơn cho

$$\lambda_{\min}^+(\mathbb{E}[A_{E^2}]) = \frac{a_e - b_e}{K}.$$

□

Bổ đề 3.13 (Bound chuẩn phổ phần dao động của A_{E^2}). Trên mô hình SupSBM cân bằng, với xác suất $1 - o(1)$,

$$\|A_{E^2} - \mathbb{E}[A_{E^2}]\|_2 \lesssim \sqrt{a_e}.$$

A_{E^2} là ma trận kề của mô hình SBM cổ điển với tham số $(a_e/n, b_e/n)$. Cận chuẩn phổ phần dao động đã được Lei và Rinaldo [18] chứng minh cho SBM; khoá luận trích dùng trực tiếp.

Bổ đề 3.14 (Spectral gap của $\mathbb{E}[A_{ET}]$). Trên mô hình SupSBM cân bằng với $a_t > b_t$,

$$\lambda_{\min}^+(\mathbb{E}[A_{ET}]) = \frac{a_t - b_t}{K^2} + o(1).$$

Chứng minh. Phân rã $A_{ET} = A_{T^2} - D$ với $D := A_{T^2} - A_{ET}$. Vì $A_{T^2}[u, v] = \sum_{w \neq u, v} T_{uvw}$ là tổng các chỉ thị Bernoulli độc lập, tính tuyến tính của kỳ vọng cho ngay

$$\mathbb{E}[A_{T^2}[u, v]] = \sum_{w \neq u, v} \pi_{uvw}^t =: \mu_{uv}.$$

Giá trị π_{uvw}^t phụ thuộc cộng đồng của bộ ba $\{u, v, w\}$ nên ta tính μ_{uv} qua tách tổng thành hai trường hợp theo cộng đồng của cặp $\{u, v\}$.

Trường hợp 1: $\bar{e}_u = \bar{e}_v = k$. Tách tổng theo việc w có cùng cộng đồng với $\{u, v\}$ hay không:

$$\begin{aligned} \mu_{uv} &= \sum_{w \in C_k \setminus \{u, v\}} \pi_{uvw}^t + \sum_{w \notin C_k} \pi_{uvw}^t \\ &= \left(\frac{n}{K} - 2\right) \cdot \frac{a_t}{n^2} + \left(n - \frac{n}{K}\right) \cdot \frac{b_t}{n^2} \\ &= \frac{1}{n} \cdot \frac{a_t + (K-1)b_t}{K} + O(1/n^2). \end{aligned} \quad (3.4)$$

Tổng thứ nhất ứng với bộ ba cùng cộng đồng nên $\pi^t = a_t/n^2$ và có $n/K - 2$ đỉnh w trong $C_k \setminus \{u, v\}$. Tổng thứ hai ứng với bộ ba có w khác cụm nên $\pi^t = b_t/n^2$ và có $n - n/K$ đỉnh w ngoài C_k .

Trường hợp 2: $\bar{e}_u \neq \bar{e}_v$. Đặt $k_1 = \bar{e}_u$, $k_2 = \bar{e}_v$. Tách tổng theo việc w thuộc $C_{k_1} \cup C_{k_2}$ hay không:

$$\begin{aligned} \mu_{uv} &= \sum_{w \in (C_{k_1} \cup C_{k_2}) \setminus \{u, v\}} \pi_{uvw}^t + \sum_{w \notin C_{k_1} \cup C_{k_2}} \pi_{uvw}^t \\ &= \left(\frac{2n}{K} - 2\right) \cdot \frac{b_t}{n^2} + \left(n - \frac{2n}{K}\right) \cdot \frac{b_t}{n^2} \\ &= (n-2) \cdot \frac{b_t}{n^2} = \frac{b_t}{n} + O(1/n^2). \end{aligned} \quad (3.5)$$

Ở cả hai nhóm, bộ ba $\{u, v, w\}$ đều không cùng cộng đồng (vì đã có $\bar{e}_u \neq \bar{e}_v$) nên $\pi_{uvw}^t = b_t/n^2$ đồng nhất.

Gộp hai trường hợp (3.4), (3.5),

$$\mu_{uv} = \begin{cases} \frac{1}{n} \cdot \frac{a_t + (K-1)b_t}{K} + O(1/n^2) & \text{nếu } \bar{e}_u = \bar{e}_v, \\ \frac{b_t}{n} + O(1/n^2) & \text{nếu } \bar{e}_u \neq \bar{e}_v. \end{cases}$$

Tiếp theo tính $\mathbb{E}[D[u, v]]$, ứng với trùng lặp tam giác. Phần tử $D[u, v]$ chỉ khác 0 khi có từ hai tam giác G_T trở lên qua (u, v) . Vì $D = A_{T^2} - A_{ET}$,

$$\mathbb{E}[D[u, v]] = \mathbb{E}[A_{T^2}[u, v]] - \mathbb{E}[A_{ET}[u, v]] = \mu_{uv} - \left[1 - \prod_{w \neq u, v} (1 - \pi_{uvw}^t) \right].$$

Khai triển tích $\prod_w (1 - \pi_{uvw}^t)$ ta được:

$$1 - \prod_{w \neq u, v} (1 - \pi_{uvw}^t) = \sum_w \pi_{uvw}^t - \sum_{w < w'} \pi_{uvw}^t \pi_{uvw'}^t + \sum_{w < w' < w''} \pi_{uvw}^t \pi_{uvw'}^t \pi_{uvw''}^t - \dots$$

Đại lượng đầu là μ_{uv} . Tổng các bậc ba trở lên bị chặn bởi

$$\sum_{w < w' < w''} \pi_{uvw}^t \pi_{uvw'}^t \pi_{uvw''}^t \leq \frac{1}{6} \left(\sum_w \pi_{uvw}^t \right)^3 = \frac{\mu_{uv}^3}{6} = O(\mu_{uv}^3).$$

Thay vào,

$$\mathbb{E}[D[u, v]] = \sum_{w < w'} \pi_{uvw}^t \pi_{uvw'}^t + O(\mu_{uv}^3).$$

Khai triển bình phương của tổng,

$$\left(\sum_w \pi_{uvw}^t \right)^2 = \sum_w (\pi_{uvw}^t)^2 + 2 \sum_{w < w'} \pi_{uvw}^t \pi_{uvw'}^t,$$

do đó

$$\sum_{w < w'} \pi_{uvw}^t \pi_{uvw'}^t = \frac{1}{2} \left[\left(\sum_w \pi_{uvw}^t \right)^2 - \sum_w (\pi_{uvw}^t)^2 \right] = \frac{1}{2} \mu_{uv}^2 - \frac{1}{2} \sum_w (\pi_{uvw}^t)^2.$$

kết hợp

$$\sum_w (\pi_{uvw}^t)^2 = O(n \cdot 1/n^4) = O(1/n^3) = o(\mu_{uv}^2),$$

ta được

$$\mathbb{E}[D[u, v]] = \frac{1 + o(1)}{2} \mu_{uv}^2 = O(1/n^2),$$

trong đó dùng $\mu_{uv} = O(1/n)$.

Gộp lại, $\mathbb{E}[A_{ET}[u, v]] = \mathbb{E}[A_{T^2}[u, v]] - \mathbb{E}[D[u, v]] = \mu_{uv} + O(1/n^2)$, tức

$$\mathbb{E}[A_{ET}[u, v]] = \begin{cases} \frac{1}{n} \cdot \frac{a_t + (K-1)b_t}{K} + O(1/n^2) & \text{nếu } \bar{e}_u = \bar{e}_v, \\ \frac{b_t}{n} + O(1/n^2) & \text{nếu } \bar{e}_u \neq \bar{e}_v. \end{cases}$$

Dùng lại ma trận chỉ thị C và đặt $B_{ET} \in \mathbb{R}^{K \times K}$ với

$$B_{ET}[k, \ell] = \begin{cases} \frac{a_t + (K-1)b_t}{Kn} & \text{nếu } k = \ell, \\ \frac{b_t}{n} & \text{nếu } k \neq \ell. \end{cases}$$

Khi đó $\mathbb{E}[A_{ET}] \approx CB_{ET}C^\top$ ở bậc dẫn đầu, sai số chuẩn phổ $O(1/n)$ không ảnh hưởng $\lambda_{\min}^+$. Viết B_{ET} về dạng hai mức

$$B_{ET} = \alpha_T I_K + \beta_T \mathbf{1}_K \mathbf{1}_K^\top, \quad \alpha_T = \frac{a_t - b_t}{Kn}, \quad \beta_T = \frac{b_t}{n},$$

rồi áp dụng Bổ đề 3.11 cho hai giá trị riêng khác không là $\frac{a_t + (K^2-1)b_t}{K^2}$ (bội 1) và $\frac{a_t - b_t}{K^2}$ (bội $K-1$). Giả thiết $a_t > b_t$ cho cả hai dương, và giá trị nhỏ hơn cho gap. $\square$

Bổ đề 3.15 (Bound chuẩn phổ phần dao động của A_{ET}). *Trên mô hình SupSBM cân bằng, ở giả thiết thừa $a_t \gtrsim \log n$, với xác suất $1 - o(1)$,*

$$\|A_{ET} - \mathbb{E}[A_{ET}]\|_2 \lesssim \sqrt{a_t}.$$

Chứng minh. A_{ET} là ma trận kề của các cạnh quan sát được trong G_T . Cùng một chỉ thị T_{uvw} ảnh hưởng đến cả ba phần tử $A_{ET}[u, v]$, $A_{ET}[u, w]$, $A_{ET}[v, w]$, nên các phần tử của A_{ET} không độc lập theo cặp (u, v) . Để tận dụng đánh giá của Paul, Milenkovic và Chen [17] cho ma trận đếm A_{T^2} , ta phân rã

$$A_{ET} = A_{T^2} - D, \quad D = A_{T^2} - A_{ET}.$$

Bất đẳng thức tam giác cho

$$\|A_{ET} - \mathbb{E}[A_{ET}]\|_2 \leq \|A_{T^2} - \mathbb{E}[A_{T^2}]\|_2 + \|D - \mathbb{E}[D]\|_2.$$

Đại lượng đầu có bound

$$\|A_{T^2} - \mathbb{E}[A_{T^2}]\|_2 \lesssim \sqrt{a_t}$$

với xác suất $1 - o(1)$, trích trực tiếp từ kết quả của Paul, Milenkovic và Chen [17] cho A_{T^2} .

Còn lại $\|D - \mathbb{E}[D]\|_2$. Dùng $\|M\|_2 \leq \|M\|_F$ cho ma trận tùy ý,

$$\|D - \mathbb{E}[D]\|_2 \leq \|D - \mathbb{E}[D]\|_F.$$

Lấy kỳ vọng bình phương và đổi tổng,

$$\mathbb{E}[\|D - \mathbb{E}[D]\|_F^2] = \sum_{u,v} \text{Var}(D[u, v]).$$

Vậy chỉ cần chặn phương sai từng phần tử.

Đặt $X_{uv} := A_{T^2}[u, v] = \sum_w T_{uvw}$. Theo định nghĩa,

$$D[u, v] = \begin{cases} X_{uv} - 1 & \text{nếu } X_{uv} \geq 2, \\ 0 & \text{nếu trái lại.} \end{cases}$$

Khi $X_{uv} \geq 2$, $(X_{uv} - 1)^2 \leq X_{uv}(X_{uv} - 1)$, do đó $D[u, v]^2 \leq X_{uv}(X_{uv} - 1)$ ở mọi giá trị của X_{uv} . Vì các T_{uvw} độc lập theo w ,

$$\mathbb{E}[X_{uv}(X_{uv} - 1)] = \sum_{w \neq w'} \pi_{uvw}^t \pi_{uvw'}^t \leq \left(\sum_w \pi_{uvw}^t \right)^2 = \mu_{uv}^2.$$

Kết hợp,

$$\text{Var}(D[u, v]) \leq \mathbb{E}[D[u, v]^2] \leq \mu_{uv}^2 = O(1/n^2).$$

Tổng theo n^2 cặp (u, v) ,

$$\mathbb{E}[\|D - \mathbb{E}[D]\|_F^2] = \sum_{u,v} \text{Var}(D[u, v]) \leq n^2 \cdot O(1/n^2) = O(1).$$

Đặt $Y := \|D - \mathbb{E}[D]\|_F^2$. Áp dụng bất đẳng thức Markov cho biến ngẫu nhiên không âm Y : với mỗi $M > 0$,

$$\Pr(Y > M) \leq \frac{\mathbb{E}[Y]}{M} = \frac{O(1)}{M}.$$

Chọn $M = \log n$, xác suất ở vế phải tiến đến 0. Do đó với xác suất $1 - o(1)$,

$$\|D - \mathbb{E}[D]\|_F = O(\sqrt{\log n}) = o(\sqrt{a_t}),$$

trong đó dùng giả thiết $a_t \gtrsim \log n$. Dùng tiếp $\|M\|_2 \leq \|M\|_F$,

$$\|D - \mathbb{E}[D]\|_2 = o(\sqrt{a_t}).$$

Kết hợp với $\|A_{T^2} - \mathbb{E}[A_{T^2}]\|_2 \lesssim \sqrt{a_t}$,

$$\|A_{ET} - \mathbb{E}[A_{ET}]\|_2 \leq \|A_{T^2} - \mathbb{E}[A_{T^2}]\|_2 + \|D - \mathbb{E}[D]\|_2 \lesssim \sqrt{a_t}$$

với xác suất $1 - o(1)$. □

3.3.4 Gộp kỳ vọng hai tầng cạnh

Ký hiệu $A_E = A_{E^2} + A_{ET}$ là ma trận cạnh tổng hợp của hai tầng. Tính tuyến tính của kỳ vọng cho

$$\mathbb{E}[A_E] = \mathbb{E}[A_{E^2}] + \mathbb{E}[A_{ET}].$$

Áp dụng Bổ đề 3.12 và Bổ đề 3.14,

$$\mathbb{E}[A_E] \approx CB_{E^2}C^\top + CB_{ET}C^\top = C(B_{E^2} + B_{ET})C^\top.$$

Cả $\mathbb{E}[A_{E^2}]$ và $\mathbb{E}[A_{ET}]$ đều có hệ vector riêng dạng Cv với $v = \mathbf{1}_K$ (giá trị riêng lớn) và v trực giao với $\mathbf{1}_K$ (giá trị riêng nhỏ). Vì cùng hệ vector riêng, giá trị riêng cộng tính trực tiếp:

$$\begin{aligned} \lambda_{\min}^+(\mathbb{E}[A_E]) &= \lambda_{\min}^+(\mathbb{E}[A_{E^2}]) + \lambda_{\min}^+(\mathbb{E}[A_{ET}]) \\ &= \frac{a_e - b_e}{K} + \frac{a_t - b_t}{K^2}. \end{aligned}$$

3.3.5 Kỳ vọng ma trận tam giác A_T

Paul, Milenkovic và Chen [17] đã phân tích phổ của ma trận tam giác A_T trên mô hình SupSBM cân bằng. Khóa luận trích lại kết quả để áp dụng vào cận tỉ lệ phân cụm sai.


Mỗi tam giác trong đồ thị quan sát $G_s = G_E \cup G_T$ được hoàn thành bởi tổ hợp ba cạnh, trong đó mỗi cạnh có hai nguồn khả dĩ: cạnh thuần E từ tầng cạnh, hoặc cạnh sinh từ một tam giác trong tầng tam giác T . Bốn tổ hợp tạo ra bốn loại tam giác E^3, T^3, T^2E, TE^2 minh họa ở Hình 3.3. Paul, Milenkovic và Chen [17] tính lần lượt kỳ vọng số tam giác qua $\{i, j\}$ trong bốn loại trên dưới giả thiết thừa, cộng bốn đóng góp cho cấu trúc block hai mức của $\mathbb{E}[A_T]$ trên cộng đồng. Từ đó suy ra hai kết quả sau.

Bổ đề 3.16 (Spectral gap của $\mathbb{E}[A_T]$ [17]). *Trên mô hình SupSBM cân bằng với $a_t > b_t$,*

$$\lambda_{\min}^+(\mathbb{E}[A_T]) = \frac{a_t - b_t}{K^2} + o(1).$$

Bổ đề 3.17 (Bound chuẩn phổ phân dao động của A_T [17]). *Trên mô hình SupSBM cân bằng, với xác suất $1 - o(1)$,*

$$\|A_T - \mathbb{E}[A_T]\|_2 \lesssim \sqrt{a_t}.$$



Hình 3.3: Bốn loại tam giác sinh ra trên đỉnh $\{i, j, k\}$ qua phép chồng tăng cạnh G_E và tăng tam giác G_T : (a) E^3 ba cạnh từ G_E ; (b) T^3 ba cạnh sinh từ tam giác trong G_T với các đỉnh phụ k_1, k_2, k_3 ; (c) T^2E hai cạnh sinh từ tam giác G_T và một cạnh từ G_E ; (d) TE^2 một cạnh sinh từ tam giác G_T và hai cạnh từ G_E .

3.3.6 Chứng minh Định lý 3.10

Ta có đủ thành phần để hoàn tất chứng minh. Theo định nghĩa $W_\lambda = A_E + \lambda A_T$, áp dụng cận tỉ lệ phân cụm sai (3.2) cho $\widehat{M} = W_\lambda$:

$$R_\lambda \lesssim \frac{\|W_\lambda - \mathbb{E}[W_\lambda]\|_2^2}{\lambda_{\min}^+(\mathbb{E}[W_\lambda])^2}.$$

Phân tích lần lượt mẫu số và tử số.

Mẫu số. Vì $\mathbb{E}[A_E]$ và $\mathbb{E}[A_T]$ chia sẻ cùng hệ vector riêng (cấu trúc cộng đồng), giá trị riêng cộng tính:

$$\begin{aligned} \lambda_{\min}^+(\mathbb{E}[W_\lambda]) &= \lambda_{\min}^+(\mathbb{E}[A_E]) + \lambda \cdot \lambda_{\min}^+(\mathbb{E}[A_T]) \\ &= \left[\frac{a_e - b_e}{K} + \frac{a_t - b_t}{K^2} \right] + \lambda \cdot \frac{a_t - b_t}{K^2} + o(1) \\ &= \frac{a_e - b_e}{K} + (1 + \lambda) \cdot \frac{a_t - b_t}{K^2} + o(1), \end{aligned}$$

trong đó dòng thứ hai dùng Mục 3.3.4, Bổ đề 3.16 và Bổ đề 3.17.

Tử số. Bất đẳng thức tam giác cho

$$\|W_\lambda - \mathbb{E}[W_\lambda]\|_2 \leq \|A_E - \mathbb{E}[A_E]\|_2 + \lambda \|A_T - \mathbb{E}[A_T]\|_2.$$

Đại lượng $\|A_E - \mathbb{E}[A_E]\|_2$ là chuẩn phổ phần dao động của ma trận cạnh thuần A_{E^2} cộng đóng góp bậc thấp từ cạnh sinh trong G_T là A_{ET} ; kết quả tập trung phổ của Lei và Rinaldo [18] cho phần thuần và bậc của A_{ET} cho tổng $\|A_E - \mathbb{E}[A_E]\|_2 \lesssim \sqrt{a_e}$. Đại lượng $\|A_T - \mathbb{E}[A_T]\|_2 \lesssim \sqrt{a_t}$ trích từ Bổ đề 3.17. Do đó với xác suất $1 - o(1)$,

$$\|W_\lambda - \mathbb{E}[W_\lambda]\|_2 \lesssim \sqrt{a_e} + \lambda \sqrt{a_t}.$$

Gộp tử số và mẫu số. Thay hai cận trên vào (3.2) cho cận cuối

$$R_\lambda \lesssim \frac{(\sqrt{a_e} + \lambda\sqrt{a_t})^2}{\left[\frac{a_e - b_e}{K} + (1 + \lambda)\frac{a_t - b_t}{K^2}\right]^2},$$

trùng với phát biểu của Định lý 3.10. $\square$

3.3.7 Tối ưu λ^* và so sánh với HOSC

Đặt $\alpha = a_e - b_e$ (tín hiệu cộng đồng từ tầng cạnh) và $\beta = (a_t - b_t)/K$ (tín hiệu cộng đồng từ tầng tam giác, đã scale theo K). Cận tỉ lệ phân cụm sai ở Định lý 3.10 viết gọn thành

$$R_\lambda \lesssim \frac{a_e + \lambda^2 a_t}{\left[\frac{\alpha}{K} + (1 + \lambda)\frac{\beta}{K}\right]^2} \cdot \frac{(\sqrt{a_e} + \lambda\sqrt{a_t})^2}{a_e + \lambda^2 a_t}$$

sau khi nhận xét rằng $(\sqrt{a_e} + \lambda\sqrt{a_t})^2 \leq 2(a_e + \lambda^2 a_t)$. Để chọn λ tối ưu, ta cực tiểu hoá vế phải dưới dạng đơn giản hơn

$$f(\lambda) = \frac{a_e + \lambda^2 a_t}{[\alpha + (1 + \lambda)\beta]^2}.$$

Mệnh đề 3.18 (Tham số nội suy tối ưu). *Hàm $f(\lambda)$ trên $\lambda \geq 0$ đạt cực tiểu tại*

$$\lambda^* = \frac{a_e \beta}{a_t(\alpha + \beta)} = \frac{a_e(a_t - b_t)/K}{a_t[(a_e - b_e) + (a_t - b_t)/K]}.$$

Chứng minh. Đặt $N(\lambda) = a_e + \lambda^2 a_t$ và $D(\lambda) = \alpha + (1 + \lambda)\beta$. Khi đó $N'(\lambda) = 2\lambda a_t$ và $D'(\lambda) = \beta$. Điểm dừng $f'(\lambda) = 0$ tương đương $N'(\lambda)D(\lambda) = 2N(\lambda)D'(\lambda)$:

$$2\lambda a_t[(\alpha + \beta) + \lambda\beta] = 2(a_e + \lambda^2 a_t)\beta.$$

Khai triển vế trái: $2\lambda a_t(\alpha + \beta) + 2\lambda^2 a_t \beta$. Vế phải: $2a_e \beta + 2\lambda^2 a_t \beta$. Triệt tiêu $2\lambda^2 a_t \beta$ ở hai vế cho $\lambda a_t(\alpha + \beta) = a_e \beta$, suy ra λ^* ở phát biểu. Kiểm tra đạo hàm hai vế hoặc thay biên $\lambda = 0, \infty$ xác nhận đây là cực tiểu. $\square$

Diễn giải. Tỉ số $\lambda^* \sim a_e/a_t$ scale theo "tỉ lệ nhiều cạnh trên nhiều tam giác". Khi tín hiệu cạnh trội ($\alpha \gg \beta$), $\lambda^* \approx a_e \beta/(a_t \alpha) \sim 1/K$ nhỏ, tức ưu tiên cạnh. Khi tín hiệu tam giác trội ($\alpha \ll \beta$), $\lambda^* \approx a_e/a_t$, tức ưu tiên tam giác. Trong cả hai cực, λ^* luôn hữu hạn.

Thay λ^* vào $f(\lambda)$ và rút gọn cho cận tại điểm tối ưu:

$$R_{\lambda^*} \lesssim \frac{K^2 \cdot a_e \cdot a_t}{a_t(\alpha + \beta)^2 + a_e\beta^2}. \quad (3.6)$$

So sánh với HOSC. Thuật toán Higher Order Spectral Clustering tương ứng giới hạn $\lambda \rightarrow \infty$ (chỉ dùng ma trận tam giác A_T). Ký hiệu cận tương ứng là R_T :

$$R_T \lesssim \lim_{\lambda \rightarrow \infty} f(\lambda) \cdot K^2 = \frac{K^4 a_t}{(a_t - b_t)^2} = \frac{K^2 a_t}{\beta^2}.$$

Tỉ số hai cận:

$$\frac{R_{\lambda^*}}{R_T} \lesssim \frac{a_e\beta^2}{a_t(\alpha + \beta)^2 + a_e\beta^2} = \frac{1}{1 + \rho_T}, \quad \rho_T = \frac{a_t(\alpha + \beta)^2}{a_e\beta^2}. \quad (3.7)$$

Khi ρ_T lớn, R_{λ^*} nhỏ hơn R_T đáng kể; cụ thể, $\rho_T \rightarrow \infty$ kéo theo $R_{\lambda^*}/R_T \rightarrow 0$.

Diễn giải regime. Đặt $\rho_T = (a_t/a_e) \cdot (1 + K(a_e - b_e)/(a_t - b_t))^2$. Khi tín hiệu cạnh trội ($K(a_e - b_e) \gg (a_t - b_t)$, tức $\alpha \gg \beta$), ρ_T tăng theo K^2 và $R_{\lambda^*}/R_T \rightarrow 0$ về tốc độ — cải thiện về *rate* so với HOSC. Khi tín hiệu tam giác trội ($\alpha \ll \beta$), $\rho_T \approx a_t/a_e$, độ cải thiện chỉ là constant phụ thuộc tỉ số a_t/a_e .

Lưu ý về tính chặt của cận. Cận R_T ở trên thu được bằng cách thay $\lambda \rightarrow \infty$ vào (3.3) và là cận trên cho misclustering rate của HOSC theo cùng kỹ thuật Davis–Kahan. Paul, Milenkovic và Chen [17] chứng minh cận tương đương cho HOSC trực tiếp trên A_T , do đó so sánh ở (3.7) hợp lệ ở mức cận trên. Câu hỏi về cận dưới information-theoretic cho R_λ trên SupSBM vẫn là vấn đề mở.

Chương 4

THỰC NGHIỆM VÀ ĐÁNH GIÁ

Chương này trình bày kết quả thực nghiệm Thuật toán 2 với đầu vào $W = W_\lambda = A + \lambda W^{(M)}$ ($M = K_3$) trên hai loại dữ liệu. Loại thứ nhất gồm bốn mô hình sinh ngẫu nhiên có cấu trúc cộng đồng (SBM, Planted Partition, GRPG, LFR). Loại thứ hai gồm mười đồ thị mạng xã hội thật. Định nghĩa hình thức của các mô hình sinh ngẫu nhiên xem Phụ lục B.

4.1 Thiết lập thí nghiệm

Quét tham số. $\lambda \in \{0, 0.5, 1, 2, 5, 10\}$ kèm trường hợp W_M thuần (tương ứng $\lambda \rightarrow \infty$). Trường hợp $\lambda = 0$ trùng với phân cụm phổ cổ điển trên ma trận kề A và được dùng làm chuẩn so sánh.

Số cụm K . Với đồ thị có phân hoạch chuẩn, đặt $K = K_{\text{gt}}$ là số cộng đồng thật. Với đồ thị mạng xã hội không có phân hoạch chuẩn, quét $K \in \{50, 100, 200, 300, 400, 500\}$ cho mỗi đồ thị.

Chỉ số đánh giá. Mọi chỉ số được tính trên đồ thị gốc A , không phải trên W_λ :

- Modularity Q là chỉ số chất lượng chính.
- NMI và Jaccard so với phân hoạch chuẩn (khi có).
- $\overline{CC}$, $\overline{CC}_w$: hệ số phân cụm tổng hợp.
- Số cạnh bị cắt và số motif (tam giác) bị cắt qua biên cụm.

Mục tiêu. Với mỗi bộ test, ghi lại $Q(\lambda)$ cho từng giá trị λ . Đặt

$$\Delta Q = \max_{\lambda > 0} Q(\lambda) - Q(0)$$

là mức tăng tốt nhất do ma trận hỗn hợp đem lại so với phân cụm phổ cổ điển. $\Delta Q > 0$ chứng tỏ W_λ với $\lambda > 0$ phù hợp hơn A ; λ^* đạt cực đại là giá trị tối ưu cho bộ test.

4.2 Đồ thị có cấu trúc cộng đồng

Bảng 4.1 tổng hợp kết quả tốt nhất trên bốn mô hình. Với mỗi mô hình, năm bộ test có ΔQ lớn nhất (lọc $Q(0) \geq 0,1$ để tránh phân hoạch tầm thường) được chọn.

Bảng 4.1: Kết quả tốt nhất trên bốn mô hình có cấu trúc cộng đồng

Mô hình	Bộ test tốt nhất	$Q(0)$	λ^*	$Q(\lambda^*)$	ΔQ
LFR	LFR-100- $\mu=0,35$	0,1124	5,0	0,4785	+0,3661
GRPG	GRPG-2000- $p_{\text{out}}=0,006$	0,1165	1,0	0,2005	+0,0840
Planted	Planted- $k=5$ - $p_{\text{out}}=0,025$	0,1203	0,5	0,2185	+0,0982
SBM	SBM-1500- $p_{\text{out}}=0,008$	0,1673	0,5	0,1975	+0,0302

4.2.1 LFR Benchmark


Bộ dữ liệu Lancichinetti–Fortunato–Radicchi (LFR) được công nhận rộng rãi như benchmark chuẩn cho bài toán phát hiện cộng đồng nhờ phân bố bậc và phân bố kích thước cụm cùng tuân theo lũy thừa, gần với cấu trúc của nhiều mạng thật. Tham số then chốt là mixing parameter $\mu \in (0, 1)$: mỗi đỉnh dành tỉ lệ $1 - \mu$ số cạnh cho cộng đồng của mình và tỉ lệ μ số cạnh cho phần còn lại của đồ thị. Giá trị μ càng lớn, ranh giới cộng đồng càng mờ và bài toán càng khó. Khóa luận quét $n \in \{100, 500, 2000\}$ và $\mu \in \{0,2, 0,35, 0,4, 0,5\}$, các tham số còn lại giữ mặc định của thuật toán sinh.

Modularity và NMI


Bảng 4.2 trình bày năm bộ test LFR có ΔQ lớn nhất. Hình 4.1 và Hình 4.2 lần lượt cho biểu đồ modularity và NMI theo λ .

Bảng 4.2: Năm bộ test LFR có cải thiện modularity lớn nhất

Bộ test	$Q(0)$	$\lambda=0,5$	$\lambda=1$	$\lambda=2$	$\lambda=5$	λ^*
LFR-100- $\mu 0,35$	0,1124	0,0042	0,0838	0,2942	0,4785	5,0
LFR-100- $\mu 0,2$	0,4747	0,4858	0,4761	0,6280	0,6255	2,0
LFR-500- $\mu 0,4$	0,1670	0,2979	0,2951	0,2778	0,2708	0,5
LFR-2000- $\mu 0,5$	0,1112	0,2348	0,2409	0,2382	0,2275	1,0
LFR-500- $\mu 0,35$	0,2181	0,3380	0,2992	0,3270	0,3199	0,5



Hình 4.1: Modularity Q trên năm bộ LFR có ΔQ lớn nhất theo λ .




Hình 4.2: NMI so với phân hoạch chuẩn trên năm bộ LFR theo λ .

Quan sát. Q tăng trên toàn dải μ , biên độ lớn nhất tập trung ở vùng cộng đồng tách yếu. Bộ LFR-100- $\mu 0.35$ minh họa rõ nhất khi Q chuyển từ 0,1124 tại $\lambda = 0$ lên 0,4785 tại $\lambda = 5$, và NMI đồng pha tăng từ 0,2026 lên 0,3124. Giá trị λ^* tối ưu phân tán trong khoảng 0,5 đến 5 tùy bộ test.


Nhận xét. Mức cải thiện chỉ rõ rệt khi modularity ban đầu thấp. Khi μ nhỏ, các cạnh nội cụm đã đủ rõ để phân cụm phổ trên A hoạt động tốt, đóng góp của motif bị bão hòa. Sự đồng pha của Q và NMI là yếu tố

then chốt: phân hoạch thu được không chỉ tối ưu theo chỉ số nội tại mà còn gần phân hoạch chuẩn hơn, loại trừ khả năng modularity tăng do thuật toán bị đẩy về một phân hoạch tốt giả tạo. Phân tán của λ^* cho thấy cần chiến lược chọn λ phụ thuộc đồ thị, không tồn tại quy tắc cố định toàn cục.

Hệ số phân cụm



Hình 4.3: $\overline{CC}_w$ trên năm bộ LFR theo λ .



Hình 4.4: $\overline{CC}$ trên năm bộ LFR theo λ .

Quan sát. Hệ số phân cụm toàn cục của đồ thị gốc $cc_{\text{global}} = 0,0513$ đóng vai trò baseline. Trên bộ LFR-100- $\mu 0,35$, $\overline{CC}_w$ chuyển từ 0,0477 tại $\lambda = 0$ (sát baseline) lên cực đại 0,1412 tại $\lambda = 2$, gấp khoảng ba lần. $\overline{CC}$ biến thiên gần đồng pha với $\overline{CC}_w$, đạt 0,1364 tại $\lambda = 2$. Modularity đạt đỉnh trễ hơn, ở $\lambda = 5$.

Nhận xét. Việc $\overline{CC}_w$ tại đỉnh vượt baseline cc_{global} rõ rệt cho thấy thuật toán thực sự cô lập được các vùng đậm đặc tam giác vào trong cụm, không chỉ phản ánh phân bố tam giác sẵn có của đồ thị. Lệch pha giữa đỉnh $\overline{CC}_w$ và đỉnh modularity phản ánh hai khía cạnh khác nhau: $\overline{CC}_w$ chỉ đo mật độ tam giác nội cụm nên tăng theo trọng số motif một cách trực tiếp, còn modularity cân bằng giữa mật độ cạnh nội cụm và kỳ vọng ngẫu nhiên, do đó phản ứng chậm hơn và chỉ đạt đỉnh khi đóng góp của motif bù trừ được tác động làm loãng cạnh gốc. Khoảng cách giữa $\overline{CC}$ và $\overline{CC}_w$ không đáng kể, dấu hiệu cho thấy phân bố kích thước cụm lũy thừa của LFR không sinh ra nhiều cụm rất nhỏ đủ để làm thiên lệch trung bình không trọng số; do đó hai đại lượng cho cùng kết luận trên dataset này.



4.2.2 Stochastic Block Model

Stochastic Block Model là mô hình tổng quát nhất trong lớp đồ thị có cấu trúc cộng đồng đối xứng. Mỗi đỉnh được gán vào một trong K khối, và xác suất xuất hiện cạnh giữa hai đỉnh chỉ phụ thuộc vào cặp khối mà chúng thuộc về. Tham số then chốt là cặp $(p_{\text{in}}, p_{\text{out}})$ với p_{in} là xác suất cạnh nội cụm và p_{out} là xác suất cạnh liên cụm; tỉ số $p_{\text{out}}/p_{\text{in}}$ càng cao thì bài toán càng khó. Khoá luận quét $n \in \{300, 600, 1500, 3000\}$ với $K = 3$ và p_{out} thuộc $\{0,005, 0,008, 0,02\}$, đi kèm p_{in} điều chỉnh theo n để giữ bậc trung bình hợp lý.

Modularity và NMI

Bảng 4.3: Năm bộ test SBM có cải thiện modularity lớn nhất

Bộ test	$Q(0)$	$\lambda=0,5$	$\lambda=1$	$\lambda=2$	$\lambda=5$	λ^*
SBM-1500- $p_{\text{out}}0,008$	0,1673	0,1975	0,1925	0,1638	0,1330	0,5
SBM-3000- $p_{\text{out}}0,005$	0,1757	0,1951	0,1932	0,1768	0,1448	0,5
SBM-300- $p_{\text{out}}0,02$	0,3033	0,3064	0,3016	0,2929	0,2618	0,5
SBM-600- $p_{\text{out}}0,02$	0,2168	0,2177	0,2109	0,1907	0,1672	0,5
SBM-300- $p_{\text{out}}0,005$	0,5497	0,5505	0,5505	0,5505	0,5505	0,5


Hình 4.5: Modularity Q trên năm bộ SBM có ΔQ lớn nhất theo λ .Hình 4.6: NMI so với phân hoạch chuẩn trên năm bộ SBM theo λ .

Quan sát. Toàn bộ năm bộ test cho $\lambda^* = 0,5$ và biên độ cải thiện ΔQ duy trì trong vùng hẹp từ $+0,0007$ đến $+0,0302$. Khi λ vượt $0,5$, modularity giảm đều và NMI sụt rất nhanh: trên bộ SBM-1500- $p_{out}0,008$, NMI từ $0,3360$ tại $\lambda = 0,5$ tụt xuống còn $0,0044$ tại W_M .


Nhận xét. Hành vi trên SBM khác hẳn LFR và phản ánh trực tiếp đặc tính sinh dữ liệu. Cơ chế sinh cạnh độc lập theo cặp của SBM khiến mọi tam giác xuất hiện đều là hệ quả thống kê của mật độ cạnh chứ không

phải tín hiệu cấu trúc riêng. Vì thế tăng trọng số motif không cung cấp thông tin mới và còn phản tác dụng khi λ lớn, do thành phần motif làm pha loãng tín hiệu cạnh vốn đã đủ để khôi phục cộng đồng. Sự sụp đổ nhanh của NMI là chỉ dấu rõ nhất rằng motif và phân hoạch chuẩn của SBM không chia sẻ chung một nguồn tín hiệu; bất cứ tối ưu nào theo W_M thuần đều dẫn xa khỏi cộng đồng thật.

Hệ số phân cụm



Hình 4.7: $\overline{CC}_w$ trên năm bộ SBM theo λ .



Hình 4.8: $\overline{CC}$ trên năm bộ SBM theo λ .

Quan sát. $cc_{\text{global}} = 0,0128$ cho đồ thị nền của bộ SBM-1500- $p_{\text{out}}0,008$ rất thấp, phù hợp với tính chất sinh cạnh độc lập theo cặp. Trên bộ này, $\overline{CC}_w$ chuyển từ 0,0200 tại $\lambda = 0$ lên 0,0773 tại W_M , gấp khoảng sáu lần baseline. $\overline{CC}$ cũng tăng đến 0,0791 tại W_M . Cả hai đại lượng tăng đơn điệu theo λ trên cả năm bộ test, ngược chiều biến thiên của Q và NMI.

Nhận xét. Mức tăng tuyệt đối nhỏ ($\overline{CC}_w$ tại đỉnh chỉ 0,0773, thấp xa so với mức quan sát được trên LFR) phù hợp với việc SBM không sinh nhiều tam giác có nghĩa. Tỷ số $\overline{CC}_w/cc_{\text{global}}$ tăng chủ yếu vì baseline thấp, không phải vì thuật toán phát hiện cấu trúc tam giác đậm đặc. Sự đối lập về chiều giữa nhóm $\{\overline{CC}, \overline{CC}_w\}$ và nhóm $\{Q, \text{NMI}\}$ mang ý nghĩa diễn giải quan trọng: dưới trọng số motif lớn, thuật toán gom được các tam giác về cùng cụm nhưng các cụm thu được lại không phản ánh phân hoạch chuẩn. Hệ quả phương pháp luận: $\overline{CC}_w$, dù phản ánh đúng định nghĩa, không thể thay thế modularity hay NMI khi kiểm chứng tính đúng của phân hoạch trên SBM. Tương tự, $\overline{CC}$ và $\overline{CC}_w$ trùng nhau gần như chính xác, cho thấy SBM với $K = 3$ và kích thước cụm bằng nhau không có cụm nhỏ thiên lệch trung bình không trọng số.



4.2.3 Planted Partition

Planted Partition là trường hợp đặc biệt của SBM trong đó mọi cụm có cùng kích thước s và mọi cặp khối dùng chung một cặp $(p_{\text{in}}, p_{\text{out}})$. Mức độ đối xứng cao khiến mô hình này thường được dùng làm baseline kiểm tra hành vi cơ bản của thuật toán. Khoá luận cố định $K = 5$ và quét $s \in \{40, 100, 200, 400\}$ với các cặp $(p_{\text{in}}, p_{\text{out}})$ tương ứng để bao quát các mức độ tách cộng đồng từ yếu đến rõ.

Modularity và NMI

Bảng 4.4: Bốn bộ test Planted có cải thiện modularity lớn nhất

Bộ test	$Q(0)$	$\lambda=0,5$	$\lambda=1$	$\lambda=2$	$\lambda=5$	λ^*
Planted- $s100-p_{\text{in}}0,08-p_{\text{out}}0,025$	0,1203	0,2185	0,2087	0,1937	0,1825	0,5
Planted- $s40-p_{\text{in}}0,15-p_{\text{out}}0,03$	0,2424	0,3164	0,3068	0,2862	0,2955	0,5
Planted- $s400-p_{\text{in}}0,025-p_{\text{out}}0,006$	0,2960	0,2974	0,2930	0,2774	0,2379	0,5
Planted- $s200-p_{\text{in}}0,05-p_{\text{out}}0,005$	0,5156	0,5156	0,5146	0,5107	0,5009	0,5


Hình 4.9: Modularity Q trên bốn bộ Planted Partition theo λ .Hình 4.10: NMI so với phân hoạch chuẩn trên bốn bộ Planted Partition theo λ .

Quan sát. $\lambda^* = 0,5$ trên cả bốn bộ test. Hai bộ có cộng đồng tách yếu cho ΔQ đáng kể (+0,098 và +0,074); hai bộ tách rõ gần như không cải thiện. NMI đạt đỉnh đồng thuận với modularity tại $\lambda = 0,5$ và giảm dần theo cùng nhịp khi λ tăng.


Nhận xét. Pattern lặp lại nguyên vẹn từ SBM — điều dự kiến do Planted là trường hợp đặc biệt của SBM. Hiệu ứng bão hoà theo $Q(0)$ tỏ ra rõ rệt: khi cộng đồng đã tách rõ trong A , modularity ban đầu cao và

phần thông tin còn lại để motif đóng góp gần như bằng không. Việc cộng đồng đối xứng, kích thước bằng nhau và xác suất sinh cạnh đồng nhất giữa các cặp khối làm cho tam giác trở thành đại lượng nhiều thuận tuý theo nghĩa thống kê; do đó vai trò của $W^{(M)}$ chỉ dừng ở mức ổn định hoá phân cụm phổ, không bổ sung được tín hiệu cấu trúc riêng.

Hệ số phân cụm



Hình 4.11: $\overline{CC}_w$ trên bốn bộ Planted Partition theo λ .



Hình 4.12: $\overline{CC}$ trên bốn bộ Planted Partition theo λ .

Quan sát. $cc_{\text{global}} = 0,0379$ cho đồ thị nền của bộ Planted-s100- $p_{\text{in}}0,08$ - $p_{\text{out}}0,025$. $\overline{CC}_w$ tăng từ 0,0604 tại $\lambda = 0$ lên 0,1540 tại W_M (gấp khoảng bốn lần baseline), $\overline{CC}$ đạt 0,1412 tại $\lambda = 10$. Cả hai đại lượng tăng đơn điệu theo λ trên cả bốn bộ test, trong khi Q và NMI đỉnh tại $\lambda = 0,5$ rồi suy giảm.

Nhận xét. Pattern lặp lại nguyên vẹn từ SBM, điều dự kiến vì Planted là trường hợp đặc biệt của SBM. Khoảng cách hẹp giữa $\overline{CC}$ và $\overline{CC}_w$ là hệ quả trực tiếp của cơ chế sinh: tất cả cụm có cùng kích thước nên không có cụm nhỏ kéo trung bình không trọng số lên cao. Sự lặp lại pattern phân kỳ giữa $\{\overline{CC}, \overline{CC}_w\}$ và $\{Q, \text{NMI}\}$ trên hai mô hình SBM và Planted khẳng định một nguyên lý chung: trên đồ thị sinh ngẫu nhiên đối xứng, mật độ tam giác nội cụm và tính đúng của phân hoạch là hai mục tiêu có thể tách biệt; tối ưu một trong hai không tự động kéo theo cải thiện đại lượng còn lại.



4.2.4 Gaussian Random Partition Graph

Gaussian Random Partition Graph nằm giữa Planted Partition và LFR về mức độ đa dạng kích thước cụm. Kích thước mỗi cụm được lấy mẫu từ phân bố Gaussian $\mathcal{N}(s, s/v)$ với s là kích thước trung bình và v là tham số hình dạng kiểm soát phương sai; cạnh sau đó được sinh theo cơ chế Planted Partition trên tập cụm thu được. Khóa luận quét $n \in \{200, 500, 2000\}$ với các cặp $(p_{\text{in}}, p_{\text{out}})$ và s tương ứng để bao quát các mức độ tách cộng đồng từ yếu đến rõ.

Modularity và NMI

Bảng 4.5: Năm bộ test GRPG có cải thiện modularity lớn nhất

Bộ test	$Q(0)$	$\lambda=0,5$	$\lambda=1$	$\lambda=2$	$\lambda=5$	λ^*
GRPG-2000- $p_{\text{out}}0,006$	0,1165	0,2004	0,2005	0,1887	0,1678	1,0
GRPG-500- $p_{\text{out}}0,008$	0,4240	0,4753	0,4728	0,4668	0,4590	0,5
GRPG-500- $p_{\text{out}}0,015$	0,2914	0,3400	0,3307	0,3113	0,3026	0,5
GRPG-2000- $p_{\text{out}}0,001$	0,6209	0,6611	0,6196	0,6600	0,6573	0,5
GRPG-200- $p_{\text{out}}0,03$	0,3593	0,3606	0,3572	0,3523	0,3436	0,5


Hình 4.13: Modularity Q trên năm bộ GRPG theo λ .Hình 4.14: NMI so với phân hoạch chuẩn trên năm bộ GRPG theo λ .

Quan sát. λ^* luôn thuộc $\{0,5,1\}$, nhưng biên độ cải thiện vượt Planted: bộ GRPG-2000- $p_{\text{out}}0,006$ cho $\Delta Q = +0,0840$, cùng cấp độ với các bộ LFR khó nhất. NMI đạt đỉnh tại $\lambda = 0,5$, sớm hơn modularity (đỉnh tại $\lambda = 1$) một bước.


Nhận xét. GRPG cho hành vi trung gian giữa Planted và LFR. Sự đa dạng về kích thước cụm sinh ra từ phân bố Gaussian dường như mở rộng phạm vi λ mà motif còn đóng góp tích cực, đẩy biên độ cải thiện

vượt Planted đủ chưa đủ để λ^* vượt khỏi vùng nhỏ. Sự lệch pha một bước giữa đỉnh NMI và đỉnh modularity là cảnh báo phương pháp luận: ngay trong vùng cải thiện, phân hoạch tối ưu theo modularity đã bắt đầu rời khỏi phân hoạch chuẩn. Việc dựa hoàn toàn vào modularity để chọn λ^* có thể dẫn đến phân hoạch lệch khỏi ground truth dù ΔQ vẫn dương.

Hệ số phân cụm



Hình 4.15: $\overline{CC}_w$ trên năm bộ GRPG theo λ .



Hình 4.16: $\overline{CC}$ trên năm bộ GRPG theo λ .

Quan sát. $cc_{\text{global}} = 0,0104$ cho đồ thị nền của bộ GRPG-2000- $p_{\text{out}}0,006$, ở mức rất thấp tương tự SBM. Trên bộ này, $\overline{CC}_w$ tăng từ 0,0178 tại $\lambda = 0$ lên 0,1953 tại W_M , gấp khoảng mười một lần baseline. $\overline{CC}$ đạt 0,2617 tại W_M , cách $\overline{CC}_w$ một khoảng đáng kể.

Nhận xét. Mức tăng tuyệt đối của $\overline{CC}_w$ vượt trội so với SBM và Planted, phản ánh khả năng thuật toán cô lập các vùng tam giác đậm đặc khi phân bố kích thước cụm đa dạng. Khoảng cách rõ rệt giữa $\overline{CC}$ và $\overline{CC}_w$ tại W_M là đặc trưng của GRPG: phân bố Gaussian sinh ra một số cụm kích thước nhỏ với hệ số phân cụm cao trên đơn vị đỉnh, làm thiên lệch trung bình không trọng số lên cao. Đây là minh họa thực nghiệm rõ nhất cho lý do khoá luận chọn $\overline{CC}_w$ làm chỉ số chính (Định nghĩa 2.13): trên các đồ thị có kích thước cụm đa dạng, $\overline{CC}$ có thể đánh giá quá lạc quan do hiệu ứng cụm nhỏ. Mặc dù vậy, pattern cốt lõi vẫn được giữ — cực đại của $\overline{CC}_w$ không trùng cực đại của modularity, khẳng định tách biệt giữa hai mục tiêu trên lớp đồ thị sinh ngẫu nhiên đối xứng.

Tổng kết kết quả trên đồ thị sinh ngẫu nhiên

Bốn mô hình sinh ngẫu nhiên cho một bức tranh nhất quán. λ^* tối ưu nằm trong vùng nhỏ $\{0,5, 1\}$ trên Planted, SBM và GRPG, chỉ dịch lên đến 5 trên các bộ LFR có cộng đồng tách yếu ($\mu \geq 0,35$). ΔQ luôn dương trên cả 35 bộ test, nhưng biên độ cải thiện phụ thuộc trực tiếp vào độ tách cộng đồng của bộ sinh: trên các bộ test khó, ΔQ vượt +0,3; trên các bộ tách rõ, ΔQ gần như bằng 0.

Cơ chế đứng sau hiện tượng này thống nhất giữa bốn mô hình: tam giác trên các đồ thị sinh ngẫu nhiên là hệ quả thống kê của mật độ cạnh chứ không độc lập với cạnh. Khi mật độ nội cụm p_{in} cao, số tam giác kỳ vọng trong cụm tỉ lệ với p_{in}^3 và đã được phản ánh ngầm trong ma trận kề A . Do đó việc cộng thêm trọng số motif lớn không bổ sung tín hiệu mới mà chỉ pha loãng cấu trúc cạnh, khiến λ^* tối ưu nằm ở vùng nhỏ. Trên hệ số phân cụm, $\overline{CC}_w$ tăng đều với λ và phản ánh đúng mức độ đóng kín tam giác trong cụm, trong khi $\overline{CC}$ có thể bị đẩy lên cao tại $\lambda = W_M$ do các cụm nhỏ với hệ số phân cụm gần 1 — một biểu hiện sớm của hiện tượng phân mảnh cụm sẽ thấy rõ hơn trên đồ thị thật. Phần kế tiếp xét xem các kết luận trên có còn đúng khi tam giác xuất hiện không phải do thống kê cạnh mà do một cơ chế xã hội độc lập.

4.3 Đồ thị mạng xã hội thật

Mười một đồ thị thật được khảo sát với $\lambda \in \{0, 1, 5, 10, W_M\}$ và K quét trong $\{50, 100, 200, 300, 400, 500\}$. Mỗi đồ thị có ý nghĩa đỉnh và cạnh riêng, dẫn đến đặc tính cấu trúc khác nhau. Bảng 4.6 tổng hợp bộ test có ΔQ cao nhất cho mỗi đồ thị, sau đó từng đồ thị được trình bày kèm biểu đồ chi tiết.


Bảng 4.6: Tổng hợp kết quả trên mười đồ thị mạng xã hội thật

Đồ thị	n	m	cc_{global}	K^*	λ^*	ΔQ
musae_DE_edges	9,498	153,138	0,2009	50	W_M	+0,1156
musae_ES_edges	4,648	59,382	0,2225	50	1,0	+0,0902
lastfm_asia_edges	7,624	27,806	0,2194	500	10,0	+0,0815
Email-Enron	33,696	180,811	0,5092	300	5,0	+0,0640
facebook_combined	4,039	88,234	0,6055	500	5,0	+0,0519
CA-GrQc	4,158	13,422	0,5569	500	5,0	+0,0476
CA-AstroPh	17,903	196,972	0,6328	50	5,0	+0,0421
CA-CondMat	21,363	91,286	0,6417	50	5,0	+0,0316
CA-HepTh	8,638	24,806	0,4816	50	5,0	+0,0250
musae_facebook_edges	22,470	170,823	0,3597	500	5,0	+0,0202

musae_DE

Đỉnh là một streamer Twitch người Đức, cạnh nối hai streamer cùng chia sẻ người theo dõi. Cộng đồng có nghĩa là nhóm streamer cùng phân khúc khán giả. Hệ số phân cụm toàn cục $cc_{\text{global}} = 0,2009$ ở mức trung bình.


Modularity.




Hình 4.17: Modularity Q trên musae_DE theo λ và K .

$Q(0)$ rất thấp trên mọi K (chỉ trong khoảng 0,05–0,10). Ma trận hỗn hợp đẩy Q lên gấp hai đến ba lần, mạnh nhất tại $K = 50$ với $\Delta Q = +0,1156$ và $\lambda^* = W_M$. Đây là trường hợp $Q(0)$ thấp điển hình: phân cụm phổ trên A thuần không tìm được phân hoạch tốt, trọng số motif lớn tạo ra cải thiện rõ rệt.

Hệ số phân cụm.



Hình 4.18: $\overline{CC}_w$ trên musae_DE theo λ và K .



Hình 4.19: $\overline{CC}$ trên musae_DE theo λ và K .

Tại $K = 50$, $\overline{CC}_w(0) = 0,1132$ thấp hơn cả cc_{global} , nghĩa là phân


cụm phổ trên A không gom được tam giác có sẵn vào trong cụm. Khi λ chuyển về W_M , $\overline{CC}_w$ đạt 0,3531, gấp ba lần và vượt baseline cc_{global} . $\overline{CC}$ cũng tăng lên 0,4103 tại W_M , bắt từ 0,2630 tại $\lambda = 10$ (tăng 0,15 chỉ qua một bước sang W_M); $\overline{CC}_w$ trong cùng đoạn chỉ tăng từ 0,2810 lên 0,3531, độ tăng nhỏ hơn rõ rệt. Điều này phù hợp với nhận định ở Định nghĩa 2.13: việc bỏ ma trận kề A tạo ra một số cụm rất nhỏ với CC cực bộ cao, đẩy $\overline{CC}$ lên trong khi $\overline{CC}_w$ vẫn phản ánh trung thực kích thước cụm trung bình.

Kết luận. musae_DE đại diện cho lớp đồ thị xã hội với triadic closure mạnh nhưng cộng đồng được mã hoá ẩn trong cấu trúc tam giác, không thể phát hiện chỉ qua cạnh. Trọng số motif lớn (W_M) là cần thiết để bóc tách cộng đồng; cả modularity và $\overline{CC}_w$ cùng tăng mạnh và đồng pha, củng cố tính nhất quán của phân hoạch thu được.

musae_ES

Tương tự musae_DE nhưng cho streamer Twitch người Tây Ban Nha. Đồ thị nhỏ hơn ($n = 4,648$) nhưng giữ đặc tính triadic closure tương tự. Hệ số phân cụm toàn cục $cc_{\text{global}} = 0,2225$.


Modularity.




Hình 4.20: Modularity Q trên musae_ES theo λ và K .

$Q(0)$ thuộc khoảng 0,07–0,13, sát chế độ của musae_DE . Cải thiện lớn nhất tại $K = 50$ với $\Delta Q = +0,0902$, tương ứng tăng khoảng 70%. $\lambda^* = 1$ ở $K = 50$, nhỏ hơn W_M của musae_DE , cho thấy đóng góp tối ưu của motif đã đạt ở mức trọng số trung bình.

Hệ số phân cụm.



Hình 4.21: $\overline{CC}_w$ trên musae_ES theo λ và K .



Hình 4.22: $\overline{CC}$ trên musae_ES theo λ và K .

Tại $K = 50$, $\overline{CC}_w(0) = 0,1793$ vẫn dưới cc_{global} , sau đó tăng lên 0,3968 tại W_M , gấp khoảng hai lần. $\overline{CC}$ bắt từ 0,3504 tại $\lambda = 10$ lên 0,4678 tại W_M (tăng 0,12), nhanh hơn rõ rệt so với $\overline{CC}_w$ (tăng 0,05 trong cùng đoạn). Lặp lại pattern của musae_DE: W_M tạo nhiều cụm nhỏ thiên lệch $\overline{CC}$.


Kết luận. Cùng họ với musae_DE nhưng quy mô nhỏ hơn, musae_ES

tái lập cùng pattern: phân cụm phổ thuần bỏ sót cấu trúc tam giác, trọng số motif khôi phục được tín hiệu cộng đồng. Việc λ^* nhỏ hơn (giá trị 1 thay vì W_M) phản ánh quy mô nhỏ làm tín hiệu cạnh đã có đóng góp tương đối, nên không cần trọng số motif cực đại.

lastfm_asia

Đỉnh là một người dùng LastFM ở châu Á, cạnh là quan hệ bạn bè trong nền tảng. Cộng đồng có xu hướng theo quốc gia hoặc sở thích âm nhạc. Hệ số phân cụm toàn cục $cc_{\text{global}} = 0,2194$, đồ thị thưa hơn musae.



Modularity.



Hình 4.23: Modularity Q trên lastfm_asia theo λ và K .

Đồ thị này phơi bày cả hai chế độ trên cùng một dataset. Tại $K = 50$, $Q(0) = 0,7486$ đã cao và ΔQ chỉ $+0,0059$. Tại $K = 500$, $Q(0)$ tụt còn $0,4155$ và ΔQ vọt lên $+0,0815$ với $\lambda^* = 10$. Mức độ cải thiện do trọng số motif tỉ lệ nghịch với chất lượng phân hoạch ban đầu.

Hệ số phân cụm.

Hình 4.24: $\overline{CC}_w$ trên lastfm_asia theo λ và K .Hình 4.25: $\overline{CC}$ trên lastfm_asia theo λ và K .


Tại $K = 50$, $\overline{CC}_w(0) = 0,2328$ đã gần cc_{global} , tăng lên 0,3146 tại W_M . $\overline{CC}$ tại W_M đạt 0,6044, chênh tới 0,29 so với $\overline{CC}_w$, lớn nhất trong toàn bộ tập dữ liệu thật; con số này bắt từ 0,2681 tại $\lambda = 10$ chỉ qua một bước. Đây là minh họa rõ nhất cho hiện tượng phân mảnh cụm khi $\lambda \rightarrow \infty$ đã trình bày ở Định nghĩa 2.13: W_M sinh nhiều cụm rất nhỏ với hệ số phân cụm cục bộ cao, đẩy $\overline{CC}$ vọt lên trong khi $\overline{CC}_w$ tiếp tục cho con số thận trọng.

Kết luận. lastfm_asia là ví dụ điển hình về đồ thị xã hội thưa với cộng đồng đa quy mô. Tại K nhỏ, các cụm lớn đã định hình tốt qua cạnh; tại K lớn, cần bóc tách thêm các nhóm sở thích nhỏ và motif đóng vai trò quan trọng. Chênh lệch lớn giữa $\overline{CC}$ và $\overline{CC}_w$ khẳng định lựa chọn $\overline{CC}_w$ làm chỉ số chính: nếu dùng $\overline{CC}$, chất lượng phân hoạch trên đồ thị này sẽ bị đánh giá quá lạc quan.

Email-Enron

Đỉnh là một địa chỉ email nội bộ công ty Enron, cạnh nếu có ít nhất một thư trao đổi giữa hai địa chỉ. Cộng đồng có nghĩa là phòng ban hoặc nhóm dự án. Hệ số phân cụm toàn cục $cc_{\text{global}} = 0,5092$ ở mức cao, phản ánh trao đổi email ba bên trong cùng phòng ban.



Modularity.



Hình 4.26: Modularity Q trên Email-Enron theo λ và K .

$Q(0)$ thuộc vùng trung gian (0,39–0,50). Cải thiện đáng kể trên mọi K , ΔQ dao động từ +0,016 tại $K = 100$ đến +0,064 tại $K = 300$, bám sát quy luật $Q(0)$ càng thấp thì ΔQ càng lớn. Tại $K = 300$, $\lambda^* = 5$.

Hệ số phân cụm.

Hình 4.27: $\overline{CC}_w$ trên Email-Enron theo λ và K .Hình 4.28: $\overline{CC}$ trên Email-Enron theo λ và K .

Tại $K = 100$, $\overline{CC}_w(0) = 0,4844$ đã sát cc_{global} . Mức tăng nhẹ lên 0,5040 tại $\lambda = 10$ là biên độ điển hình của đồ thị có cc_{global} cao. $\overline{CC}$ tại $\lambda = 10$ chênh 0,04 so với $\overline{CC}_w$ (0,5432 so với 0,5040), nhưng tại W_M bật lên 0,7592 trong khi $\overline{CC}_w$ tụt còn 0,4959, mở rộng chênh lệch lên 0,26. Đây là một trong những trường hợp W_M làm phân mảnh cụm rõ nhất, được $\overline{CC}_w$ phát hiện và phạt đúng.


Kết luận. Email-Enron thuộc nhóm đồ thị có cấu trúc tam giác đã

được phân cụm phổ trên A khai thác tốt, khoảng cải thiện CC còn lại cho W_λ tương đối hẹp. Tuy nhiên modularity vẫn cải thiện đáng kể, cho thấy motif giúp tinh chỉnh ranh giới cụm chứ không tạo ra cấu trúc tam giác mới.

facebook_combined

Hợp của mười ego-network: với mỗi trong mười người dùng Facebook, ta lấy đồ thị bạn bè của họ rồi ghép lại. Đỉnh là người dùng, cạnh là quan hệ bạn bè. Cộng đồng có nghĩa là vòng quan hệ xã hội của từng ego. Hệ số phân cụm toàn cục $cc_{\text{global}} = 0,6055$ rất cao, đặc trưng của cấu trúc ego-network.



Modularity.



Hình 4.29: Modularity Q trên facebook_combined theo λ và K .

Tại $K = 50$, $Q(0) = 0,7810$ rất cao và $\Delta Q = +0,0010$ không đáng kể. Khi tăng K lên 500, $Q(0)$ tụt còn 0,2319 và ΔQ đạt $+0,0519$ với $\lambda^* = 5$. Cùng đồ thị nhưng hai chế độ tách biệt theo K .

Hệ số phân cụm.

Hình 4.30: $\overline{CC}_w$ trên facebook_combined theo λ và K .Hình 4.31: $\overline{CC}$ trên facebook_combined theo λ và K .

Tại $K = 50$, $\overline{CC}_w(0) = 0,6061$ trùng khớp với cc_{global} . Mức tăng theo λ rất nhỏ, đạt 0,6192 tại $\lambda = 1$. Khác biệt với phần lớn đồ thị thật, $\overline{CC}$ tại W_M không bật lên mạnh (0,6548, gần với giá trị tại $\lambda = 10$ là 0,6587); $\overline{CC}_w$ cùng giữ ổn định. Cấu trúc ego-network bền vững khiến phân hoạch không bị phân mảnh ngay cả khi bỏ ma trận kề.


Kết luận. facebook_combined là đồ thị ego-network với cấu trúc tam giác đã trùng khớp gần như hoàn hảo với cộng đồng vòng bạn bè. Khi

K nhỏ, mỗi ego tạo thành một cụm tự nhiên và phân cụm phổ trên A đã đạt gần tối đa; vai trò của W_λ chỉ rõ rệt khi tăng K để chia tiếp các vòng bạn bè con bên trong mỗi ego.

CA-GrQc

Mạng đồng tác giả trên arXiv lĩnh vực Tương đối tổng quát. Đỉnh là một tác giả, cạnh nếu hai tác giả cùng đứng tên trên ít nhất một bài báo. Cộng đồng có nghĩa là nhóm nghiên cứu thường xuyên hợp tác. Hệ số phân cụm toàn cục $cc_{\text{global}} = 0,5569$, do bài báo nhiều tác giả tự nhiên sinh tam giác đầy đủ giữa đồng tác giả.



Modularity.



Hình 4.32: Modularity Q trên CA-GrQc theo λ và K .

$Q(0)$ cao trên dải rộng (0,66–0,82). Tại $K = 50$, $Q(0) = 0,8161$ và $\Delta Q = +0,0031$ không đáng kể. Chỉ ở $K = 500$ với $Q(0) = 0,6630$ thấp hơn, ΔQ mới đạt $+0,0476$ với $\lambda^* = 5$. Phân hoạch chất lượng cao gần như không hưởng lợi từ ma trận hỗn hợp.

Hệ số phân cụm.

Hình 4.33: $\overline{CC}_w$ trên CA-GrQc theo λ và K .Hình 4.34: $\overline{CC}$ trên CA-GrQc theo λ và K .

Tại $K = 50$, $\overline{CC}_w(0) = 0,5677$ sát cc_{global} . $\overline{CC}_w$ tăng nhẹ lên 0,6167 tại W_M , biên độ điển hình của đồ thị có cc_{global} cao. $\overline{CC}$ bắt từ 0,6056 tại $\lambda = 10$ lên 0,7574 tại W_M , một bước nhảy 0,15 trong khi $\overline{CC}_w$ trong cùng đoạn chỉ tăng 0,03. Nhóm nghiên cứu nhỏ với hệ số phân cụm gần 1 bị W_M tách ra thành cụm riêng, thiên lệch $\overline{CC}$ nhưng được $\overline{CC}_w$ giữ ổn định.


Kết luận. CA-GrQc đại diện cho mạng đồng tác giả nhỏ với cấu trúc

nhóm nghiên cứu đã được phân cụm phổ trên A phát hiện gần như tối ưu. Vai trò của W_λ chỉ thể hiện khi tăng K để chia nhỏ các nhóm lớn; ngược lại, cấu trúc tam giác nội cụm là đặc trưng cố hữu của đồ thị nên $\overline{CC}_w$ chỉ tăng khiêm tốn.

CA-AstroPh

Tương tự CA-GrQc nhưng cho lĩnh vực Vật lý thiên văn. Đồ thị lớn hơn ($n = 17,903$) và đậm đặc tam giác hơn. Hệ số phân cụm toàn cục $cc_{\text{global}} = 0,6328$ cao hơn CA-GrQc, do cộng tác trong vật lý thiên văn thường nhiều tác giả cùng một bài.



Modularity.



Hình 4.35: Modularity Q trên CA-AstroPh theo λ và K .

$Q(0)$ tập trung ở vùng 0,49–0,53, cải thiện đồng đều +0,030 đến +0,042. Tại $K = 50$, $\Delta Q = +0,0421$ với $\lambda^* = 10$. Đồ thị không có bộ test nào ở vùng $Q(0)$ cao nên biên độ ΔQ không bị thu hẹp như CA-GrQc.

Hệ số phân cụm.

Hình 4.36: $\overline{CC}_w$ trên CA-AstroPh theo λ và K .Hình 4.37: $\overline{CC}$ trên CA-AstroPh theo λ và K .

Tại $K = 50$, $\overline{CC}_w(0) = 0,6365$ trùng khớp với cc_{global} . $\overline{CC}_w$ tăng nhẹ lên 0,6717 tại W_M . $\overline{CC}$ bắt từ 0,7041 tại $\lambda = 10$ lên 0,7518 tại W_M , chênh 0,08 so với $\overline{CC}_w$. Bứt phá $\overline{CC}$ tại W_M vừa phải do CA-AstroPh là đồ thị lớn với nhiều nhóm hợp tác có kích thước trung bình, ít cụm cực nhỏ.


Kết luận. CA-AstroPh thuộc nhóm đồ thị đồng tác giả lớn với cc_{global} cao và phân hoạch ban đầu chất lượng trung bình. Vai trò của W_λ chủ yếu là tinh chỉnh modularity, không tạo ra thay đổi cấu trúc tam giác đáng

kể.

CA-CondMat

Tương tự CA-GrQc nhưng cho lĩnh vực Vật chất ngưng tụ. Hệ số phân cụm toàn cục $cc_{\text{global}} = 0,6417$ rất cao, gần với CA-AstroPh.



Modularity.



Hình 4.38: Modularity Q trên CA-CondMat theo λ và K .

$Q(0)$ cao trên toàn dải (0,62–0,66). ΔQ nhỏ, dao động từ +0,013 đến +0,032. Tại $K = 50$, $\Delta Q = +0,0316$ với $\lambda^* = 10$. Khi $Q(0)$ đã gần đạt mức cao của thang Q , biên độ cải thiện khả dĩ vốn nhỏ nên ΔQ bị thu hẹp.

Hệ số phân cụm.

Hình 4.39: $\overline{CC}_w$ trên CA-CondMat theo λ và K .Hình 4.40: $\overline{CC}$ trên CA-CondMat theo λ và K .


Tại $K = 50$, $\overline{CC}_w(0) = 0,6435$ trùng cc_{global} . Tăng lên 0,6769 tại W_M . $\overline{CC}$ bắt từ 0,6691 tại $\lambda = 10$ lên 0,7370 tại W_M (tăng 0,07), trong khi $\overline{CC}_w$ chỉ tăng 0,01 trong cùng đoạn. Phân mảnh cụm tại W_M ở mức khiêm tốn, $\overline{CC}_w$ giữ ổn định phản ánh đúng kích thước cụm.

Kết luận. CA-CondMat tái lập pattern của CA-AstroPh và CA-GrQc: mạng đồng tác giả có cấu trúc tam giác mạnh đã được phân cụm phổ trên A khai thác gần tối ưu, W_λ chỉ đóng vai trò tinh chỉnh.

CA-HepTh

Tương tự CA-GrQc nhưng cho lĩnh vực Vật lý năng lượng cao lý thuyết. Đồ thị đồng tác giả thừa nhất trong nhóm CA-, hệ số phân cụm toàn cục $cc_{\text{global}} = 0,4816$ thấp nhất nhóm.



Modularity.



Hình 4.41: Modularity Q trên CA-HepTh theo λ và K .

$Q(0)$ cao (0,63–0,69). ΔQ chỉ +0,015 đến +0,025, mức cải thiện không đáng kể nhưng đều dương. Tại $K = 50$, $\Delta Q = +0,0250$ với $\lambda^* = 5$. Khẳng định thêm xu hướng ΔQ thu hẹp khi $Q(0)$ đã cao.

Hệ số phân cụm.

Hình 4.42: $\overline{CC}_w$ trên CA-HepTh theo λ và K .Hình 4.43: $\overline{CC}$ trên CA-HepTh theo λ và K .

Tại $K = 50$, $\overline{CC}_w(0) = 0,4863$ sát cc_{global} , tăng lên 0,5557 tại W_M . $\overline{CC}$ bắt từ 0,5337 tại $\lambda = 10$ lên 0,7043 tại W_M , tăng 0,17 chỉ qua một bước trong khi $\overline{CC}_w$ trong cùng đoạn tăng 0,04. Chênh lệch 0,15 giữa hai đại lượng tại W_M là một trong những chênh lớn nhất trong tập dữ liệu thật, dấu hiệu CA-HepTh có nhiều nhóm nghiên cứu thừa cỡ nhỏ bị W_M tách rời.


Kết luận. CA-HepTh là phiên bản thừa của họ CA-, modularity

sớm đạt mức cao nên biên độ cải thiện theo Q nhỏ, nhưng $\overline{CC}_w$ vẫn có khoảng cải thiện đáng kể. Chênh lệch giữa $\overline{CC}$ và $\overline{CC}_w$ phản ánh nhiều nhóm nghiên cứu nhỏ với hệ số phân cụm gần 1.

`musae_facebook`

Đỉnh là một trang Facebook công khai, cạnh nối hai trang có liên kết “like” lẫn nhau. Cộng đồng phản ánh chủ đề hoặc lĩnh vực của trang. Hệ số phân cụm toàn cục $cc_{\text{global}} = 0,3597$, thấp hơn các mạng xã hội cá nhân do quan hệ “like” giữa trang phản ánh chủ đề hơn là cộng tác ba bên.



Modularity.



Hình 4.44: Modularity Q trên `musae_facebook` theo λ và K .

$Q(0)$ rất cao (0,69–0,75). ΔQ chỉ +0,003 đến +0,020, hầu như không thay đổi kết quả phân cụm. Tại $K = 500$, $\Delta Q = +0,0202$ với $\lambda^* = 10$. Đây là minh chứng rõ nhất cho xu hướng ΔQ thu hẹp khi $Q(0)$ đã cao.

Hệ số phân cụm.

Hình 4.45: $\overline{CC}_w$ trên musae_facebook theo λ và K .Hình 4.46: $\overline{CC}$ trên musae_facebook theo λ và K .

Tại $K = 200$, $\overline{CC}_w(0) = 0,4091$ đã vượt cc_{global} , dấu hiệu phân cụm phổ trên A đặt được tam giác có sẵn vào trong cụm. $\overline{CC}_w$ tăng lên 0,4737 tại W_M . $\overline{CC}$ bật từ 0,4508 tại $\lambda = 10$ lên 0,6439 tại W_M , tăng 0,19 trong khi $\overline{CC}_w$ trong cùng đoạn tăng 0,03. Chênh 0,17 giữa hai đại lượng tại W_M phản ánh nhiều chủ đề nhánh nhỏ bị tách rời, khẳng định $\overline{CC}_w$ là chỉ số phù hợp hơn.

Kết luận. musae_facebook khác biệt với họ musae Twitch ở chỗ

quan hệ giữa các trang chủ đề mang tính phân loại hơn là quan hệ xã hội ba bên. Modularity ban đầu đã cao nhờ cấu trúc chủ đề rõ ràng, trọng số motif chỉ tạo ra cải thiện cận biên. Chênh lệch giữa $\overline{CC}$ và $\overline{CC}_w$ phản ánh nhiều cụm nhỏ ứng với các chủ đề ngách.

Tổng kết kết quả trên đồ thị thật

Quan sát chung. Trên cả mười đồ thị, mức cải thiện ΔQ tỉ lệ nghịch với $Q(0)$, thể hiện hai chế độ rõ rệt:

- Khi $Q(0)$ thấp (musae_DE, musae_ES, các phân hoạch K lớn của lastfm_asia và facebook_combined), ma trận hỗn hợp cải thiện rõ rệt, ΔQ tới $+0,08 - +0,12$.
- Khi $Q(0)$ đã cao (CA-CondMat, CA-HepTh, musae_facebook, các phân hoạch K nhỏ của CA-GrQc và facebook_combined), ΔQ chỉ $+0,001 - +0,03$, hầu như không thay đổi kết quả phân cụm.

ΔQ luôn dương trên cả mười đồ thị, nên ma trận hỗn hợp không bao giờ làm giảm chất lượng. Giá trị λ^* tối ưu nằm trong khoảng $\{5, 10, W_M\}$ ở chín trên mười đồ thị, lớn hơn hẳn so với đồ thị sinh ngẫu nhiên ở Mục 4.2 (chủ yếu là 0,5). Hai đồ thị mạng Twitch (musae_DE và musae_ES) cho ΔQ cao nhất với $\lambda^* \in \{W_M, 1\}$, là dấu hiệu của triadic closure mạnh nhất trong tập dữ liệu.

Phụ thuộc theo K . Trên cùng một đồ thị, biên độ cải thiện của W_λ tăng đều theo K . Khi K nhỏ, các cụm rộng và phân hoạch trên A đã chứa phần lớn tam giác; trọng số motif khi đó không bổ sung thông tin và $\overline{CC}_w$ gần như không thay đổi giữa $\lambda = 0$ và λ^* . Khi K lớn, số tam giác bị cắt qua biên cụm tăng lên, và chính phần tam giác liên cụm này mới là tín hiệu mà W_λ khai thác để gom các đỉnh chung tam giác về cùng cụm. Hiện tượng thấy rõ trên facebook_combined (ΔQ từ $+0,006$ tại $K = 50$ lên $+0,082$ tại $K = 500$), CA-HepTh ($+0,001 \rightarrow +0,052$) và CA-GrQc ($+0,003 \rightarrow +0,048$). Nói ngắn gọn, motif chỉ phát huy vai trò khi yêu cầu phân hoạch chi tiết vượt khả năng của A thuần.

G_λ so với G_M thuần. So sánh hai cực λ^* hữu hạn và $\lambda = W_M$ cho thấy chúng tối ưu hai chỉ số khác nhau. G_M cho $\overline{CC}$ cao hơn rõ rệt trên đại đa số đồ thị (lastfm_asia $0,27 \rightarrow 0,60$, CA-HepTh $0,53 \rightarrow 0,70$, musae_facebook $0,45 \rightarrow 0,64$), nhưng đổi lại Q thấp hơn nhiều: trên 9/10 đồ thị, $Q(W_M) < Q(\lambda^*)$ với khoảng cách có thể tới 0,10–0,15. Nguyên nhân được giải thích ngay bởi Mệnh đề 3.7 và thấy rõ qua $\overline{CC}_w$: bỏ hoàn toàn A khiến các đỉnh không thuộc tam giác bị cô lập trong G_M và rơi vào cụm rất nhỏ, đẩy $\overline{CC}$ lên cao do hiệu ứng cụm nhỏ chứ không do chất

lượng phân hoạch thực sự cao hơn. G_λ ở λ hữu hạn giữ lại A làm khung liên thông, hy sinh một phần $\overline{CC}$ để đổi lấy Q và phân hoạch không bị phân mảnh.

Xác nhận thực nghiệm về vai trò của $\overline{CC}_w$. Khoảng cách quan sát được giữa $\overline{CC}$ và $\overline{CC}_w$ trên đồ thị thật xác nhận động cơ thiết kế đã trình bày ở Định nghĩa 2.13. Tại $K = 50$ trên lastfm_asia, $\overline{CC}(\lambda^\dagger) = 0,6044$ trong khi $\overline{CC}_w(\lambda^\dagger) = 0,3146$, chênh tới 0,29; trên CA-GrQc chênh 0,14; trên CA-HepTh chênh 0,15. Chênh lệch tích cực này hoàn toàn do các cụm rất nhỏ với hệ số phân cụm gần 1 kéo $\overline{CC}$ lên cao, dù chúng đóng góp ít vào tổng số đỉnh được phân cụm. Do đó trên dữ liệu thật, $\overline{CC}$ có xu hướng đánh giá quá lạc quan; $\overline{CC}_w$ cho con số thận trọng hơn và phản ánh đúng chất lượng phân hoạch.

So sánh giữa các giá trị λ cung cấp thêm một bằng chứng thiết kế quan trọng. Trên hầu hết đồ thị thật, $\overline{CC}$ ở $\lambda = W_M$ bật lên rất cao so với các λ hữu hạn — chẳng hạn trên lastfm_asia tại $K = 50$, $\overline{CC}$ chuyển từ 0,2681 ở $\lambda = 10$ lên 0,6044 ở W_M , gấp hơn hai lần; trên CA-HepTh chuyển từ 0,5337 lên 0,7043; trên musae_facebook chuyển từ 0,4508 lên 0,6439. Cùng phân hoạch đó, $\overline{CC}_w$ chỉ tăng nhẹ giữa λ hữu hạn và W_M , giữ ổn định trong cùng dải biến thiên. Sự bất đối xứng này có lời giải thích trực tiếp: bỏ hoàn toàn ma trận kề A và chỉ dùng $W^{(M)}$ khiến phân cụm phổ tách đồ thị thành nhiều cụm rất nhỏ, vì các đỉnh không nằm trong tam giác trở thành cô lập trong G_M (Mệnh đề 3.7). Các cụm nhỏ này có hệ số phân cụm cục bộ gần 1 và đẩy $\overline{CC}$ lên rất nhanh, nhưng $\overline{CC}_w$ không bị thổi phồng vì trọng số tỉ lệ với kích thước cụm. Vì vậy mức tăng do bởi $\overline{CC}_w$ phản ánh đúng phần đóng góp thực của motif vào chất lượng phân hoạch; $\overline{CC}$ thì bị ảnh hưởng nặng bởi hiện tượng phân mảnh cụm khi $\lambda \rightarrow \infty$.

4.4 Tổng hợp: hai chế độ tối ưu của λ

Kết hợp toàn bộ kết quả thực nghiệm, λ^* tối ưu thể hiện hai chế độ trái ngược, phụ thuộc vào cơ chế sinh cạnh của đồ thị.

Bảng 4.7: Hai chế độ tối ưu của λ^* phụ thuộc loại đồ thị

Loại đồ thị	λ^* quan sát	Cơ chế sinh tam giác
SBM, Planted, GRPG	0,5 – 1	Tam giác là hệ quả thống kê của mật độ cạnh, không độc lập với cạnh.
LFR khó ($\mu \geq 0,35$)	0,5 – 5	Tam giác cũng từ cấu hình cạnh, nhưng phân bố bậc power-law tạo các vùng tam giác đậm đặc cục bộ.
Mạng xã hội thật	5 – W_M	Triadic closure tạo tam giác có chủ đích, mang tín hiệu cộng đồng độc lập với cạnh đơn lẻ.

Quan sát then chốt: λ^* phụ thuộc *tỷ lệ tín hiệu cộng đồng giữa tam giác và cạnh*. Khi tam giác chỉ là hệ quả thống kê của cạnh (các mô hình ngẫu nhiên), thêm trọng số motif nhiều làm pha loãng cạnh và giảm chất lượng phân hoạch, do đó λ^* nhỏ. Khi tam giác mang tín hiệu cấu trúc riêng vượt xa kỳ vọng độc lập (mạng xã hội thật), trọng số motif lớn lại có lợi và λ^* dịch về phía W_M . Đây là biểu hiện thực nghiệm của Nhận xét B.5 ở Phụ lục B.

Kết quả tổng quát. Ma trận hỗn hợp W_λ với λ^* chọn phù hợp luôn cho modularity tốt hơn hoặc bằng A thuần trên cả 35 bộ test sinh ngẫu nhiên và các cấu hình (K) trên mười đồ thị thật. Trên các bộ test khó nhất, mức cải thiện ΔQ vượt +0,1. Điều này xác nhận giả thiết lý thuyết ở Chương 3: việc gộp thông tin cạnh và motif qua một tham số nội suy duy nhất là một mở rộng có giá trị thực nghiệm cho phân cụm phổ.

KẾT LUẬN

Đóng góp của khóa luận

- 1) Đề xuất ma trận hỗn hợp $W_\lambda = A + \lambda W^{(M)}$ kết hợp thông tin cạnh và motif qua một tham số nội suy duy nhất. Chứng minh W_λ luôn là ma trận trọng số đối xứng không âm hợp lệ (Mệnh đề 3.2), kế thừa bất đẳng thức Cheeger trên đồ thị có trọng số (Định lý 3.5) và tính đúng đắn của phép nối lỏng phổ NCut (Định lý 3.6). Ma trận W_λ khắc phục hạn chế của $W^{(M)}$ thuần khi đồ thị có cạnh không nằm trong motif nào (Mệnh đề 3.7).
- 2) Tiến hành thực nghiệm hệ thống với Thuật toán 2 sử dụng đầu vào W_λ trên bốn mô hình sinh ngẫu nhiên có cấu trúc cộng đồng (SBM, Planted Partition, GRPG, LFR) và mười đồ thị mạng xã hội thật.
- 3) Phát hiện thực nghiệm hai chế độ tối ưu của λ^* phụ thuộc cơ chế sinh tam giác:
 - Trên đồ thị sinh ngẫu nhiên, λ^* tối ưu nằm trong khoảng $\{0,5, 1\}$. Tam giác là hệ quả thống kê của mật độ cạnh, không độc lập với cạnh, nên thêm trọng số motif lớn làm pha loãng cạnh và giảm chất lượng phân hoạch.
 - Trên đồ thị mạng xã hội thật, λ^* dịch về phía $\{5, 10, W_M\}$ ở chín trên mười đồ thị. Triadic closure tạo tam giác mang tín hiệu cộng đồng độc lập với cạnh đơn lẻ, nên trọng số motif lớn có lợi.
- 4) Phát hiện quan hệ ngược giữa ΔQ và $Q(0)$ trên đồ thị thật: khi $Q(0)$ thấp, W_λ cải thiện rõ rệt với ΔQ đạt +0,08 đến +0,12; khi $Q(0)$ đã cao, biên độ cải thiện khả dĩ vốn nhỏ nên ΔQ chỉ +0,001 đến +0,03, hầu như không thay đổi kết quả phân cụm. Xu hướng này quan sát được trên nhiều đồ thị thật, kể cả khi so sánh các giá trị K khác nhau trên cùng một đồ thị.

Hạn chế

- Chưa có công thức lý thuyết tiên đoán λ^* từ các đại lượng cấu trúc của đồ thị như mật độ tam giác hay phân bố bậc.
- Chỉ thực nghiệm với motif tam giác K_3 ; chưa khảo sát các motif bậc cao hơn như K_4 hay bi-fan.
- Chưa phát biểu chặt chẽ điều kiện cấu trúc để đảm bảo tồn tại $\lambda^* > 0$ với $Q(\lambda^*) > Q(0)$.

Hướng phát triển

- Xây dựng khung chứng minh bất đẳng thức $Q_A(S_\lambda) \geq Q_A(S_0)$ dưới điều kiện cấu trúc trên G , kèm phát biểu chặt chẽ ý nghĩa của motif K_3 trên đồ thị.
- Mở rộng ma trận trọng số sang dạng tổng quát $f(e, \lambda)$ cá nhân hóa theo cạnh: hệ số Jaccard, hệ số phân cụm cạnh, hoặc tham số λ riêng cho từng đỉnh.
- Định nghĩa modularity hỗn hợp Q_λ sử dụng null model tương thích với W_λ , thay vì dùng Q_A làm chỉ số đánh giá.
- Mở rộng phương pháp sang đồ thị có hướng qua kỹ thuật tách đỉnh, giữ nguyên cấu trúc đối xứng cho ma trận trọng số.
- So sánh với các motif khác ngoài K_3 để kiểm tra giả thuyết tam giác là đơn vị cộng đồng tự nhiên nhất trên mạng xã hội.

Phụ lục A

CHỨNG MINH CÁC ĐỊNH LÝ

Phụ lục này trình bày chứng minh các định lý nền được nêu trong Chương 2. Một số chứng minh được trình bày đầy đủ, một số chứng minh dài và phức tạp được trình bày dưới dạng phác thảo kèm tham chiếu nguồn chi tiết.

A.1 Định lý Courant–Fischer

Phát biểu. Cho ma trận đối xứng $M \in \mathbb{R}^{n \times n}$ với các giá trị riêng $\lambda_1 \leq \dots \leq \lambda_n$ và các vector riêng đơn vị tương ứng $v_1, \dots, v_n$ tạo thành cơ sở trực chuẩn. Khi đó với mọi $k \in \{1, \dots, n\}$:

$$\lambda_k = \min_{\substack{U \subset \mathbb{R}^n \\ \dim U = k}} \max_{x \in U \setminus \{0\}} R(M, x) = \max_{x \perp v_1, \dots, v_{k-1}} R(M, x).$$

Chứng minh. Vì M đối xứng, theo định lý phổ tồn tại cơ sở trực chuẩn $\{v_1, \dots, v_n\}$ của $\mathbb{R}^n$ gồm các vector riêng. Mọi $x \neq 0$ viết được duy nhất dưới dạng $x = \sum_{i=1}^n c_i v_i$ với $c_i = v_i^\top x$. Khi đó

$$x^\top M x = \sum_{i=1}^n \lambda_i c_i^2, \quad x^\top x = \sum_{i=1}^n c_i^2,$$

nên $R(M, x) = \frac{\sum_i \lambda_i c_i^2}{\sum_i c_i^2}$ là trung bình có trọng số (không âm) của các giá trị riêng λ_i .

Đẳng thức thứ hai. Lấy $x \perp v_1, \dots, v_{k-1}$, tức $c_1 = \dots = c_{k-1} = 0$. Khi đó

$$R(M, x) = \frac{\sum_{i \geq k} \lambda_i c_i^2}{\sum_{i \geq k} c_i^2} \geq \lambda_k,$$

vì $\lambda_i \geq \lambda_k$ với mọi $i \geq k$. Đẳng thức xảy ra khi $x = v_k$, do đó

$$\max_{x \perp v_1, \dots, v_{k-1}} R(M, x) = \lambda_k.$$

Đẳng thức thứ nhất (min-max). Với mọi không gian con $U \subset \mathbb{R}^n$ có $\dim U = k$, vì $\dim \text{span}\{v_k, \dots, v_n\} = n - k + 1$ và $\dim U + (n - k + 1) > n$, hai không gian này phải giao nhau ngoài vector 0. Lấy $x \in U \cap \text{span}\{v_k, \dots, v_n\}$ với $x \neq 0$, ta có $c_1 = \dots = c_{k-1} = 0$ nên

$$R(M, x) = \frac{\sum_{i \geq k} \lambda_i c_i^2}{\sum_{i \geq k} c_i^2} \geq \lambda_k.$$

Suy ra $\max_{x \in U \setminus \{0\}} R(M, x) \geq \lambda_k$ với mọi U có $\dim U = k$. Mặt khác, lấy $U = \text{span}\{v_1, \dots, v_k\}$ thì với mọi $x \in U \setminus \{0\}$, $R(M, x) \leq \lambda_k$, đạt được dấu bằng tại $x = v_k$. Do đó cận dưới đạt được, dẫn tới đẳng thức. $\square$

A.2 Định lý Ky Fan

Phát biểu. Cho ma trận đối xứng $M \in \mathbb{R}^{n \times n}$ với các giá trị riêng $\lambda_1 \leq \dots \leq \lambda_n$. Khi đó với mọi $k \leq n$:

$$\max_{X \in \mathbb{R}^{n \times k}, X^\top X = I_k} \text{Tr}(X^\top M X) = \sum_{i=1}^k \lambda_{n-i+1},$$

$$\min_{X \in \mathbb{R}^{n \times k}, X^\top X = I_k} \text{Tr}(X^\top M X) = \sum_{i=1}^k \lambda_i.$$

Chứng minh. Dạng cực tiểu. Đặt $X = [x_1, \dots, x_k]$ với $X^\top X = I_k$, tức $\{x_1, \dots, x_k\}$ là hệ trực chuẩn. Khi đó

$$\text{Tr}(X^\top M X) = \sum_{i=1}^k x_i^\top M x_i.$$

Mở rộng $\{x_1, \dots, x_k\}$ thành cơ sở trực chuẩn $\{x_1, \dots, x_n\}$ của $\mathbb{R}^n$. Đặt $Q = [x_1, \dots, x_n]$ là ma trận trực giao và $\widetilde{M} = Q^\top M Q$. Khi đó $\widetilde{M}$ đồng dạng với M qua phép biến đổi trực giao nên có cùng phổ $\{\lambda_1, \dots, \lambda_n\}$. Hơn nữa $x_i^\top M x_i = \widetilde{M}_{ii}$, do đó

$$\text{Tr}(X^\top M X) = \sum_{i=1}^k \widetilde{M}_{ii}.$$

Theo bổ đề Schur–Horn, vector các phần tử đường chéo của một ma trận đối xứng bị trội (majorize) bởi vector các giá trị riêng của nó. Cụ thể, với mọi hoán vị các phần tử đường chéo, tổng k phần tử đường chéo đầu

thỏa

$$\sum_{i=1}^k \widetilde{M}_{ii} \geq \sum_{i=1}^k \lambda_i,$$

với dấu bằng đạt được khi $\{x_1, \dots, x_k\}$ là k vector riêng đầu của M . Do đó

$$\min_{X^\top X = I_k} \text{Tr}(X^\top M X) = \sum_{i=1}^k \lambda_i,$$

nghiệm đạt tại $X^* = [v_1, \dots, v_k]$.

Dạng cực đại. Áp dụng kết quả vừa chứng minh cho ma trận $-M$. Phổ của $-M$ thu được bằng cách đảo dấu phổ của M rồi sắp xếp tăng dần:

$$\lambda_i(-M) = -\lambda_{n-i+1}(M), \quad i = 1, \dots, n,$$

do $\lambda_n(M) \geq \dots \geq \lambda_1(M)$ kéo theo $-\lambda_n(M) \leq \dots \leq -\lambda_1(M)$. Bởi $-M$ cũng đối xứng, dạng cực tiểu áp dụng được:

$$\min_{X^\top X = I_k} \text{Tr}(X^\top (-M) X) = \sum_{i=1}^k \lambda_i(-M) = -\sum_{i=1}^k \lambda_{n-i+1}(M).$$

Mặt khác $\text{Tr}(X^\top (-M) X) = -\text{Tr}(X^\top M X)$, do đó

$$\min_{X^\top X = I_k} (-\text{Tr}(X^\top M X)) = -\max_{X^\top X = I_k} \text{Tr}(X^\top M X).$$

Kết hợp hai đẳng thức trên và đổi dấu:

$$\max_{X^\top X = I_k} \text{Tr}(X^\top M X) = \sum_{i=1}^k \lambda_{n-i+1}(M),$$

nghiệm đạt tại $X^* = [v_n, v_{n-1}, \dots, v_{n-k+1}]$, là k vector riêng ứng với các giá trị riêng lớn nhất của M . $\square$

A.3 Bất đẳng thức Cheeger

Phát biểu. Cho đồ thị vô hướng có trọng số không âm với Laplacian chuẩn hóa $\mathcal{L} = I - D^{-1/2} A D^{-1/2}$ có các giá trị riêng $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n \leq 2$. Khi đó

$$\frac{\lambda_2}{2} \leq \phi^* \leq \sqrt{2\lambda_2}.$$

Phác thảo chứng minh. Chứng minh đầy đủ thuộc tài liệu chuẩn về phổ đồ thị, xem chương 2 của Chung [11]. Ở đây ta phác thảo các bước chính.

Cận dưới $\lambda_2/2 \leq \phi^*$. Với mọi tập $S \neq \emptyset, V$, đặt vector chỉ thị có trọng

$$f_u = \begin{cases} \sqrt{\text{vol}(\bar{S})/\text{vol}(S)} & \text{nếu } u \in S, \\ -\sqrt{\text{vol}(S)/\text{vol}(\bar{S})} & \text{nếu } u \in \bar{S}. \end{cases}$$

Khi đó f trực giao với vector $D^{1/2}\mathbf{1}$ ứng với giá trị riêng $\lambda_1 = 0$ của $\mathcal{L}$. Tính toán cho thấy

$$R(\mathcal{L}, D^{1/2}f) = \frac{2\text{cut}(S, \bar{S})}{\min(\text{vol}(S), \text{vol}(\bar{S}))} \cdot \alpha(S),$$

với $\alpha(S) \in [\frac{1}{2}, 1]$ là một hệ số chuẩn hóa. Theo Định lý Courant–Fischer (Định lý 2.7), $\lambda_2 \leq R(\mathcal{L}, D^{1/2}f)$ với mọi $f \perp D^{1/2}\mathbf{1}$, dẫn tới $\lambda_2 \leq 2\phi(S)$. Lấy inf trên S thu được $\lambda_2/2 \leq \phi^*$.

Cận trên $\phi^* \leq \sqrt{2\lambda_2}$. Lấy v_2 là vector riêng ứng với λ_2 , đặt $f = D^{-1/2}v_2$. Sắp xếp các đỉnh theo thứ tự tăng của f_u và xét các nhất cắt sweep $S_t = \{u : f_u \leq t\}$ với t chạy qua các giá trị f_u . Bằng phân tích chi tiết, tồn tại t sao cho

$$\phi(S_t) \leq \sqrt{2\lambda_2}.$$

Đây là phần khó nhất của chứng minh, sử dụng bất đẳng thức Cauchy–Schwarz và đồng nhất thức về cut và volume trên các nhất cắt sweep. Chi tiết xem [11, Định lý 2.2]. $\square$

Phụ lục B

CÁC MÔ HÌNH SINH NGẪU NHIÊN

Phụ lục này trình bày định nghĩa hình thức của bốn mô hình sinh ngẫu nhiên có cấu trúc cộng đồng được dùng trong Chương 4: SBM, Planted Partition, Gaussian Random Partition Graph (GRPG) và LFR.

Quy ước. Mỗi mô hình được đặc tả bằng cặp phân bố $(\mathcal{D}_V, \mathcal{D}_E)$:

- $\mathcal{D}_V$ là phân phối sinh tập đỉnh kèm các thuộc tính dùng để sinh cạnh: nhãn cụm $z : V \rightarrow \{1, \dots, K\}$ (nếu có), kích thước cụm $\{n_k\}$, bậc kỳ vọng $\{d_u\}$. Ký hiệu $(V, z) \sim \mathcal{D}_V$.
- $\mathcal{D}_E$ là phân phối có điều kiện trên các phần tử A_{uv} của ma trận kề, cho trước thông tin đỉnh sinh bởi $\mathcal{D}_V$. Ký hiệu $A \mid (V, z) \sim \mathcal{D}_E$.

B.1 Stochastic Block Model

Định nghĩa B.1 (Stochastic Block Model [20]). Cho số đỉnh n , số cộng đồng K , ánh xạ nhãn $z : V \rightarrow \{1, \dots, K\}$ và ma trận xác suất $P \in [0, 1]^{K \times K}$ đối xứng. Đồ thị SBM $G \sim \text{SBM}(n, z, P)$ được sinh bằng cách: với mỗi cặp $u \neq v$, đặt một cạnh giữa u và v độc lập với xác suất $P_{z(u), z(v)}$.

$\mathcal{D}_V$ Tập đỉnh $V = \{1, \dots, n\}$, nhãn z cố định với $|z^{-1}(k)| = n_k$.

$\mathcal{D}_E$ Trường hợp đối xứng: $P_{kk} = p_{\text{in}}, P_{kl} = p_{\text{out}}, p_{\text{in}} > p_{\text{out}}$.

$$A_{uv} \mid z \sim \text{Bernoulli}(P_{z(u), z(v)}), \quad u < v.$$

Kết quả lý thuyết then chốt của SBM, đã khai thác ở Mục 2.3.4, là phân hoạch phổ trên $\mathbb{E}[A]$ trùng phân hoạch chuẩn do $\mathbb{E}[A]$ có cấu trúc khối hạng K ; các định lý Davis–Kahan và Weyl bảo đảm phân hoạch phổ trên $A = \mathbb{E}[A] + E$ vẫn gần phân hoạch chuẩn khi nhiễu đủ nhỏ [5], [18], [21].

B.2 Planted Partition

Định nghĩa B.2 (Planted Partition [22]). Trường hợp riêng của Định nghĩa B.1 với mọi cụm cùng kích thước s và hai xác suất $p_{\text{in}} > p_{\text{out}}$.

$\mathcal{D}_V$ $n = Ks$ với nhãn $z(u) = \lfloor u/s \rfloor$.

$\mathcal{D}_E$ Giống SBM đối xứng:

$$A_{uv} \mid z \sim \text{Bernoulli}(P_{z(u), z(v)}), \quad u < v.$$

Tính đối xứng tuyệt đối khiến Planted Partition là baseline tối thiểu: một thuật toán không phân loại được Planted Partition thì không được kỳ vọng hoạt động trên các mô hình phức tạp hơn.

B.3 Gaussian Random Partition Graph

Định nghĩa B.3 (Gaussian Random Partition Graph). Cho số đỉnh n , kích thước cụm trung bình s , tham số hình dạng $v > 0$, và hai xác suất $p_{\text{in}}, p_{\text{out}}$. Lấy mẫu các kích thước cụm $n_1, n_2, \dots$ độc lập từ phân phối $\mathcal{N}(s, s/v)$ cho đến khi $\sum_k n_k = n$, rồi sinh cạnh theo cơ chế SBM đối xứng với $p_{\text{in}}, p_{\text{out}}$.

$\mathcal{D}_V$ Kích thước cụm độc lập theo Gauss, lấy đến khi $\sum_k n_k \geq n$:

$$n_k \stackrel{\text{iid}}{\sim} \mathcal{N}(s, s/v).$$

$\mathcal{D}_E$ Giống SBM đối xứng:

$$A_{uv} \mid z \sim \text{Bernoulli}(P_{z(u), z(v)}), \quad u < v.$$

Tham số v lớn cho cụm gần đều, v nhỏ cho cụm chênh lệch lớn. GRPG nằm giữa Planted Partition và LFR về mức độ không đồng đều.

B.4 LFR Benchmark

Định nghĩa B.4 (LFR Benchmark [23]). Cho n , hai số mũ τ_1 (phân phối bậc) và τ_2 (phân phối kích thước cụm), bậc trung bình $\langle d \rangle$, giới hạn bậc, giới hạn kích thước cụm, và tham số trộn $\mu \in [0, 1]$. Lấy mẫu bậc d_u theo $P(d) \propto d^{-\tau_1}$ và kích thước cụm n_k theo $P(s) \propto s^{-\tau_2}$; gán mỗi đỉnh u vào một cụm sao cho bậc nội cụm xấp xỉ $(1 - \mu)d_u$ và bậc liên cụm xấp xỉ μd_u ; nối lại cạnh theo mô hình cầu hình để đạt cấu hình bậc đã định.

$\mathcal{D}_V$ Bậc và kích thước cụm độc lập theo power-law:

$$d_u \stackrel{\text{iid}}{\sim} P(d) \propto d^{-\tau_1}, \quad n_k \stackrel{\text{iid}}{\sim} P(s) \propto s^{-\tau_2}.$$

$\mathcal{D}_E$ Mô hình cầu hình với ràng buộc bậc nội/liên cụm theo μ :

$$\sum_{v:z(v)=z(u)} A_{uv} \approx (1 - \mu)d_u, \quad \sum_{v:z(v) \neq z(u)} A_{uv} \approx \mu d_u.$$

Tham số trộn μ điều khiển độ mạnh cấu trúc cộng đồng: $\mu \leq 0.3$ là chế độ dễ, $\mu \in [0.3, 0.5]$ là chế độ khó, $\mu > 0.5$ bất khả phân giải bằng các thuật toán dựa trên cạnh đơn lẻ.

Nhận xét B.5 (Tam giác trong các mô hình có cấu trúc cộng đồng). Cả bốn mô hình SBM, Planted Partition, GRPG và LFR đều sinh cạnh độc lập theo cặp (sau khi cố định bậc trong LFR), nên tam giác chỉ là hệ quả thống kê của mật độ cạnh, không phản ánh một cơ chế bậc cao riêng. Điều này trái với mạng xã hội thật, nơi triadic closure (Mục 2.2.2) tạo mật độ tam giác vượt xa kỳ vọng độc lập, là điểm khác biệt then chốt giải thích kết quả thực nghiệm trái ngược giữa đồ thị sinh ngẫu nhiên và đồ thị xã hội thật.

TÀI LIỆU THAM KHẢO

- [1] A. R. Benson, D. F. Gleich **and** J. Leskovec, “Higher-order organization of complex networks,” **in** *Science* **volume** 353, 2016, **pages** 163–166. DOI: 10.1126/science.aad9029
- [2] D. H. Do **and** T. H. D. Phan, “Overlapping community detection algorithms using modularity and the cosine,” *Advances in Complex Systems*, **journal** 28, **number** 3, **page** 2550 006, 2025.
- [3] T. D. Dang, D. H. Do **and** T. H. D. Phan, “Community detection in directed graphs using stationary distribution and hitting times methods,” *Social Network Analysis and Mining*, **journal** 13, **number** 1, **page** 80, 2023.
- [4] J. Shi **and** J. Malik, “Normalized cuts and image segmentation,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, **journal** 22, **number** 8, **pages** 888–905, 2000. DOI: 10.1109/34.868688
- [5] J. Jin, “Fast community detection by SCORE,” *The Annals of Statistics*, **journal** 43, **number** 1, **pages** 57–89, 2015. DOI: 10.1214/14-AOS1265
- [6] V. D. Blondel, J.-L. Guillaume, R. Lambiotte **and** E. Lefebvre, “Fast unfolding of communities in large networks,” *Journal of Statistical Mechanics: Theory and Experiment*, **journal** 2008, **number** 10, P10008, 2008. DOI: 10.1088/1742-5468/2008/10/P10008
- [7] D. H. Do **and** T. H. D. Phan, “An improvement on the Louvain algorithm using random walks,” *Journal of Combinatorial Optimization*, **journal** 50, **number** 1, **page** 14, 2025.
- [8] D. H. Do **and** T. H. D. Phan, “Detecting communities in large networks using the extended Walktrap algorithm,” **in** *2022 RIVF International Conference on Computing and Communication Technologies (RIVF)* 2022, **pages** 100–105. DOI: 10.1109/RIVF55975.2022.10013880
- [9] M. E. J. Newman, “Modularity and community structure in networks,” *Proceedings of the National Academy of Sciences*, **journal** 103, **number** 23, **pages** 8577–8582, 2006. DOI: 10.1073/pnas.0601602103
- [10] K. Fan, “On a theorem of Weyl concerning eigenvalues of linear transformations,” *Proceedings of the National Academy of Sciences*, **journal** 35, **number** 11, **pages** 652–655, 1949. DOI: 10.1073/pnas.35.11.652
- [11] F. R. K. Chung, *Spectral Graph Theory* (CBMS Regional Conference Series in Mathematics 92). American Mathematical Society, 1997.
- [12] D. J. Watts **and** S. H. Strogatz, “Collective dynamics of ‘small-world’ networks,” *Nature*, **journal** 393, **number** 6684, **pages** 440–442, 1998. DOI: 10.1038/30918
- [13] M. E. J. Newman, “The structure and function of complex networks,” *SIAM Review*, **journal** 45, **number** 2, **pages** 167–256, 2003. DOI: 10.1137/S003614450342480
- [14] M. S. Granovetter, “The strength of weak ties,” *American Journal of Sociology*, **journal** 78, **number** 6, **pages** 1360–1380, 1973. DOI: 10.1086/225469
- [15] P. W. Holland **and** S. Leinhardt, “Transitivity in structural models of small groups,” *Comparative Group Studies*, **journal** 2, **number** 2, **pages** 107–124, 1971. DOI: 10.1177/104649647100200201
- [16] M. Belkin **and** P. Niyogi, “Laplacian Eigenmaps for Dimensionality Reduction and Data Representation,” *Neural Computation*, **journal** 15, **number** 6, **pages** 1373–1396, 2003. DOI: 10.1162/089976603321780317
- [17] S. Paul, O. Milenkovic **and** Y. Chen, “Higher-Order Spectral Clustering Under Superimposed Stochastic Block Models,” *Journal of Machine Learning Research*, **journal** 24, **number** 320, **pages** 1–55, 2023.

- [18] J. Lei **and** A. Rinaldo, “Consistency of spectral clustering in stochastic block models,” *The Annals of Statistics*, **jourvol** 43, **number** 1, **pages** 215–237, 2015. DOI: 10.1214/14-AOS1274
- [19] K. Rohe, S. Chatterjee **and** B. Yu, “Spectral clustering and the high-dimensional stochastic blockmodel,” *The Annals of Statistics*, **jourvol** 39, **number** 4, **pages** 1878–1915, 2011. DOI: 10.1214/11-AOS887
- [20] P. W. Holland, K. B. Laskey **and** S. Leinhardt, “Stochastic blockmodels: First steps,” *Social Networks*, **jourvol** 5, **number** 2, **pages** 109–137, 1983. DOI: 10.1016/0378-8733(83)90021-7
- [21] L. Su, W. Wang **and** Y. Zhang, “Strong consistency of spectral clustering for stochastic block models,” *arXiv preprint arXiv:1710.06191*, 2017.
- [22] A. Condon **and** R. M. Karp, “Algorithms for graph partitioning on the planted partition model,” *Random Structures & Algorithms*, **jourvol** 18, **number** 2, **pages** 116–140, 2001. DOI: 10.1002/1098-2418(200103)18:2<116::AID-RSA1001>3.0.CO;2-2
- [23] A. Lancichinetti, S. Fortunato **and** F. Radicchi, “Benchmark graphs for testing community detection algorithms,” *Physical Review E*, **jourvol** 78, **number** 4, **page** 046 110, 2008. DOI: 10.1103/PhysRevE.78.046110